Отчет по лабораторной работе № 1. Задача 1

НЕГОСУДАРСТВЕННОЕ ОБРАЗОВАТЕЛЬНОЕ ЧАСТНОЕ УЧРЕЖДЕНИЕ ВЫСШЕГО ОБРАЗОВАНИЯ «МОСКОВСКИЙ ФИНАНСОВО-ПРОМЫШЛЕННЫЙ УНИВЕРСИТЕТ «СИНЕРГИЯ»»

Факультет: Информационных технологий
(наименование факультета / института)

Направление подготовки: 09.03.02 Информационные системы и технологии
(код и наименование направления подготовки / специальности)

Форма обучения: очная
(очная, очно-заочная, заочная)

ОТЧЕТ
по лабораторной работе № 1
по дисциплине «Продвинутые технологии работы с большими данными»
на тему: «Задача 1. Разведочный анализ. Базовая визуализация данных»

Обучающийся: Шатов Илья Андреевич
(Фамилия Имя Отчество) (подпись)
Группа: ВБИо-403-рсоб
Преподаватель:
(Фамилия Имя Отчество) (подпись)

Москва 2026 г.

Задача 1. Разведочный анализ. Базовая визуализация данных

Условие. Загрузите встроенный набор данных `diamonds`. Постройте следующие виды визуализации данных: а) гистограммы распределения бриллиантов по цене и глубине; б) столбчатую диаграмму количества бриллиантов по качеству огранки; в) столбчатую диаграмму с подкатегориями; г) диаграмму рассеяния; д) ящики с усами. Сделайте краткие выводы по каждому типу визуализации.

Ход решения

Загружаем набор данных и выполняем первичный осмотр структуры:

```
data(diamonds)
str(diamonds)
## tibble [53,940 × 10] (S3: tbl_df/tbl/data.frame)
##  $ carat  : num [1:53940] 0.23 0.21 0.23 0.29 0.31 0.24 0.24 0.26 0.22
0.23 ...
##  $ cut    : Ord.factor w/ 5 levels "Fair"<"Good"<..: 5 4 2 4 2 3 3 3 1
3 ...
##  $ color  : Ord.factor w/ 7 levels "D"<"E"<"F"<"G"<..: 2 2 2 6 7 7 6 5 2 5
...
##  $ clarity: Ord.factor w/ 8 levels "I1"<"SI2"<"SI1"<..: 2 3 5 4 2 6 7 3 4
5 ...
##  $ depth  : num [1:53940] 61.5 59.8 56.9 62.4 63.3 62.8 62.3 61.9 65.1
59.4 ...
##  $ table  : num [1:53940] 55 61 65 58 58 57 57 55 61 61 ...
##  $ price  : int [1:53940] 326 326 327 334 335 336 336 337 337 338 ...
##  $ x      : num [1:53940] 3.95 3.89 4.05 4.2 4.34 3.94 3.95 4.07 3.87
4 ...
##  $ y      : num [1:53940] 3.98 3.84 4.07 4.23 4.35 3.96 3.98 4.11 3.78
4.05 ...
##  $ z      : num [1:53940] 2.43 2.31 2.31 2.63 2.75 2.48 2.47 2.53 2.49
2.39 ...
```

Сводные статистики по всем переменным:

```
summary(diamonds)
##      carat               cut        color        clarity          depth
##  Min.   :0.2000   Fair      : 1610   D: 6775   SI1    :13065
Min.   :43.00
##  1st Qu.:0.4000   Good      : 4906   E: 9797   VS2    :12258   1st
Qu.:61.00
##  Median :0.7000   Very Good:12082   F: 9542   SI2    : 9194
Median :61.80
##  Mean   :0.7979   Premium   :13791   G:11292   VS1    : 8171
Mean   :61.75
##  3rd Qu.:1.0400   Ideal     :21551   H: 8304   VVS2   : 5066   3rd
Qu.:62.50
##  Max.   :5.0100                     I: 5422   VVS1   : 3655
Max.   :79.00
##                                     J: 2808   (Other): 2531
##      table           price             x                y
##  Min.   :43.00   Min.   :  326   Min.   : 0.000   Min.   : 0.000
##  1st Qu.:56.00   1st Qu.:  950   1st Qu.: 4.710   1st Qu.: 4.720
```

```
##  Median :57.00   Median : 2401   Median : 5.700   Median : 5.710
##  Mean   :57.46   Mean   : 3933   Mean   : 5.731   Mean   : 5.735
##  3rd Qu.:59.00   3rd Qu.: 5324   3rd Qu.: 6.540   3rd Qu.: 6.540
##  Max.   :95.00   Max.   :18823   Max.   :10.740   Max.   :58.900
##
##        z
##  Min.   : 0.000
##  1st Qu.: 2.910
##  Median : 3.530
##  Mean   : 3.539
##  3rd Qu.: 4.040
##  Max.   :31.800
##
```

Проверяем наличие пропусков в данных:

```
colSums(is.na(diamonds))
##   carat     cut   color clarity   depth   table   price       x       y
z
##       0       0       0       0       0       0       0       0       0
0
```

Пропусков нет — все 53940 наблюдений содержат полные данные по 10 переменным (семь количественных и три категориальных: огранка, цвет, чистота).

а) Гистограммы распределения по цене и глубине

Гистограмма распределения цены представлена на рисунке 1.

```
ggplot(diamonds, aes(x = price)) +
  geom_histogram(bins = 30, fill = "steelblue", color = "white") +
  labs(title = "Распределение цены бриллиантов",
       x = "Цена ($)", y = "Количество")
```

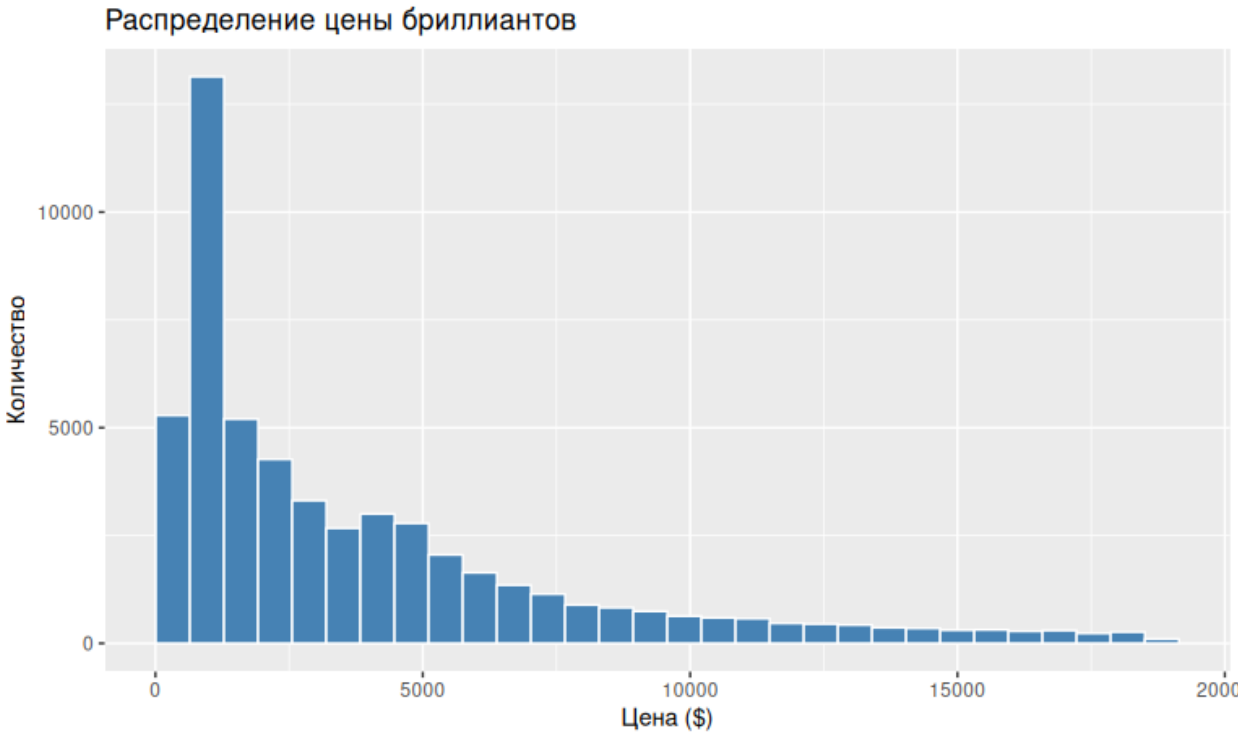


Рисунок 1. Гистограмма распределения бриллиантов по цене

Распределение глубины показано на рисунке 2.

```
ggplot(diamonds, aes(x = depth)) +
  geom_histogram(bins = 30, fill = "darkgreen", color = "white") +
  labs(title = "Распределение глубины бриллиантов",
       x = "Глубина (%)", y = "Количество")
```

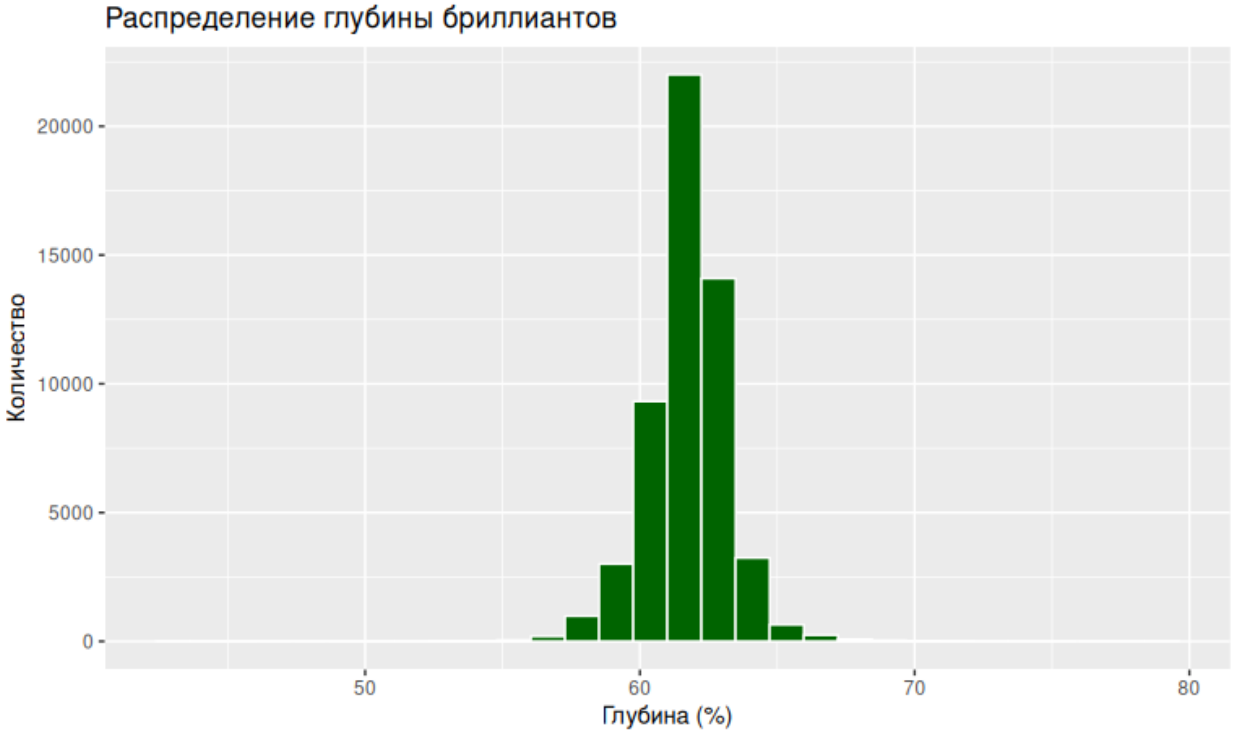


Рисунок 2. Гистограмма распределения бриллиантов по глубине

Вывод. Распределение цены (рисунок 1) сильно правоасимметрично: медиана (2401 $) заметно меньше среднего (3932.8 $), большинство камней дешевле 5000 $, а правый хвост тянется до 18823 $. Распределение глубины (рисунок 2), напротив, близко к нормальному с узкой концентрацией около 61–63 % — технологический параметр огранки держится в пределах стандарта, аномальные значения единичны.

б) Столбчатая диаграмма по качеству огранки

Количество бриллиантов по уровням огранки приведено на рисунке 3.

```
ggplot(diamonds, aes(x = cut, fill = cut)) +
  geom_bar() +
  labs(title = "Количество бриллиантов по качеству огранки",
       x = "Качество огранки", y = "Количество") +
  theme(legend.position = "none")
```

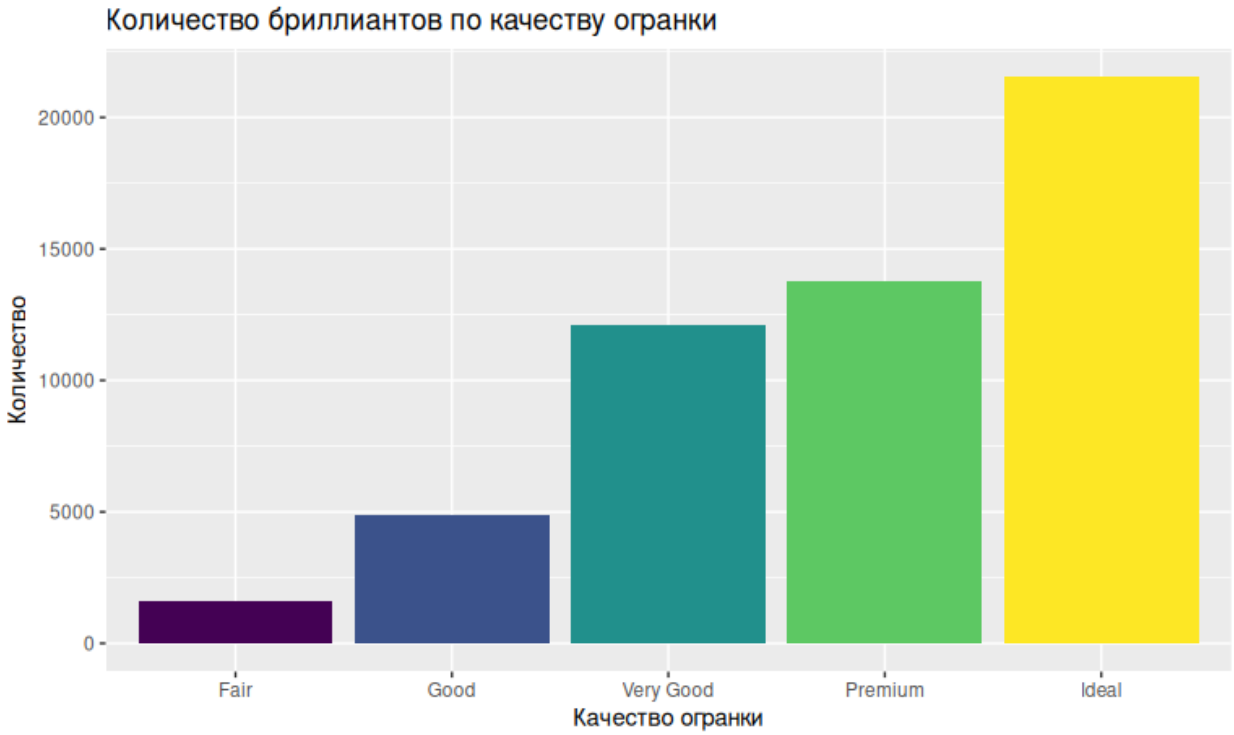


Рисунок 3. Количество бриллиантов по качеству огранки

Вывод. Распределение по огранке (рисунок 3) неравномерно: больше всего камней с огранкой Ideal — 21551 из 53940 (40 %), меньше всего — Fair (1610). Производство ориентировано на качественную огранку: доля двух верхних уровней (Premium и Ideal) превышает 60 %.

в) Столбчатая диаграмма с подкатегориями

Распределение бриллиантов по огранке с разбивкой на подкатегории чистоты представлено на рисунке 4.

```
ggplot(diamonds, aes(x = cut, fill = clarity)) +
  geom_bar(position = "dodge") +
  labs(title = "Количество бриллиантов по огранке и чистоте",
       x = "Качество огранки", y = "Количество", fill = "Чистота") +
  theme(axis.text.x = element_text(angle = 20, hjust = 1))
```

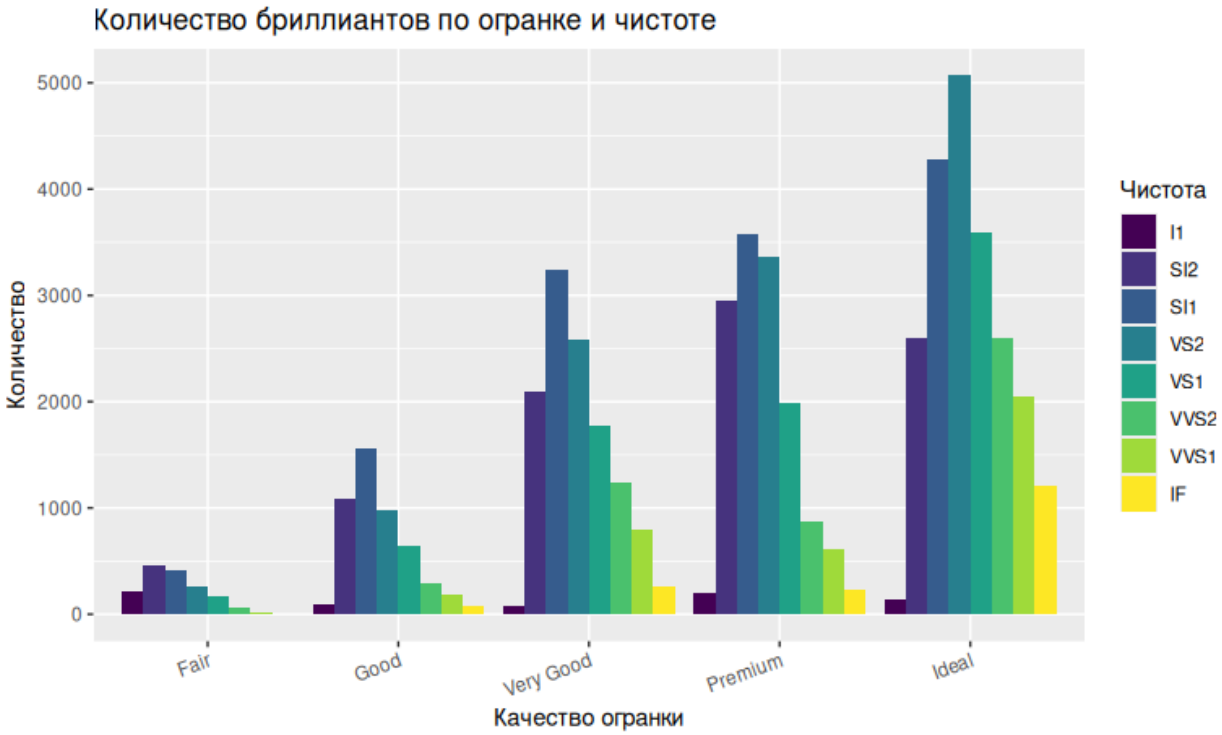


Рисунок 4. Количество бриллиантов по огранке и чистоте

Вывод. Внутри каждой огранки (рисунок 4) встречаются все уровни чистоты; чаще всего — SI1 и VS2, реже всего — FL и I1. Высокая огранка не гарантирует высокую чистоту: характеристики практически независимы, поэтому при оценке камня их нужно рассматривать совместно.

г) Диаграмма рассеяния

Совмещённая диаграмма рассеяния и ящиков с усами для связи «огранка — глубина» приведена на рисунке 5.

```
ggplot(diamonds, aes(x = cut, y = depth)) +
  geom_jitter(alpha = 0.2, color = "steelblue") +
  geom_boxplot(alpha = 0.5, fill = NA, color = "black", outlier.shape = NA) +
  labs(title = "Качество огранки и глубина",
       x = "Качество огранки", y = "Глубина (%)")
```

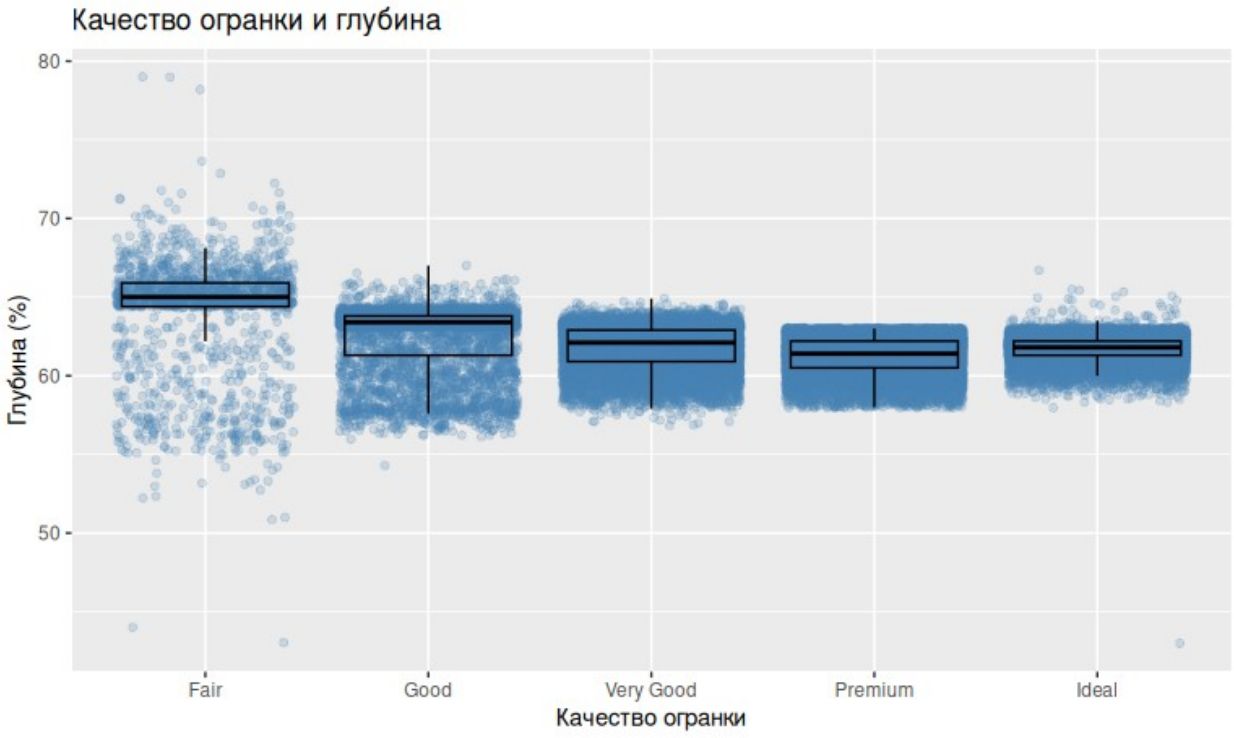


Рисунок 5. Качество огранки и глубина (джиттер + ящики с усами)

Классическая диаграмма рассеяния «вес — цена» показана на рисунке 6.

```
ggplot(diamonds, aes(x = carat, y = price, color = cut)) +
  geom_point(alpha = 0.25) +
  labs(title = "Зависимость цены от веса бриллианта",
       x = "Вес (карат)", y = "Цена ($)", color = "Огранка")
```

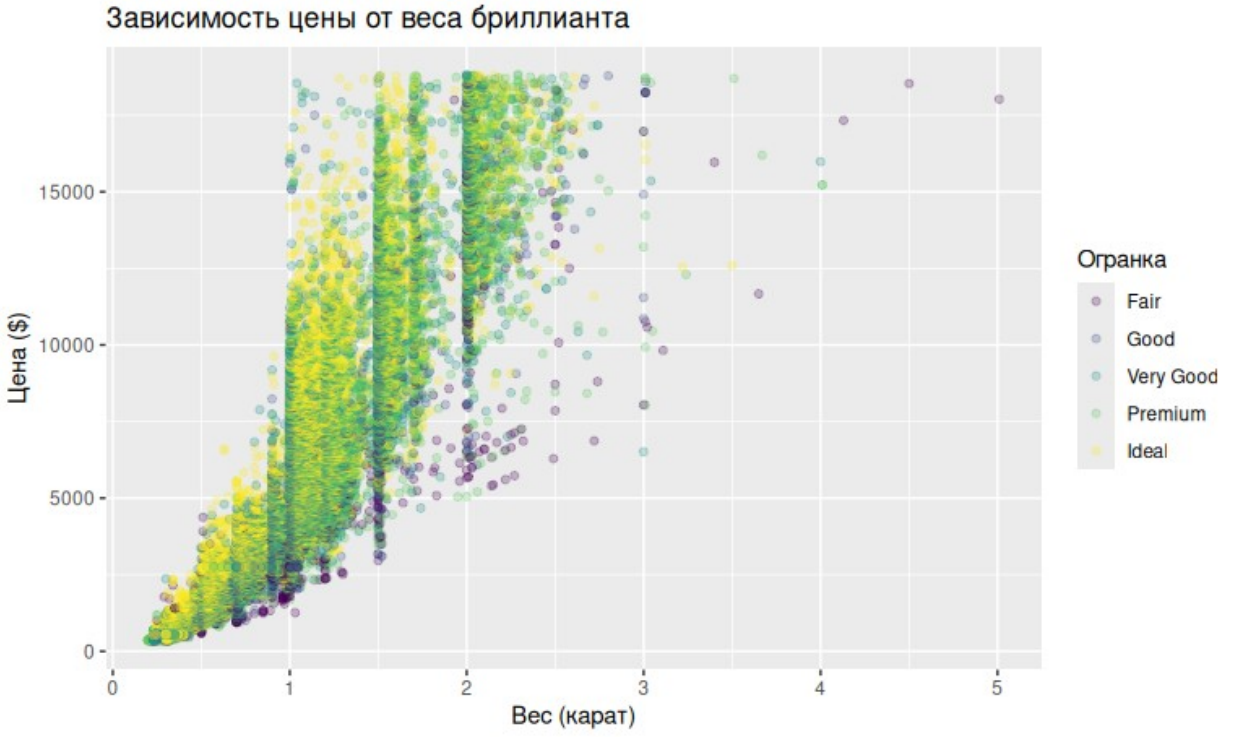


Рисунок 6. Зависимость цены от веса бриллианта

Вывод. Точки глубины (рисунок 5) плотно и симметрично группируются вокруг медианы каждой категории огранки — систематических выбросов по глубине нет. На диаграмме рассеяния (рисунок 6) видна нелинейная (близкая к экспоненциальной) связь цены с весом: цена быстро растёт с каратом, а при равном весе разброс цены велик — на цену дополнительно влияют чистота и цвет.

д) Ящики с усами

Распределение цены по уровням огранки представлено на рисунке 7.

```
ggplot(diamonds, aes(x = cut, y = price, fill = cut)) +
  geom_boxplot() +
  labs(title = "Цена по качеству огранки",
       x = "Качество огранки", y = "Цена ($)") +
  theme(legend.position = "none")
```

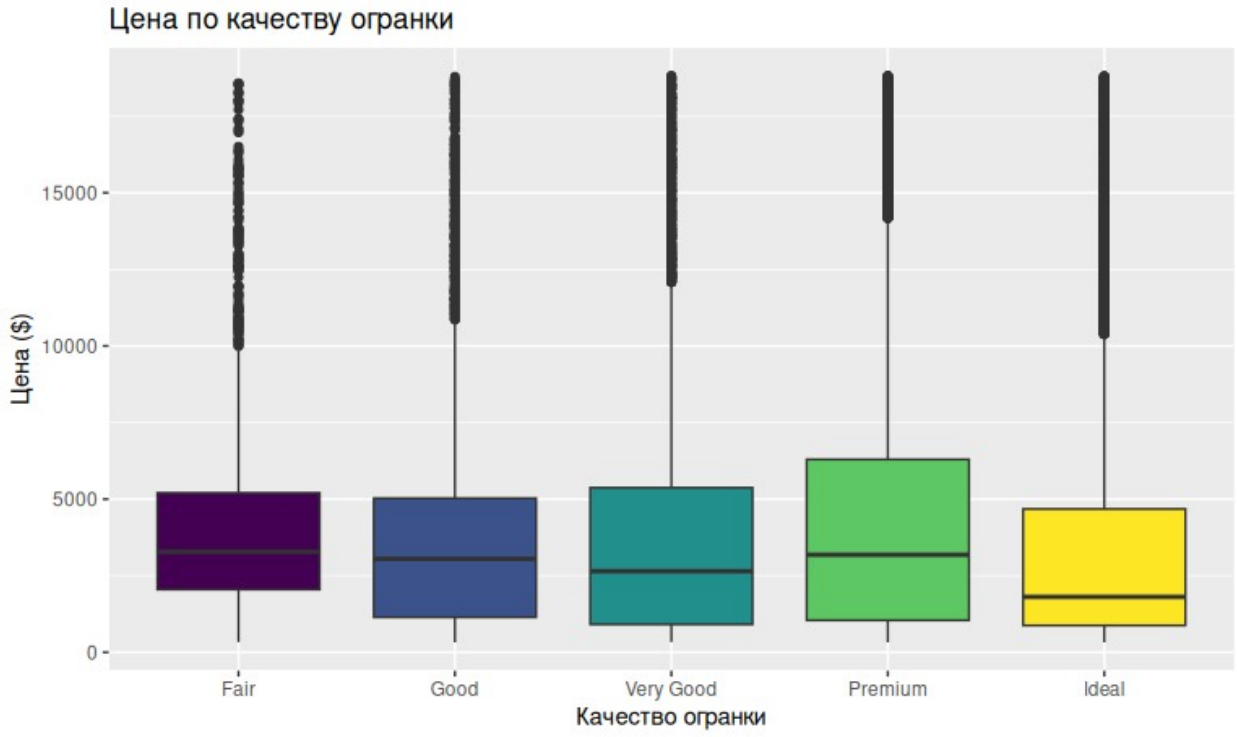


Рисунок 7. Цена по качеству огранки (ящики с усами)

Вывод. Медианная цена (рисунок 7) почти не растёт с качеством огранки, а у Ideal даже ниже, чем у Premium: огранка — не главный фактор цены. Во всех категориях много «дорогих» выбросов выше усов — рынок формируют вес, чистота и цвет, а не огранка сама по себе.

Выводы

В ходе выполнения задачи 1 проведён разведочный анализ набора данных diamonds (53940 наблюдений, 10 переменных, пропусков нет) и построены все требуемые виды визуализации: гистограммы цены и глубины (рисунки 1–2), столбчатые диаграммы по огранке и с подкатегориями чистоты (рисунки 3–4), диаграммы рассеяния (рисунки 5–6), ящики с усами (рисунок 7). Установлено: распределение цены правоасимметрично, глубина — нормальна; огранка смещена к качественным уровням; цена нелинейно зависит от веса и слабо — от огранки.