Отчет по лабораторной работе № 1. Задача 2

НЕГОСУДАРСТВЕННОЕ ОБРАЗОВАТЕЛЬНОЕ ЧАСТНОЕ
УЧРЕЖДЕНИЕ ВЫСШЕГО ОБРАЗОВАНИЯ
«МОСКОВСКИЙ ФИНАНСОВО-ПРОМЫШЛЕННЫЙ УНИВЕРСИТЕТ
«СИНЕРГИЯ»»
Институт информационных технологий
Направление подготовки: 09.03.02 Информационные системы и технологии
Форма обучения: очная
ОТЧЕТ
по лабораторной работе № 1
по дисциплине «Продвинутые технологии работы с большими данными»
на тему: «Задача 2. Разведочный анализ данных на основе датасета mtcars»
Обучающийся: Шатов Илья Андреевич
Группа: ВБИо-403-рсоб
Преподаватель: _____
Москва 2026 г.

Задача 2. Разведочный анализ данных на основе датасета mtcars

Условие. Загрузите встроенный датасет `mtcars` и выполните его комплексный статистический анализ средствами `dplyr`, `tidyr`, `broom` и `plotly`: рассчитайте описательные статистики (среднее, медиану, моду, стандартное отклонение, минимум, максимум) для всех переменных, реализовав функцию вычисления выборочной моды; постройте график плотности распределения `mpg`, совместив гистограмму, ядерную оценку плотности и теоретическую кривую нормального распределения; выполните проверку нормальности через QQ-plot и тест Шапиро–Уилка; постройте boxplot с отображением всех точек и выявите выбросы методом межквартильного размаха (IQR); выполните группировку по числу цилиндров средствами `dplyr` с визуализацией групповых статистик; проверьте гипотезу о равенстве средних `mpg` между автомобилями с 4 и 6 цилиндрами (t-тест); выполните однофакторный дисперсионный анализ (ANOVA) по трём группам цилиндров с пост-хок тестом Тьюки (Tukey HSD) и визуализацией попарных различий с выделением значимых контрастов цветом.

Ход решения

Описательные статистики и расчёт моды

Функция выборочной моды реализована вручную: среди уникальных значений выбирается то, которое встречается чаще всего.

Таблица 1. Описательные статистики переменных mtcars

```
get_mode <- function(x) {
  ux <- unique(x)
  ux[which.max(tabulate(match(x, ux)))]
}

modes <- sapply(mtcars, get_mode)

extended_stats <- data.frame(
  Variable = names(mtcars),
  Mean     = round(sapply(mtcars, mean), 2),
  Median   = sapply(mtcars, median),
```

```
  Mode      = modes,
  SD        = round(sapply(mtcars, sd), 2),
  Min       = sapply(mtcars, min),
  Max       = sapply(mtcars, max),
  row.names = NULL
)
knitr::kable(extended_stats)
```

V	M	M	M	S	M	M
ariable	ean	edian	ode	D	in	ax
m	2	1	2	6	1	3
pg	0.09	9.200	1.00	.03	0.400	3.900
c	6	6	8	1	4	8
yl	.19	.000	.00	.79	.000	.000
d	2	1	2	1	7	4
isp	30.72	96.300	75.80	23.94	1.100	72.000
h	1	1	1	6	5	3
p	46.69	23.000	10.00	8.56	2.000	35.000
d	3	3	3	0	2	4
rat	.60	.695	.92	.53	.760	.930
w	3	3	3	0	1	5
t	.22	.325	.44	.98	.513	.424
q	1	1	1	1	1	2
sec	7.85	7.710	7.02	.79	4.500	2.900
v	0	0	0	0	0	1
s	.44	.000	.00	.50	.000	.000
a	0	0	0	0	0	1
m	.41	.000	.00	.50	.000	.000
g	3	4	3	0	3	5
ear	.69	.000	.00	.74	.000	.000
c	2	2	4	1	1	8
arb	.81	.000	.00	.62	.000	.000

Вывод. По данным таблицы 1, средний расход — 20.09 миль на галлон при медиане 19.2 и стандартном отклонении 6.03. Медиана меньше среднего,

что указывает на правую асимметрию распределения `mpg`; мода расхода — 21 mpg, мода числа цилиндров — 8, мода числа карбюраторов — 4.

Плотность распределения mpg

Гистограмма, ядерная оценка плотности и теоретическая нормальная кривая совмещены на рисунке 1 (интерактивная версия построена средствами `plotly` и сохранена в `output/task2_density_mpg.html`).

```
dfn <- data.frame(x = seq(min(mtcars$mpg), max(mtcars$mpg), length.out =
200))
dfn$y <- dnorm(dfn$x, mean = mean(mtcars$mpg), sd = sd(mtcars$mpg))
ggplot(mtcars, aes(x = mpg)) +
  geom_histogram(aes(y = after_stat(density)), bins = 10,
                 fill = scales::alpha("#6496DC", 0.55), color = "white") +
  geom_density(color = "#d62728", linewidth = 1) +
  geom_line(data = dfn, aes(x, y), color = "green",
            linetype = "dashed", linewidth = 0.9) +
  labs(title = "Плотность распределения mpg",
       x = "mpg (миль на галлон)", y = "Плотность вероятности")
```

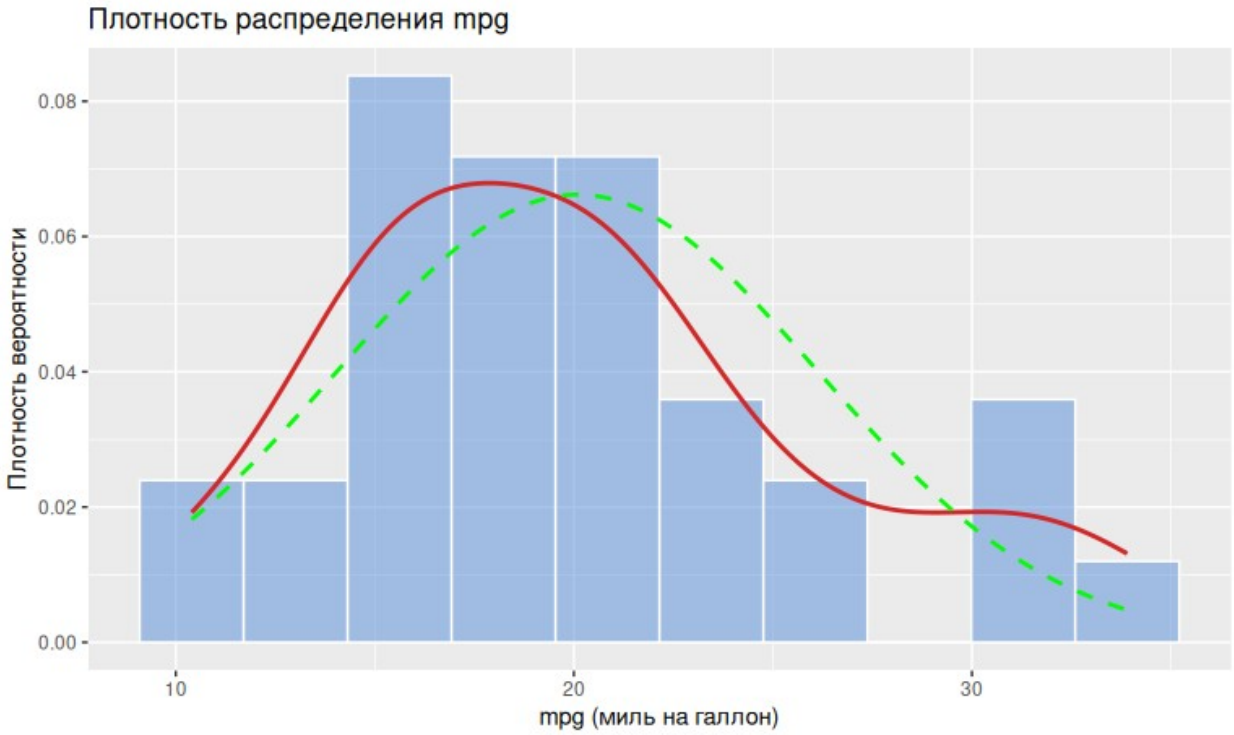


Рисунок 1. Плотность распределения mpg: гистограмма, ядерная оценка и нормальная кривая

Вывод. Ядерная оценка плотности (рисунок 1) повторяет форму гистограммы; нормальная кривая с теми же средним и дисперсией проходит близко, но не идеальна — распределение слегка многовершинное, что типично для смеси групп с разным числом цилиндров.

Проверка нормальности: QQ-plot и тест Шапиро–Уилка

QQ-plot для `mpg` представлен на рисунке 2.

```
qq_data <- as.data.frame(qqnorm(mtcars$mpg, plot.it = FALSE))
qq_data$line <- fitted(lm(y ~ x, data = qq_data))
ggplot(qq_data, aes(x, y)) +
  geom_point(color = "#1f77b4", size = 2.5) +
  geom_line(aes(y = line), color = "red") +
  labs(title = "QQ-plot для mpg",
       x = "Теоретические квантили (нормальное)",
       y = "Выборочные квантили (mpg)")
```

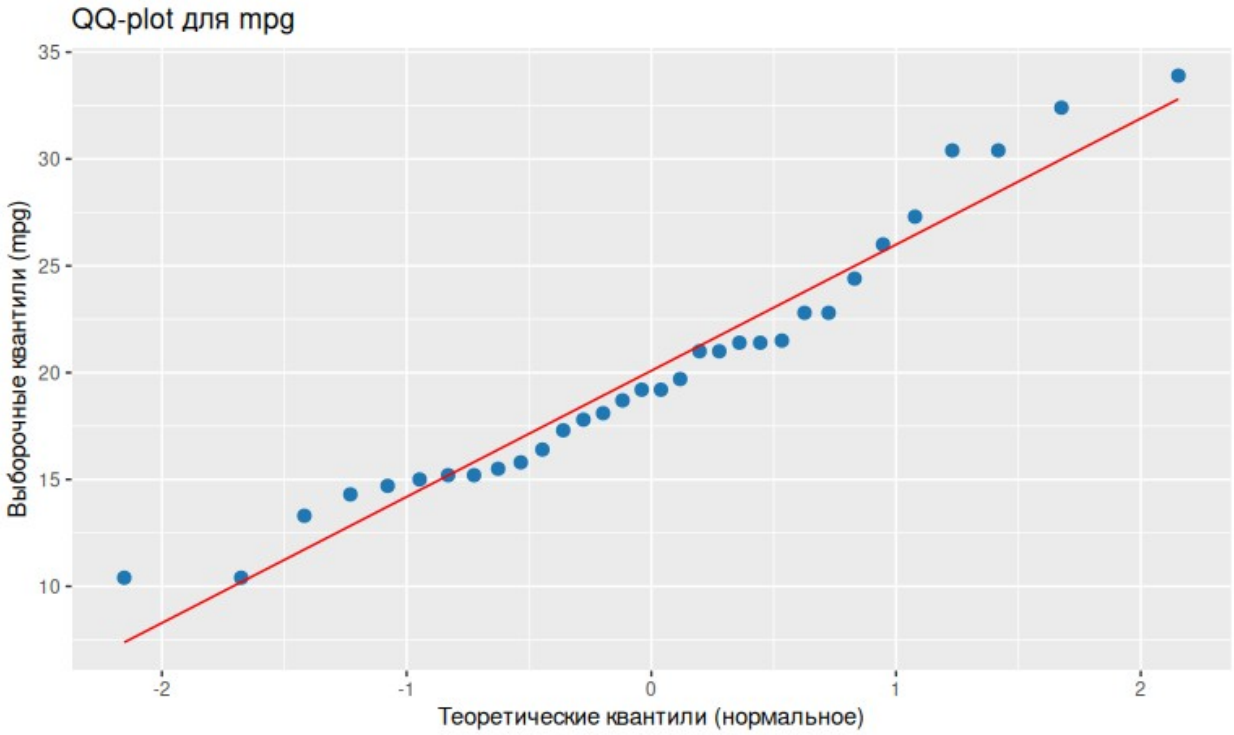


Рисунок 2. QQ-plot для mpg

```
shapiro_res <- shapiro.test(mtcars$mpg)
print(shapiro_res)
##
##  Shapiro-Wilk normality test
##
## data:  mtcars$mpg
## W = 0.94756, p-value = 0.1229
```

Гипотезы. H_0 — распределение `mpg` нормально; H_1 — не нормально.

Интерпретация. Статистика Шапиро–Уилка W = 0.9476, p-значение = 0.1229 > 0.05 — данных против H_0 недостаточно; точки QQ-plot (рисунок 2) лежат близко к опорной прямой.

Вывод. На уровне значимости 0.05 гипотеза о нормальности `mpg` не отвергается — параметрические методы (t-тест, ANOVA) применимы.

Boxplot и выбросы методом IQR

Ящик с усами с отображением всех наблюдений приведён на рисунке 3.

```
ggplot(mtcars, aes(x = "", y = mpg)) +
  geom_boxplot(fill = scales::alpha("#FFB4B4", 0.4), color = "#d62728",
               outlier.shape = NA) +
  geom_jitter(width = 0.12, size = 2.3, color = "#2ca02c") +
  labs(title = "Boxplot для mpg", x = NULL, y = "mpg") +
  theme(axis.text.x = element_blank(), axis.ticks.x = element_blank())
```

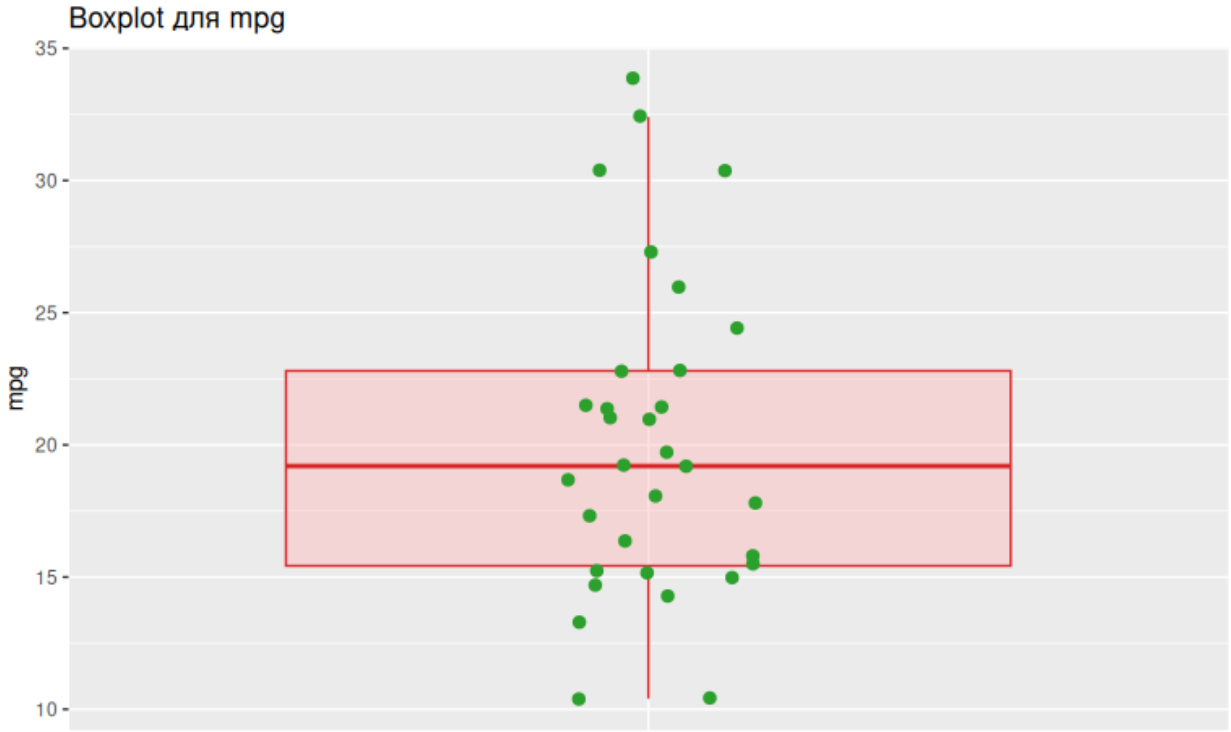


Рисунок 3. Boxplot mpg с отображением всех точек

Границы нормы и список автомобилей-выбросов определяются по правилу 1.5·IQR:

```
Q1 <- quantile(mtcars$mpg, 0.25)
Q3 <- quantile(mtcars$mpg, 0.75)
IQR_val <- Q3 - Q1
lower_bound <- Q1 - 1.5 * IQR_val
upper_bound <- Q3 + 1.5 * IQR_val

cat(sprintf("Q1 = %.2f, Q3 = %.2f, IQR = %.2f\n", Q1, Q3, IQR_val))
## Q1 = 15.43, Q3 = 22.80, IQR = 7.38
cat(sprintf("Границы нормы: [%.2f ; %.2f]\n", lower_bound, upper_bound))
## Границы нормы: [4.36 ; 33.86]
out_rows <- mtcars[mtcars$mpg < lower_bound | mtcars$mpg > upper_bound,
                   c("mpg", "cyl", "hp")]
out_cars <- rownames(out_rows)
cat("Автомобили-выбросы:", paste(out_cars, collapse = ", "), "\n")
## Автомобили-выбросы: Toyota Corolla
knitr::kable(out_rows)
```

	mpg	cyl	hp
Toyota	33.9	4	65

	mpg	cyl	hp
Corolla			

Вывод. По рисунку 3 и расчёту, границы нормы составляют [4.36; 33.86] миль на галлон. Выброс один — Toyota Corolla (33.9 mpg, 4 цилиндра, 65 л.с.): экономичный компактный автомобиль на фоне мощных машин выборки. Выброс отражает реальное свойство объекта, ошибкой данных не является и из анализа не удаляется.

Группировка по числу цилиндров (dplyr)

Групповые статистики, рассчитанные цепочкой `group_by()` + `summarise()`, приведены в таблице 2.

Таблица 2. Групповые статистики mpg по числу цилиндров

```
group_stats <- mtcars %>%
  group_by(cyl) %>%
  summarise(n = n(), mean_mpg = mean(mpg), median_mpg = median(mpg),
            sd_mpg = sd(mpg), .groups = "drop")
knitr::kable(group_stats, digits = 2)
```

cyl	n	mean_mpg	median_mpg	sd_mpg
4	11	26.66	26.0	4.51
6	7	19.74	19.7	1.45
8	14	15.10	15.2	2.56

Средние по группам со стандартными отклонениями визуализированы на рисунке 4.

```
ggplot(group_stats, aes(x = factor(cyl), y = mean_mpg, fill = factor(cyl))) +
  geom_col(width = 0.6) +
  geom_errorbar(aes(ymin = mean_mpg - sd_mpg, ymax = mean_mpg + sd_mpg),
                width = 0.15, color = "#333333") +
  scale_fill_manual(values = c("#1f77b4", "#ff7f0e", "#2ca02c")) +
  labs(title = "Средний mpg по группам цилиндров (± SD)",
       x = "Число цилиндров", y = "Средний mpg") +
  theme(legend.position = "none")
```

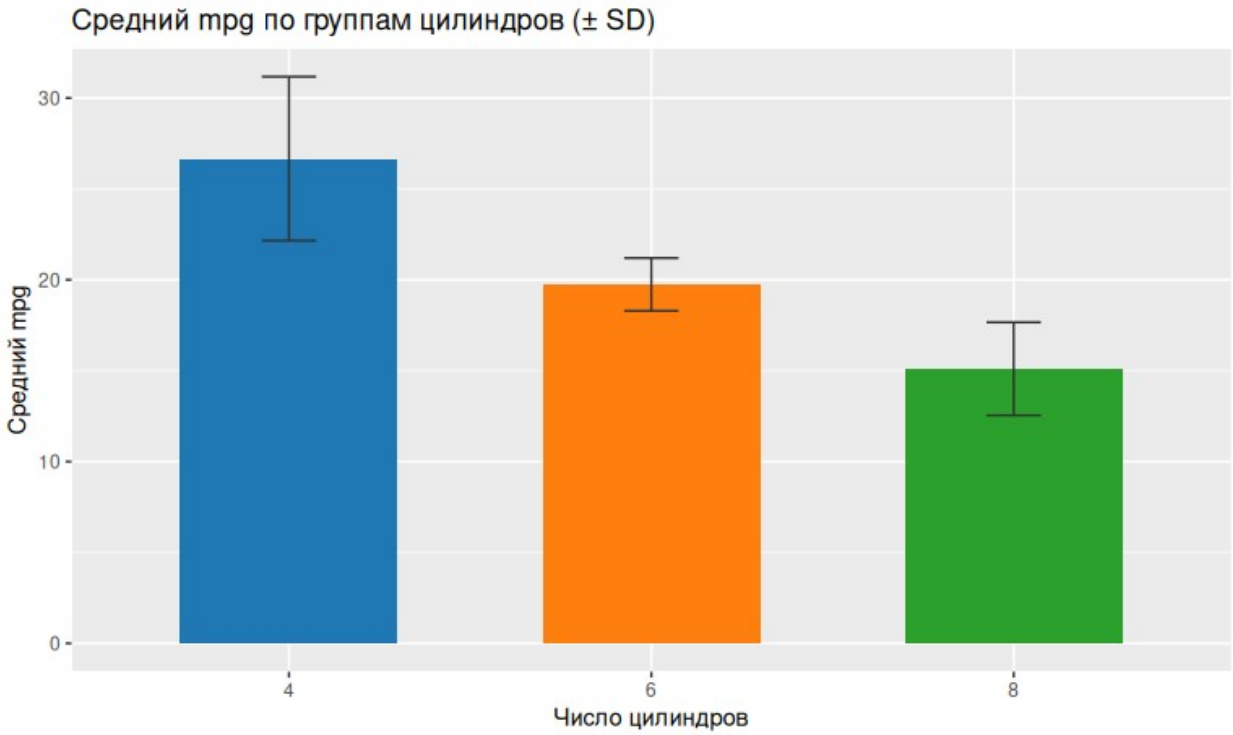


Рисунок 4. Средний mpg по группам цилиндров (± SD)

Вывод. По таблице 2 и рисунку 4 средний расход закономерно падает с ростом числа цилиндров: 26.7 → 19.7 → 15.1 миль на галлон для 4/6/8 цилиндров. Группы невелики (n = 11/7/14), поэтому стандартные отклонения существенны, особенно в группе с 4 цилиндрами.

t-тест: 4 против 6 цилиндров

```
t_res <- t.test(mpg ~ cyl, data = mtcars %>% filter(cyl %in% c(4, 6)))
print(t_res)
##
##  Welch Two Sample t-test
##
## data:  mpg by cyl
## t = 4.7191, df = 12.956, p-value = 0.0004048
## alternative hypothesis: true difference in means between group 4 and group
6 is not equal to 0
## 95 percent confidence interval:
##   3.751376 10.090182
## sample estimates:
## mean in group 4 mean in group 6
##        26.66364        19.74286
```

Гипотезы. H_0 — средний `mpg` автомобилей с 4 и 6 цилиндрами одинаков; H_1 — различается.

Интерпретация. t-статистика = 4.719, p-значение = 0.000405 < 0.05; 95 %-й доверительный интервал разности средних [3.75; 10.09] не содержит нуля.

Вывод. Нулевая гипотеза отвергается: средний `mpg` автомобилей с 4 цилиндрами статистически значимо выше, чем с 6 (разница около 6.9 миль на галлон).

Однофакторный ANOVA и тест Тьюки

```
mtcars$cyl_f <- factor(mtcars$cyl)
anova_res <- aov(mpg ~ cyl_f, data = mtcars)
print(summary(anova_res))
##             Df Sum Sq Mean Sq F value   Pr(>F)
## cyl_f        2  824.8   412.4    39.7 4.98e-09 ***
## Residuals   29  301.3    10.4
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
tukey_res <- TukeyHSD(anova_res)
print(tukey_res)
##   Tukey multiple comparisons of means
##     95% family-wise confidence level
##
## Fit: aov(formula = mpg ~ cyl_f, data = mtcars)
##
## $cyl_f
##           diff        lwr        upr     p adj
## 6-4  -6.920779 -10.769350 -3.0722086 0.0003424
## 8-4 -11.563636 -14.770779 -8.3564942 0.0000000
## 8-6  -4.642857  -8.327583 -0.9581313 0.0112287
```

Попарные различия средних по тесту Тьюки визуализированы на рисунке 5; значимые контрасты (p adj < 0.05) выделены тёмным цветом.

```
tukey_df <- as.data.frame(tukey_res$cyl_f)
tukey_df$comparison <- rownames(tukey_df)
tukey_df$half <- (tukey_df$upr - tukey_df$lwr) / 2
ggplot(tukey_df, aes(x = comparison, y = diff, fill = `p adj` < 0.05)) +
  geom_col(width = 0.6) +
  geom_errorbar(aes(ymin = diff - half, ymax = diff + half),
                width = 0.15, color = "#333333") +
  scale_fill_manual(values = c("#7f7f7f", "#d62728"),
                    labels = c("p >= 0.05", "p < 0.05")) +
  labs(title = "Tukey HSD: попарные различия средних mpg",
       x = "Сравнение групп", y = "Разница средних", fill = "") +
  theme(legend.position = "top")
```

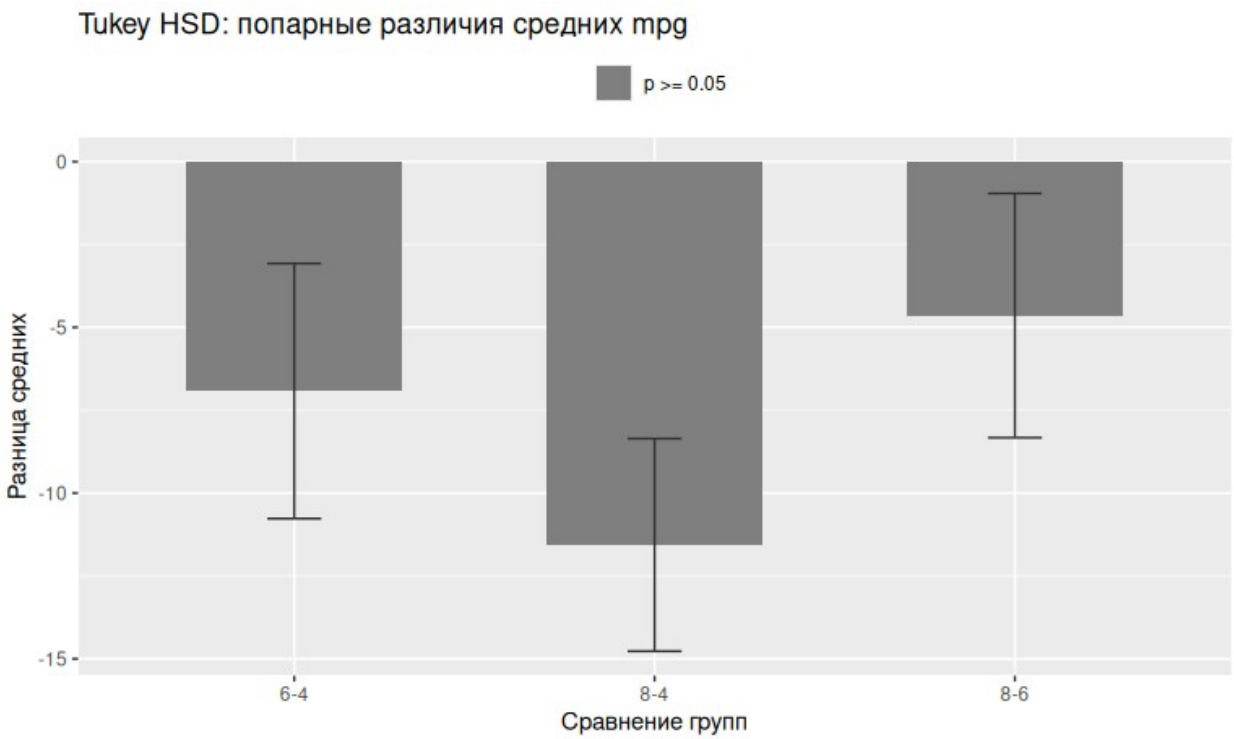


Рисунок 5. Tukey HSD: попарные различия средних mpg

Гипотезы. H_0 — средний `mpg` во всех трёх группах цилиндров одинаков; H_1 — хотя бы в одной группе отличается.

Интерпретация. F-статистика ANOVA = 39.7 при p-значении 4.979e-09 < 0.05. Пост-хок тест Тьюки (рисунок 5) показывает значимость всех трёх попарных контрастов (все p adj < 0.05).

Вывод. Число цилиндров значимо влияет на расход топлива; все попарные различия средних статистически значимы, наибольшая разница — между 8 и 4 цилиндрами (11.6 миль на галлон).

Выводы

В ходе выполнения задачи 2 проведён комплексный статистический анализ датасета mtcars: рассчитаны описательные статистики всех 11 переменных с ручной реализацией выборочной моды (таблица 1); построена плотность распределения `mpg` (рисунок 1); нормальность подтверждена QQ-plot и тестом Шапиро–Уилка (W = 0.9476, p = 0.1229); по методу IQR найден один выброс — Toyota Corolla (рисунок 3); группировка по цилиндрам (таблица 2, рисунок 4) показала монотонное снижение расхода с ростом числа цилиндров; t-тест (p = 0.000405) и ANOVA с тестом Тьюки (рисунок 5) статистически значимо подтвердили различия между всеми группами.