Отчет по лабораторной работе № 1. Задача 2

НЕГОСУДАРСТВЕННОЕ ОБРАЗОВАТЕЛЬНОЕ ЧАСТНОЕ УЧРЕЖДЕНИЕ ВЫСШЕГО ОБРАЗОВАНИЯ «МОСКОВСКИЙ ФИНАНСОВО-ПРОМЫШЛЕННЫЙ УНИВЕРСИТЕТ «СИНЕРГИЯ»»

Факультет: Информационных технологий
(наименование факультета / института)

Направление подготовки: 09.03.02 Информационные системы и технологии
(код и наименование направления подготовки / специальности)

Форма обучения: очная
(очная, очно-заочная, заочная)

ОТЧЕТ
по лабораторной работе № 1
по дисциплине «Продвинутые технологии работы с большими данными»
на тему: «Задача 2. Разведочный анализ данных на основе датасета mtcars»

Обучающийся: Шатов Илья Андреевич
(Фамилия Имя Отчество) (подпись)
Группа: ВБИо-403-рсоб
Преподаватель:
(Фамилия Имя Отчество) (подпись)

Москва 2026 г.

Задача 2. Разведочный анализ данных на основе датасета mtcars

Условие. Загрузите встроенный датасет `mtcars` и выполните его комплексный статистический анализ средствами `dplyr`, `tidyr`, `broom` и `plotly`: рассчитайте описательные статистики (среднее, медиану, моду, стандартное отклонение, минимум, максимум) для всех переменных, реализовав функцию вычисления выборочной моды; постройте график плотности распределения `mpg`, совместив гистограмму, ядерную оценку плотности и теоретическую кривую нормального распределения; выполните проверку нормальности через QQ-plot и тест Шапиро–Уилка; постройте boxplot с отображением всех точек и выявите выбросы методом межквартильного размаха (IQR); выполните группировку по числу цилиндров средствами `dplyr` с визуализацией групповых статистик; проверьте гипотезу о равенстве средних `mpg` между автомобилями с 4 и 6 цилиндрами (t-тест); выполните однофакторный дисперсионный анализ (ANOVA) по трём группам цилиндров с пост-хок тестом Тьюки (Tukey HSD) и визуализацией попарных различий с выделением значимых контрастов цветом.

Ход решения

Описательные статистики и расчёт моды

Функция выборочной моды реализована вручную: среди уникальных значений выбирается то, которое встречается чаще всего.

Таблица 1

Описательные статистики переменных mtcars.

```
get_mode <- function(x) {
  ux <- unique(x)
  ux[which.max(tabulate(match(x, ux)))]
}

modes <- sapply(mtcars, get_mode)

extended_stats <- data.frame(
  Variable = names(mtcars),
  Mean     = round(sapply(mtcars, mean), 2),
  Median   = sapply(mtcars, median),
  Mode     = modes,
  SD       = round(sapply(mtcars, sd), 2),
  Min      = sapply(mtcars, min),
```

```
  Max      = sapply(mtcars, max),
  row.names = NULL
)
knitr::kable(extended_stats)
```

Variable	Mean	Median	Mode	SD	Min	Max
mpg	20.09	19.200	21.00	6.03	10.400	33.900
cyl	6.19	6.000	8.00	1.79	4.000	8.000
disp	230.72	196.300	275.80	123.94	71.100	472.000
hp	146.69	123.000	110.00	68.56	52.000	335.000
drat	3.60	3.695	3.92	0.53	2.760	4.930
wt	3.22	3.325	3.44	0.98	1.513	5.424
qsec	17.85	17.710	17.02	1.79	14.500	22.900
vs	0.44	0.000	0.00	0.50	0.000	1.000
am	0.41	0.000	0.00	0.50	0.000	1.000
gear	3.69	4.000	3.00	0.74	3.000	5.000
carb	2.81	2.000	4.00	1.62	1.000	8.000

Вывод. По данным таблицы 1, средний расход — 20.09 миль на галлон при медиане 19.2 и стандартном отклонении 6.03. Медиана меньше среднего, что указывает на правую асимметрию распределения `mpg`; мода расхода — 21 mpg, мода числа цилиндров — 8, мода числа карбюраторов — 4.

Плотность распределения mpg

Гистограмма, ядерная оценка плотности и теоретическая нормальная кривая совмещены на рисунке 1 (интерактивная версия построена средствами `plotly` и сохранена в `output/task2_density_mpg.html`).

```
dfn <- data.frame(x = seq(min(mtcars$mpg), max(mtcars$mpg), length.out =
200))
dfn$y <- dnorm(dfn$x, mean = mean(mtcars$mpg), sd = sd(mtcars$mpg))
ggplot(mtcars, aes(x = mpg)) +
  geom_histogram(aes(y = after_stat(density)), bins = 10,
                 fill = scales::alpha("#6496DC", 0.55), color = "white") +
  geom_density(color = "#d62728", linewidth = 1) +
  geom_line(data = dfn, aes(x, y), color = "green",
            linetype = "dashed", linewidth = 0.9) +
  labs(title = "Плотность распределения mpg",
       x = "mpg (миль на галлон)", y = "Плотность вероятности")
```

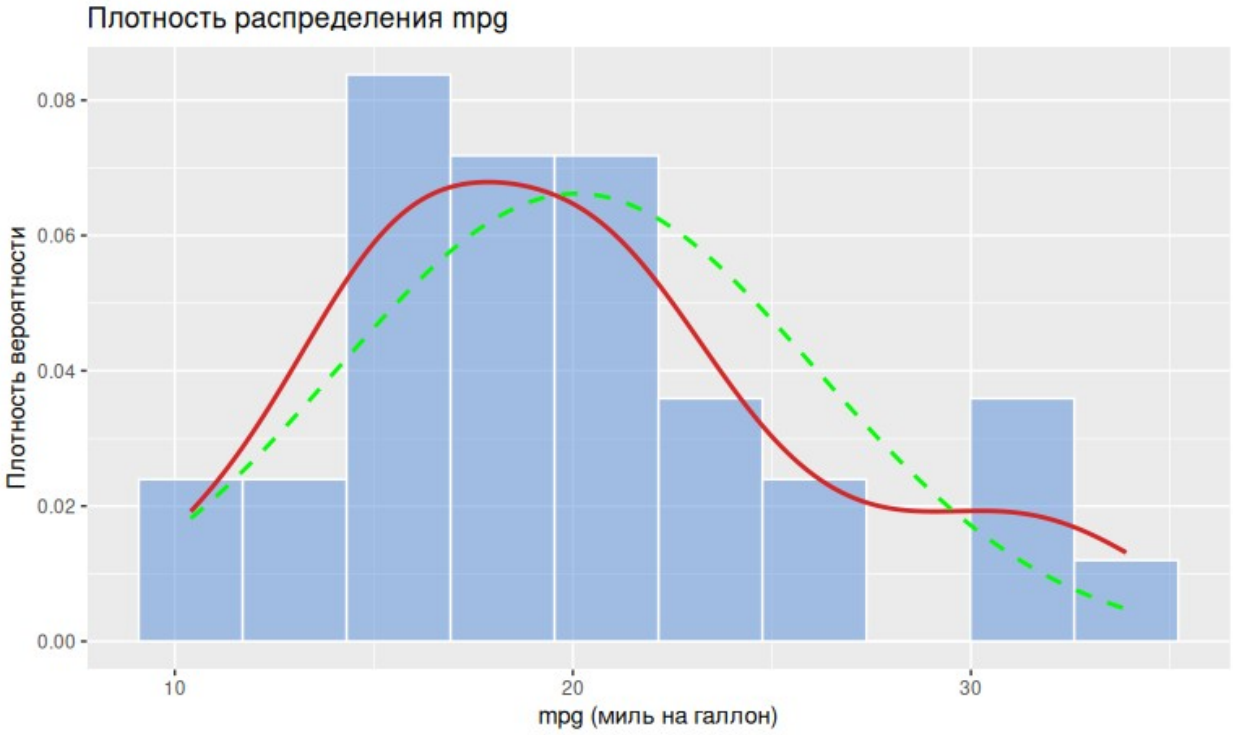


Рисунок 1. Плотность распределения mpg: гистограмма, ядерная оценка и нормальная кривая

Вывод. Ядерная оценка плотности (рисунок 1) повторяет форму гистограммы; нормальная кривая с теми же средним и дисперсией проходит близко, но не идеальна — распределение слегка многовершинное, что типично для смеси групп с разным числом цилиндров.

Проверка нормальности: QQ-plot и тест Шапиро–Уилка

QQ-plot для `mpg` представлен на рисунке 2.

```r
qq_data <- as.data.frame(qqnorm(mtcars$mpg, plot.it = FALSE))
qq_data$line <- fitted(lm(y ~ x, data = qq_data))
ggplot(qq_data, aes(x, y)) +
  geom_point(color = "#1f77b4", size = 2.5) +
  geom_line(aes(y = line), color = "red") +
  labs(title = "QQ-plot для mpg",
       x = "Теоретические квантили (нормальное)",
       y = "Выборочные квантили (mpg)")
```

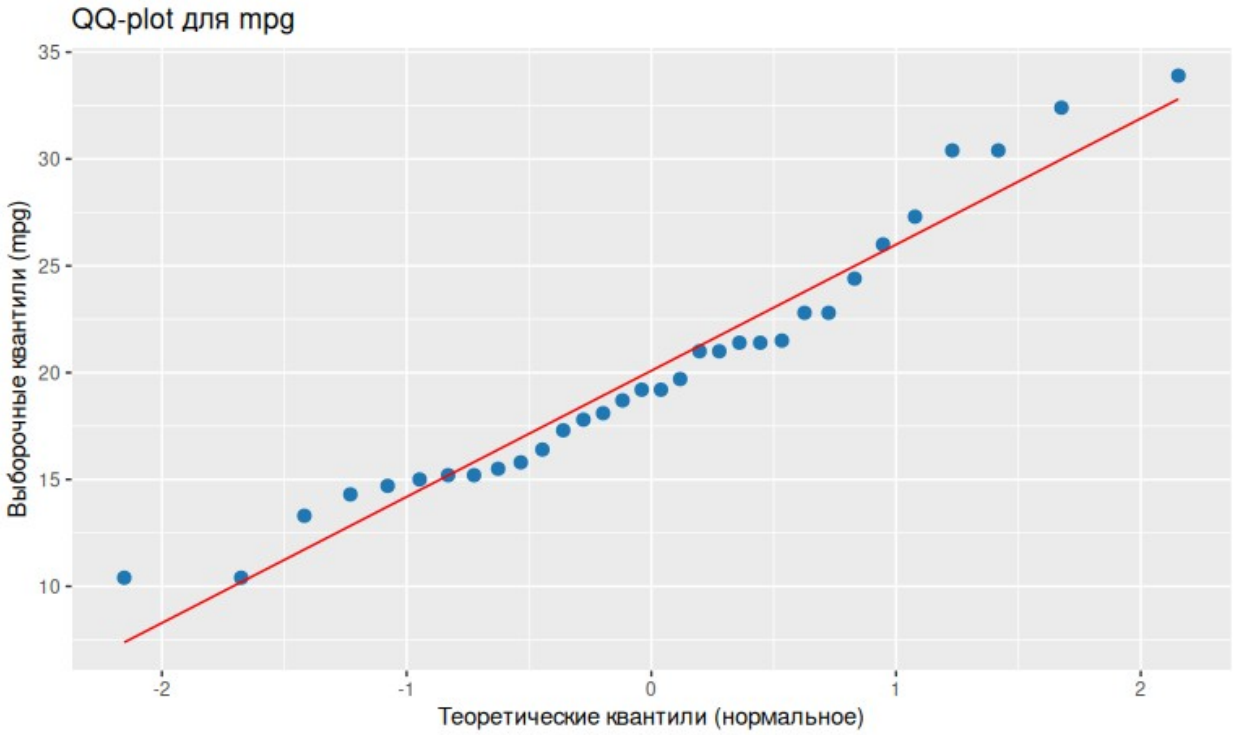


Рисунок 2. QQ-plot для mpg

```r
shapiro_res <- shapiro.test(mtcars$mpg)
print(shapiro_res)
##
##  Shapiro-Wilk normality test
##
## data:  mtcars$mpg
## W = 0.94756, p-value = 0.1229
```

Гипотезы. H_0 — распределение `mpg` нормально; H_1 — не нормально.

Интерпретация. Статистика Шапиро–Уилка W = 0.9476, p-значение = 0.1229 > 0.05 — данных против H_0 недостаточно; точки QQ-plot (рисунок 2) лежат близко к опорной прямой.

Вывод. На уровне значимости 0.05 гипотеза о нормальности `mpg` не отвергается — параметрические методы (t-тест, ANOVA) применимы.

Boxplot и выбросы методом IQR

Ящик с усами с отображением всех наблюдений приведён на рисунке 3.

```r
ggplot(mtcars, aes(x = "", y = mpg)) +
  geom_boxplot(fill = scales::alpha("#FFB4B4", 0.4), color = "#d62728",
```

```
              outlier.shape = NA) +
  geom_jitter(width = 0.12, size = 2.3, color = "#2ca02c") +
  labs(title = "Boxplot для mpg", x = NULL, y = "mpg") +
  theme(axis.text.x = element_blank(), axis.ticks.x = element_blank())
```

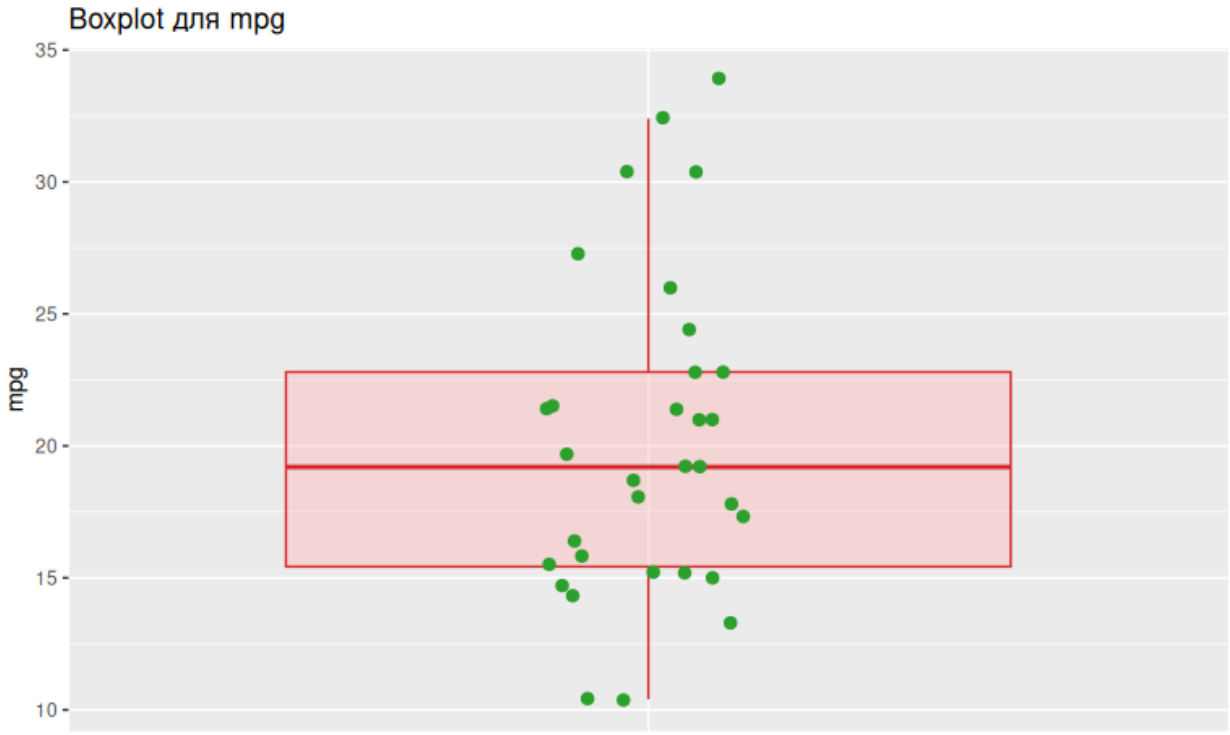


Рисунок 3. Boxplot mpg с отображением всех точек

Границы нормы и список автомобилей-выбросов определяются по правилу 1.5·IQR:

```
Q1 <- quantile(mtcars$mpg, 0.25)
Q3 <- quantile(mtcars$mpg, 0.75)
IQR_val <- Q3 - Q1
lower_bound <- Q1 - 1.5 * IQR_val
upper_bound <- Q3 + 1.5 * IQR_val

cat(sprintf("Q1 = %.2f, Q3 = %.2f, IQR = %.2f\n", Q1, Q3, IQR_val))
## Q1 = 15.43, Q3 = 22.80, IQR = 7.38
cat(sprintf("Границы нормы: [%.2f ; %.2f]\n", lower_bound, upper_bound))
## Границы нормы: [4.36 ; 33.86]
out_rows <- mtcars[mtcars$mpg < lower_bound | mtcars$mpg > upper_bound,
                   c("mpg", "cyl", "hp")]
out_cars <- rownames(out_rows)
cat("Автомобили-выбросы:", paste(out_cars, collapse = ", "), "\n")
## Автомобили-выбросы: Toyota Corolla
knitr::kable(out_rows)
```

	mpg	cyl	hp
Toyota Corolla	33.9	4	65

Вывод. По рисунку 3 и расчёту, границы нормы составляют [4.36; 33.86] миль на галлон. Выброс один — Toyota Corolla (33.9 mpg, 4 цилиндра,

65 л.с.): экономичный компактный автомобиль на фоне мощных машин выборки. Выброс отражает реальное свойство объекта, ошибкой данных не является и из анализа не удаляется.

Группировка по числу цилиндров (dplyr)

Групповые статистики, рассчитанные цепочкой `group_by()` + `summarise()`, приведены в таблице 2.

Таблица 2

Групповые статистики mpg по числу цилиндров.

```
group_stats <- mtcars %>%
  group_by(cyl) %>%
  summarise(n = n(), mean_mpg = mean(mpg), median_mpg = median(mpg),
            sd_mpg = sd(mpg), .groups = "drop")
knitr::kable(group_stats, digits = 2)
```

cyl	n	mean_mpg	median_mpg	sd_mpg
4	11	26.66	26.0	4.51
6	7	19.74	19.7	1.45
8	14	15.10	15.2	2.56

Средние по группам со стандартными отклонениями визуализированы на рисунке 4.

```
ggplot(group_stats, aes(x = factor(cyl), y = mean_mpg, fill = factor(cyl))) +
  geom_col(width = 0.6) +
  geom_errorbar(aes(ymin = mean_mpg - sd_mpg, ymax = mean_mpg + sd_mpg),
                width = 0.15, color = "#333333") +
  scale_fill_manual(values = c("#1f77b4", "#ff7f0e", "#2ca02c")) +
  labs(title = "Средний mpg по группам цилиндров (± SD)",
       x = "Число цилиндров", y = "Средний mpg") +
  theme(legend.position = "none")
```

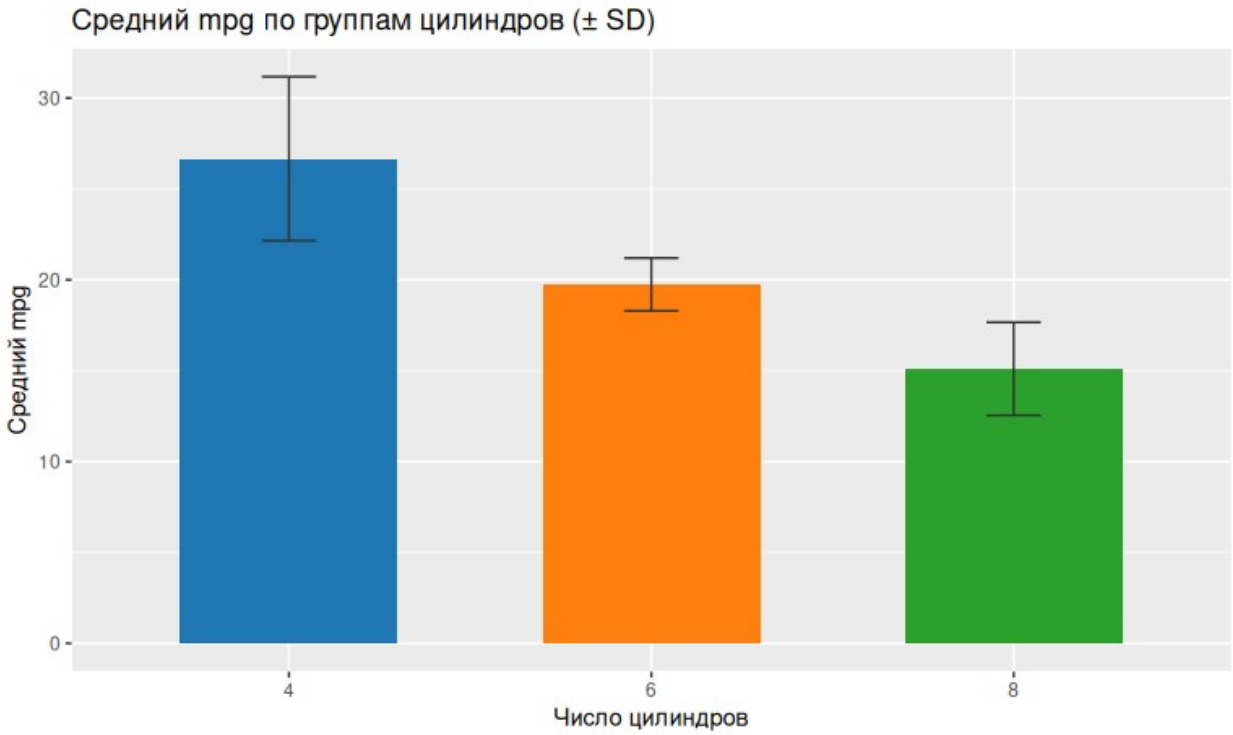


Рисунок 4. Средний mpg по группам цилиндров (± SD)

Вывод. По таблице 2 и рисунку 4 средний расход закономерно падает с ростом числа цилиндров: 26.7 → 19.7 → 15.1 миль на галлон для 4/6/8 цилиндров. Группы невелики (n = 11/7/14), поэтому стандартные отклонения существенны, особенно в группе с 4 цилиндрами.

t-тест: 4 против 6 цилиндров

```
t_res <- t.test(mpg ~ cyl, data = mtcars %>% filter(cyl %in% c(4, 6)))
print(t_res)
##
##  Welch Two Sample t-test
##
## data:  mpg by cyl
## t = 4.7191, df = 12.956, p-value = 0.0004048
## alternative hypothesis: true difference in means between group 4 and group
6 is not equal to 0
## 95 percent confidence interval:
##   3.751376 10.090182
## sample estimates:
## mean in group 4 mean in group 6
##        26.66364        19.74286
```

Гипотезы. H_0 — средний `mpg` автомобилей с 4 и 6 цилиндрами одинаков; H_1 — различается.

Интерпретация. t-статистика = 4.719, p-значение = 0.000405 < 0.05; 95 %-й доверительный интервал разности средних [3.75; 10.09] не содержит нуля.

Вывод. Нулевая гипотеза отвергается: средний `mpg` автомобилей с 4 цилиндрами статистически значимо выше, чем с 6 (разница около 6.9 миль на галлон).

Однофакторный ANOVA и тест Тьюки

```
mtcars$cyl_f <- factor(mtcars$cyl)
anova_res <- aov(mpg ~ cyl_f, data = mtcars)
print(summary(anova_res))
##             Df Sum Sq Mean Sq F value   Pr(>F)
## cyl_f        2  824.8   412.4    39.7 4.98e-09 ***
## Residuals   29  301.3    10.4
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
tukey_res <- TukeyHSD(anova_res)
print(tukey_res)
##   Tukey multiple comparisons of means
##     95% family-wise confidence level
##
## Fit: aov(formula = mpg ~ cyl_f, data = mtcars)
##
## $cyl_f
##           diff        lwr        upr     p adj
## 6-4  -6.920779 -10.769350 -3.0722086 0.0003424
## 8-4 -11.563636 -14.770779 -8.3564942 0.0000000
## 8-6  -4.642857  -8.327583 -0.9581313 0.0112287
```

Попарные различия средних по тесту Тьюки визуализированы на рисунке 5; значимые контрасты (p adj < 0.05) выделены тёмным цветом.

```
tukey_df <- as.data.frame(tukey_res$cyl_f)
tukey_df$comparison <- rownames(tukey_df)
tukey_df$half <- (tukey_df$upr - tukey_df$lwr) / 2
ggplot(tukey_df, aes(x = comparison, y = diff, fill = `p adj` < 0.05)) +
  geom_col(width = 0.6) +
  geom_errorbar(aes(ymin = diff - half, ymax = diff + half),
                width = 0.15, color = "#333333") +
  scale_fill_manual(values = c("#7f7f7f", "#d62728"),
                    labels = c("p >= 0.05", "p < 0.05")) +
  labs(title = "Tukey HSD: попарные различия средних mpg",
       x = "Сравнение групп", y = "Разница средних", fill = "") +
  theme(legend.position = "top")
```

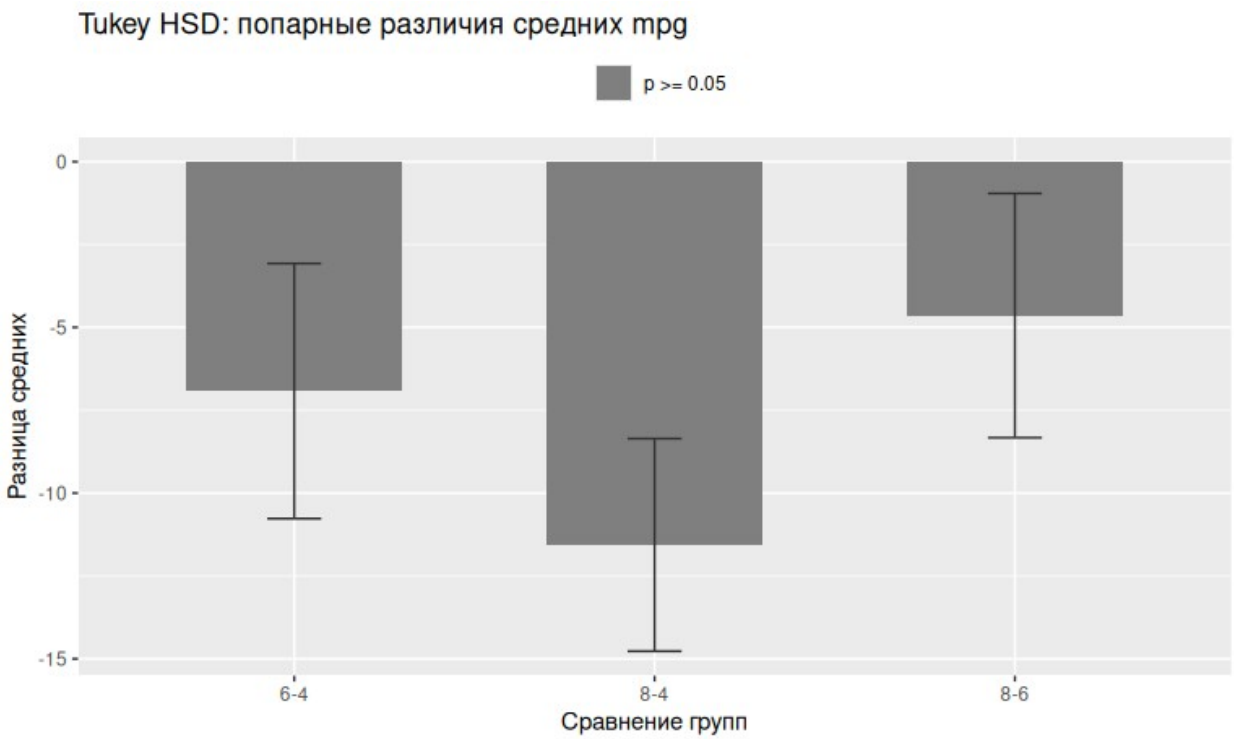


Рисунок 5. Tukey HSD: попарные различия средних mpg

Гипотезы. H_0 — средний `mpg` во всех трёх группах цилиндров одинаков; H_1 — хотя бы в одной группе отличается.

Интерпретация. F-статистика ANOVA = 39.7 при p-значении 4.979e-09 < 0.05. Пост-хок тест Тьюки (рисунок 5) показывает значимость всех трёх попарных контрастов (все p adj < 0.05).

Вывод. Число цилиндров значимо влияет на расход топлива; все попарные различия средних статистически значимы, наибольшая разница — между 8 и 4 цилиндрами (11.6 миль на галлон).

Выводы

В ходе выполнения задачи 2 проведён комплексный статистический анализ датасета mtcars: рассчитаны описательные статистики всех 11 переменных с ручной реализацией выборочной моды (таблица 1); построена плотность распределения `mpg` (рисунок 1); нормальность подтверждена QQ-plot и тестом Шапиро–Уилка (W = 0.9476, p = 0.1229); по методу IQR найден один выброс — Toyota Corolla (рисунок 3); группировка по цилиндрам (таблица 2, рисунок 4) показала монотонное снижение расхода с ростом числа цилиндров; t-тест (p = 0.000405) и ANOVA с тестом Тьюки (рисунок 5) статистически значимо подтвердили различия между всеми группами.