НЕГОСУДАРСТВЕННОЕ ОБРАЗОВАТЕЛЬНОЕ ЧАСТНОЕ УЧРЕЖДЕНИЕ ВЫСШЕГО ОБРАЗОВАНИЯ
**«МОСКОВСКИЙ ФИНАНСОВО-ПРОМЫШЛЕННЫЙ УНИВЕРСИТЕТ «СИНЕРГИЯ»»**

Факультет Информационных технологий

| | | | |
|---|---|---|---|
| **Направление подготовки:** | 09.03.02 Информационные системы и технологии | **Кафедра** | ИИиАД |
| *(код, наименование)* | | *(аббревиатура)* | |

**Профиль:** Разработка, сопровождение и обеспечение безопасности информационных систем

# ОТЧЕТ ПО ЛАБОРАТОРНОЙ РАБОТЕ № 1

**по дисциплине «Продвинутые технологии работы с большими данными»**

**на тему** **Задача 2. Разведочный анализ данных на основе датасета mtcars**

**Обучающийся** ***Шатов Илья Андреевич***

*(Фамилия Имя Отчество)* *(подпись)*

**Группа** ***ВБИо-403-рсоб***

**Преподаватель**

*(Фамилия Имя Отчество)* *(подпись)*

**МОСКВА 2026 г.**

**СОДЕРЖАНИЕ**

**ВВЕДЕНИЕ..... 4**

**1 Описательные статистики и расчёт выборочной моды..... 5**

**2 Анализ распределения и нормальности mpg..... 7**

2.1 Плотность распределения mpg..... 7

2.2 QQ-plot и тест Шапиро–Уилка..... 8

**3 Boxplot и выбросы методом межквартильного размаха..... 9**

**4 Группировка по числу цилиндров..... 11**

**5 Проверка статистических гипотез..... 13**

5.1 t-тест для групп с 4 и 6 цилиндрами..... 13

5.2 Однофакторный дисперсионный анализ и тест Тьюки..... 13

**ВЫВОДЫ..... 15**

# ВВЕДЕНИЕ

**Условие.** Загрузите встроенный датасет `mtcars` и выполните его комплексный статистический анализ средствами `dplyr`, `tidyr`, `broom` и `plotly`: рассчитайте описательные статистики (среднее, медиану, моду, стандартное отклонение, минимум, максимум) для всех переменных, реализовав функцию вычисления выборочной моды; постройте график плотности распределения `mpg`, совместив гистограмму, ядерную оценку плотности и теоретическую кривую нормального распределения; выполните проверку нормальности через QQ-plot и тест Шапиро–Уилка; постройте boxplot с отображением всех точек и выявите выбросы методом межквартильного размаха (IQR); выполните группировку по числу цилиндров средствами `dplyr` с визуализацией групповых статистик; проверьте гипотезу о равенстве средних `mpg` между автомобилями с 4 и 6 цилиндрами (t-тест); выполните однофакторный дисперсионный анализ (ANOVA) по трём группам цилиндров с пост-хок тестом Тьюки (Tukey HSD) и визуализацией попарных различий с выделением значимых контрастов цветом.

# 1 Описательные статистики и расчёт выборочной моды

Функция выборочной моды реализована вручную: среди уникальных значений выбирается то, которое встречается чаще всего.

**Таблица 1 — Описательные статистики переменных mtcars**

```
get_mode <- function(x) {
  ux <- unique(x)
  ux[which.max(tabulate(match(x, ux)))]
}

modes <- sapply(mtcars, get_mode)

extended_stats <- data.frame(
  Variable = names(mtcars),
  Mean     = round(sapply(mtcars, mean), 2),
  Median   = sapply(mtcars, median),
  Mode     = modes,
  SD       = round(sapply(mtcars, sd), 2),
  Min      = sapply(mtcars, min),
  Max      = sapply(mtcars, max),
  row.names = NULL
)
knitr::kable(extended_stats)
```

| Variable | Mean | Median | Mode | SD | Min | Max |
|---|---|---|---|---|---|---|
| mpg | 20.09 | 19.200 | 21.00 | 6.03 | 10.400 | 33.900 |
| cyl | 6.19 | 6.000 | 8.00 | 1.79 | 4.000 | 8.000 |
| disp | 230.72 | 196.300 | 275.80 | 123.94 | 71.100 | 472.000 |
| hp | 146.69 | 123.000 | 110.00 | 68.56 | 52.000 | 335.000 |
| drat | 3.60 | 3.695 | 3.92 | 0.53 | 2.760 | 4.930 |
| wt | 3.22 | 3.325 | 3.44 | 0.98 | 1.513 | 5.424 |
| qsec | 17.85 | 17.710 | 17.02 | 1.79 | 14.500 | 22.900 |
| vs | 0 | 0 | 0 | 0 | 0 | 1 |

| Variable | Mean | Median | Mode | SD | Min | Max |
|---|---|---|---|---|---|---|
| s | .44 | .000 | .00 | .50 | .000 | .000 |
| am | 0<br>.41 | 0<br>.000 | 0<br>.00 | 0<br>.50 | 0<br>.000 | 1<br>.000 |
| gear | 3<br>.69 | 4<br>.000 | 3<br>.00 | 0<br>.74 | 3<br>.000 | 5<br>.000 |
| carb | 2<br>.81 | 2<br>.000 | 4<br>.00 | 1<br>.62 | 1<br>.000 | 8<br>.000 |

**Вывод.** По данным таблицы 1, средний расход — 20.09 миль на галлон при медиане 19.2 и стандартном отклонении 6.03. Медиана меньше среднего, что указывает на правую асимметрию распределения `mpg`; мода расхода — 21 mpg, мода числа цилиндров — 8, мода числа карбюраторов — 4.

# 2 Анализ распределения и нормальности mpg

## 2.1 Плотность распределения mpg

Гистограмма, ядерная оценка плотности и теоретическая нормальная кривая совмещены на рисунке 1 (интерактивная версия построена средствами `plotly` и сохранена в `output/task2_density_mpg.html`).

```
dfn <- data.frame(x = seq(min(mtcars$mpg), max(mtcars$mpg), length.out =
200))
dfn$y <- dnorm(dfn$x, mean = mean(mtcars$mpg), sd = sd(mtcars$mpg))
ggplot(mtcars, aes(x = mpg)) +
  geom_histogram(aes(y = after_stat(density)), bins = 10,
                 fill = scales::alpha("#6496DC", 0.55), color = "white") +
  geom_density(color = "#d62728", linewidth = 1) +
  geom_line(data = dfn, aes(x, y), color = "green",
            linetype = "dashed", linewidth = 0.9) +
  labs(title = "Плотность распределения mpg",
       x = "mpg (миль на галлон)", y = "Плотность вероятности")
```

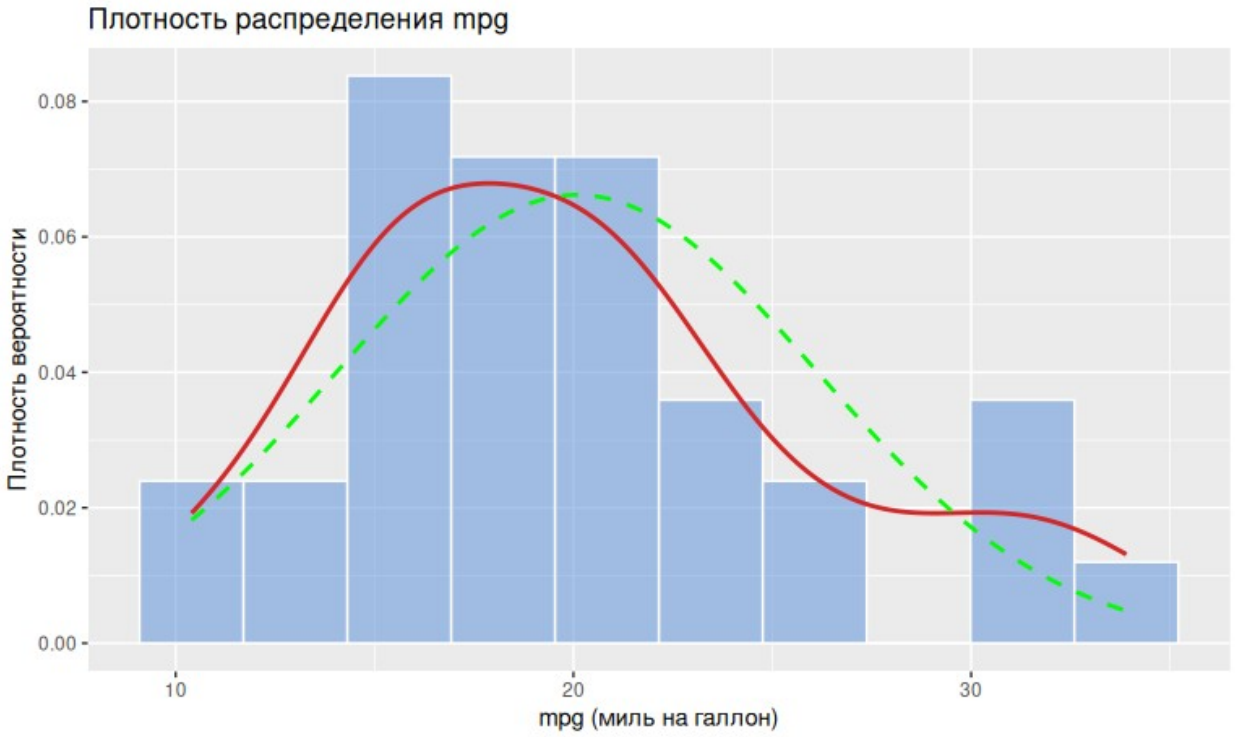



**Рисунок 1 — Плотность распределения mpg: гистограмма, ядерная оценка и нормальная кривая**

**Вывод.** Ядерная оценка плотности (рисунок 1) повторяет форму гистограммы; нормальная кривая с теми же средним и дисперсией проходит близко, но не идеальна — распределение слегка многовершинное, что типично для смеси групп с разным числом цилиндров.

### 2.2 QQ-plot и тест Шапиро–Уилка

QQ-plot для `mpg` представлен на рисунке 2.

```
qq_data <- as.data.frame(qqnorm(mtcars$mpg, plot.it = FALSE))
qq_data$line <- fitted(lm(y ~ x, data = qq_data))
ggplot(qq_data, aes(x, y)) +
  geom_point(color = "#1f77b4", size = 2.5) +
  geom_line(aes(y = line), color = "red") +
  labs(title = "QQ-plot для mpg",
       x = "Теоретические квантили (нормальное)",
       y = "Выборочные квантили (mpg)")
```

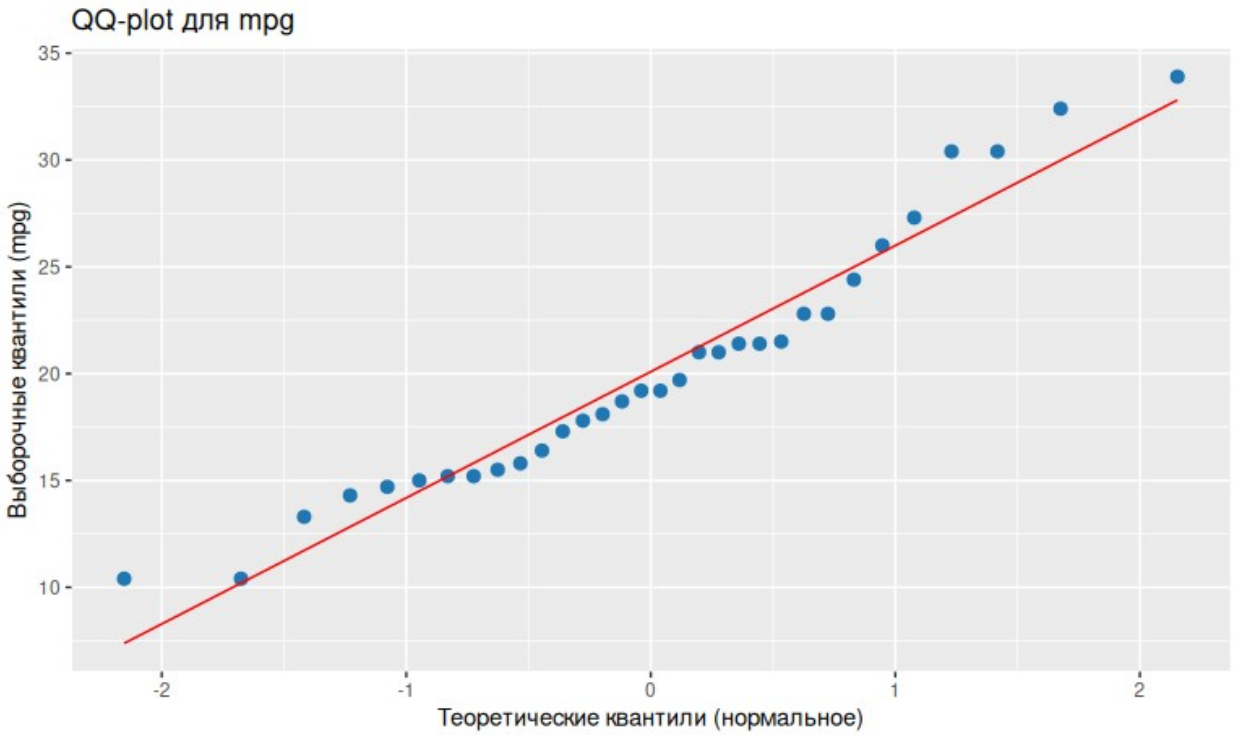



**Рисунок 2 — QQ-plot для mpg**

```
shapiro_res <- shapiro.test(mtcars$mpg)
print(shapiro_res)
##
##  Shapiro-Wilk normality test
##
## data:  mtcars$mpg
## W = 0.94756, p-value = 0.1229
```

**Гипотезы.** $H_0$ — распределение `mpg` нормально; $H_1$ — не нормально.

**Интерпретация.** Статистика Шапиро–Уилка W = 0.9476, p-значение = 0.1229 > 0.05 — данных против $H_0$ недостаточно; точки QQ-plot (рисунок 2) лежат близко к опорной прямой.

**Вывод.** На уровне значимости 0.05 гипотеза о нормальности `mpg` не отвергается — параметрические методы (t-тест, ANOVA) применимы.

## 3 Boxplot и выбросы методом межквартильного размаха

Ящик с усами с отображением всех наблюдений приведён на рисунке 3.

```
ggplot(mtcars, aes(x = "", y = mpg)) +
  geom_boxplot(fill = scales::alpha("#FFB4B4", 0.4), color = "#d62728",
               outlier.shape = NA) +
  geom_jitter(width = 0.12, size = 2.3, color = "#2ca02c") +
  labs(title = "Boxplot для mpg", x = NULL, y = "mpg") +
  theme(axis.text.x = element_blank(), axis.ticks.x = element_blank())
```

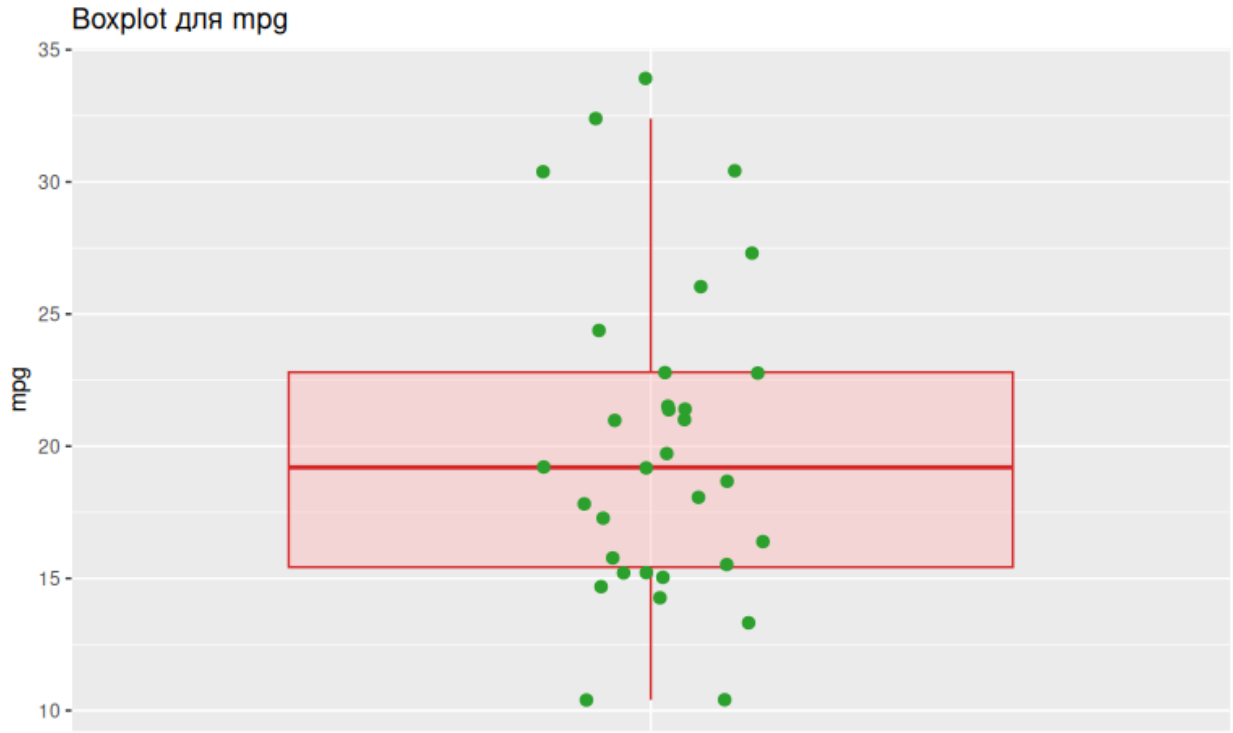



**Рисунок 3 — Boxplot mpg с отображением всех точек**

Границы нормы и список автомобилей-выбросов определяются по правилу 1.5·IQR:

```
Q1 <- quantile(mtcars$mpg, 0.25)
Q3 <- quantile(mtcars$mpg, 0.75)
IQR_val <- Q3 - Q1
lower_bound <- Q1 - 1.5 * IQR_val
upper_bound <- Q3 + 1.5 * IQR_val

cat(sprintf("Q1 = %.2f, Q3 = %.2f, IQR = %.2f\n", Q1, Q3, IQR_val))
## Q1 = 15.43, Q3 = 22.80, IQR = 7.38
cat(sprintf("Границы нормы: [%.2f ; %.2f]\n", lower_bound, upper_bound))
## Границы нормы: [4.36 ; 33.86]
out_rows <- mtcars[mtcars$mpg < lower_bound | mtcars$mpg > upper_bound,
                   c("mpg", "cyl", "hp")]
out_cars <- rownames(out_rows)
cat("Автомобили-выбросы:", paste(out_cars, collapse = ", "), "\n")
## Автомобили-выбросы: Toyota Corolla
knitr::kable(out_rows)
```

| | mpg | cyl | hp |
|---|---|---|---|
| Toyota | 33.9 | 4 | 65 |

| | mpg | cyl | hp |
|---|---|---|---|
| Corolla | | | |

**Вывод.** По рисунку 3 и расчёту, границы нормы составляют [4.36; 33.86] миль на галлон. Выброс один — Toyota Corolla (33.9 mpg, 4 цилиндра, 65 л.с.): экономичный компактный автомобиль на фоне мощных машин выборки. Выброс отражает реальное свойство объекта, ошибкой данных не является и из анализа не удаляется.

## 4 Группировка по числу цилиндров

Групповые статистики, рассчитанные цепочкой `group_by()` + `summarise()`, приведены в таблице 2.

**Таблица 2 — Групповые статистики mpg по числу цилиндров**

```
group_stats <- mtcars %>%
  group_by(cyl) %>%
  summarise(n = n(), mean_mpg = mean(mpg), median_mpg = median(mpg),
            sd_mpg = sd(mpg), .groups = "drop")
knitr::kable(group_stats, digits = 2)
```

| cyl | n | mean_mpg | median_mpg | sd_mpg |
|---|---|---|---|---|
| 4 | 11 | 26.66 | 26.0 | 4.51 |
| 6 | 7 | 19.74 | 19.7 | 1.45 |
| 8 | 14 | 15.10 | 15.2 | 2.56 |

Средние по группам со стандартными отклонениями визуализированы на рисунке 4.

```
ggplot(group_stats, aes(x = factor(cyl), y = mean_mpg, fill = factor(cyl))) +
  geom_col(width = 0.6) +
  geom_errorbar(aes(ymin = mean_mpg - sd_mpg, ymax = mean_mpg + sd_mpg),
                width = 0.15, color = "#333333") +
  scale_fill_manual(values = c("#1f77b4", "#ff7f0e", "#2ca02c")) +
  labs(title = "Средний mpg по группам цилиндров (± SD)",
       x = "Число цилиндров", y = "Средний mpg") +
  theme(legend.position = "none")
```

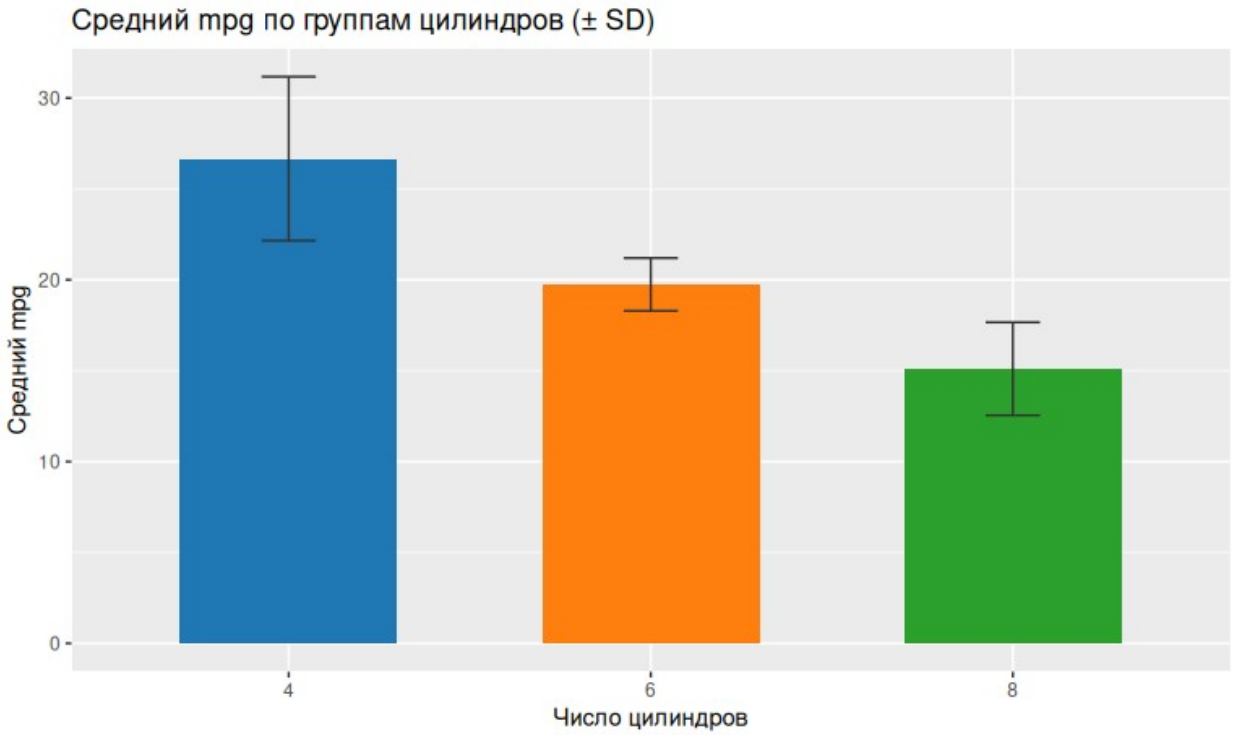



**Рисунок 4 — Средний mpg по группам цилиндров (± SD)**

**Вывод.** По таблице 2 и рисунку 4 средний расход закономерно падает с ростом числа цилиндров: 26.7 → 19.7 → 15.1 миль на галлон для 4/6/8 цилиндров. Группы невелики (n = 11/7/14), поэтому стандартные отклонения существенны, особенно в группе с 4 цилиндрами.

# 5 Проверка статистических гипотез

## 5.1 t-тест для групп с 4 и 6 цилиндрами

```
t_res <- t.test(mpg ~ cyl, data = mtcars %>% filter(cyl %in% c(4, 6)))
print(t_res)
##
##  Welch Two Sample t-test
##
## data:  mpg by cyl
## t = 4.7191, df = 12.956, p-value = 0.0004048
## alternative hypothesis: true difference in means between group 4 and group
6 is not equal to 0
## 95 percent confidence interval:
##   3.751376 10.090182
## sample estimates:
## mean in group 4 mean in group 6
##        26.66364        19.74286
```

**Гипотезы.** $H_0$ — средний `mpg` автомобилей с 4 и 6 цилиндрами одинаков; $H_1$ — различается.

**Интерпретация.** t-статистика = 4.719, p-значение = 0.000405 < 0.05; 95 %-й доверительный интервал разности средних [3.75; 10.09] не содержит нуля.

**Вывод.** Нулевая гипотеза отвергается: средний `mpg` автомобилей с 4 цилиндрами статистически значимо выше, чем с 6 (разница около 6.9 миль на галлон).

## 5.2 Однофакторный дисперсионный анализ и тест Тьюки

```
mtcars$cyl_f <- factor(mtcars$cyl)
anova_res <- aov(mpg ~ cyl_f, data = mtcars)
print(summary(anova_res))
##             Df Sum Sq Mean Sq F value   Pr(>F)
## cyl_f        2  824.8   412.4    39.7 4.98e-09 ***
## Residuals   29  301.3    10.4
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
tukey_res <- TukeyHSD(anova_res)
print(tukey_res)
##   Tukey multiple comparisons of means
##     95% family-wise confidence level
##
## Fit: aov(formula = mpg ~ cyl_f, data = mtcars)
##
## $cyl_f
##           diff        lwr        upr     p adj
## 6-4  -6.920779 -10.769350 -3.0722086 0.0003424
## 8-4 -11.563636 -14.770779 -8.3564942 0.0000000
## 8-6  -4.642857  -8.327583 -0.9581313 0.0112287
```

Попарные различия средних по тесту Тьюки визуализированы на рисунке 5; значимые контрасты (p adj < 0.05) выделены тёмным цветом.

```r
tukey_df <- as.data.frame(tukey_res$cyl_f)
tukey_df$comparison <- rownames(tukey_df)
tukey_df$half <- (tukey_df$upr - tukey_df$lwr) / 2
ggplot(tukey_df, aes(x = comparison, y = diff, fill = `p adj` < 0.05)) +
  geom_col(width = 0.6) +
  geom_errorbar(aes(ymin = diff - half, ymax = diff + half),
                width = 0.15, color = "#333333") +
  scale_fill_manual(values = c("#7f7f7f", "#d62728"),
                    labels = c("p >= 0.05", "p < 0.05")) +
  labs(title = "Tukey HSD: попарные различия средних mpg",
       x = "Сравнение групп", y = "Разница средних", fill = "") +
  theme(legend.position = "top")
```

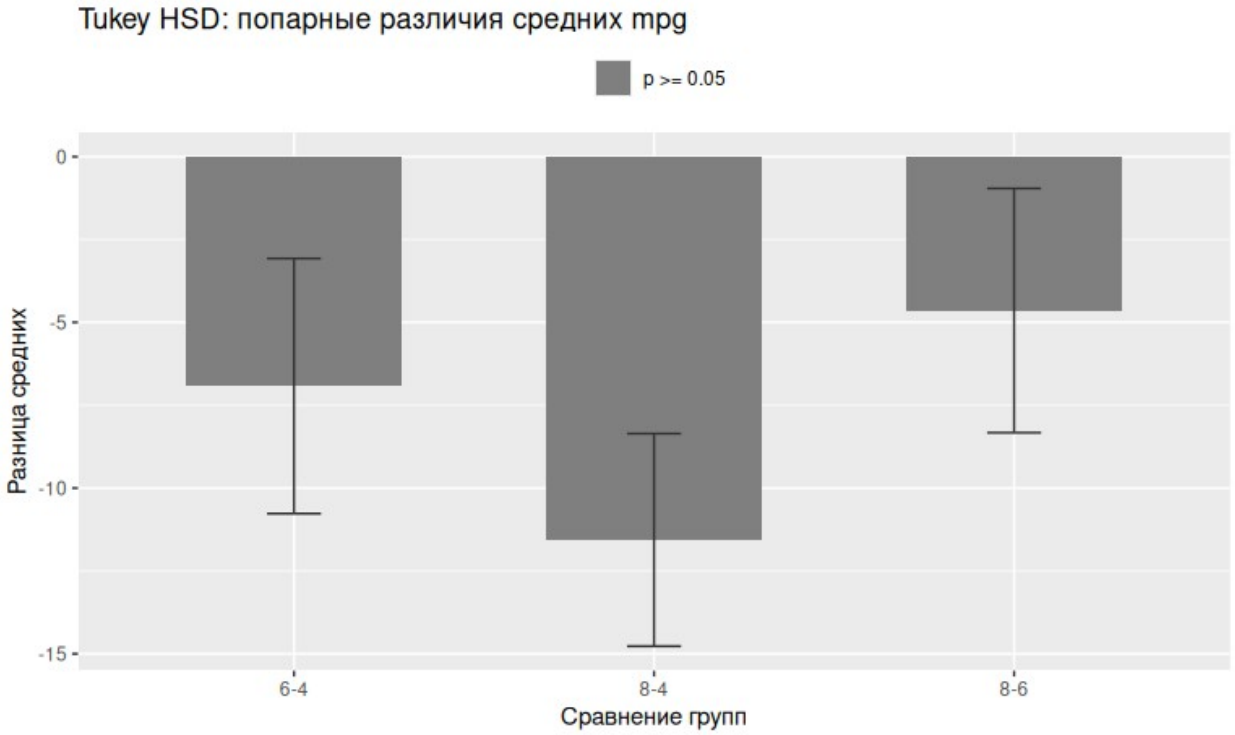



**Рисунок 5 — Tukey HSD: попарные различия средних mpg**

**Гипотезы.** $H_0$ — средний `mpg` во всех трёх группах цилиндров одинаков; $H_1$ — хотя бы в одной группе отличается.

**Интерпретация.** F-статистика ANOVA = 39.7 при p-значении 4.979e-09 < 0.05. Пост-хок тест Тьюки (рисунок 5) показывает значимость всех трёх попарных контрастов (все p adj < 0.05).

**Вывод.** Число цилиндров значимо влияет на расход топлива; все попарные различия средних статистически значимы, наибольшая разница — между 8 и 4 цилиндрами (11.6 миль на галлон).

# ВЫВОДЫ

В ходе выполнения задачи 2 проведён комплексный статистический анализ датасета mtcars: рассчитаны описательные статистики всех 11 переменных с ручной реализацией выборочной моды (таблица 1); построена плотность распределения `mpg` (рисунок 1); нормальность подтверждена QQ-plot и тестом Шапиро–Уилка ($W = 0.9476$, $p = 0.1229$); по методу IQR найден один выброс — Toyota Corolla (рисунок 3); группировка по цилиндрам (таблица 2, рисунок 4) показала монотонное снижение расхода с ростом числа цилиндров; t-тест ($p = 0.000405$) и ANOVA с тестом Тьюки (рисунок 5) статистически значимо подтвердили различия между всеми группами.