НЕГОСУДАРСТВЕННОЕ ОБРАЗОВАТЕЛЬНОЕ ЧАСТНОЕ УЧРЕЖДЕНИЕ ВЫСШЕГО ОБРАЗОВАНИЯ
«МОСКОВСКИЙ ФИНАНСОВО-ПРОМЫШЛЕННЫЙ УНИВЕРСИТЕТ «СИНЕРГИЯ»»

Факультет Информационных технологий

Направление подготовки:	09.03.02 Информационные системы и технологии	**Кафедра**	ИИиАД
(код, наименование)			*(аббревиатура)*

Профиль: Разработка, сопровождение и обеспечение безопасности информационных систем

ОТЧЕТ ПО ЛАБОРАТОРНОЙ РАБОТЕ № 2

по дисциплине «Продвинутые технологии работы с большими данными»

на тему **Задача 1. Кластерный анализ набора данных Wine**

Обучающийся ***Шатов Илья Андреевич***

(Фамилия Имя Отчество) *(подпись)*

Группа ***ВБИо-403-рсоб***

Преподаватель

(Фамилия Имя Отчество) *(подпись)*

МОСКВА 2026 г.

СОДЕРЖАНИЕ

ВВЕДЕНИЕ..... 4

1 Подготовка данных Wine..... 5

2 Выбор числа кластеров..... 7

3 Кластеризация и сравнение алгоритмов..... 9

3.1 K-means, PAM и CLARA..... 9

3.2 Проекция на главные компоненты..... 9

3.3 Графики силуэтов..... 11

3.4 Сравнение с истинными классами..... 14

ВЫВОДЫ..... 17

ВВЕДЕНИЕ

Условие. Провести кластерный анализ набора данных Wine и сравнить эффективность трёх алгоритмов: K-means, PAM и CLARA. Нужно подготовить признаки и истинные классы, стандартизировать данные, выбрать число кластеров методом силуэта и статистикой разрыва, выполнить кластеризацию при k = 3, показать кластеры в пространстве двух главных компонент, построить графики силуэтов и сравнить разбиения с истинными классами по скорректированному индексу Рэнда (ARI).

Цель работы — определить, какой из трёх алгоритмов лучше восстанавливает известные типы вин, и обосновать выбор по графикам и по ARI.

1 Подготовка данных Wine

Набор содержит результаты химического анализа вин трёх типов. Первый столбец — истинный класс (`Type`), остальные 13 столбцов — признаки (спирт, яблочная кислота, зола, щёлочность золы, магний, фенолы, флавоноиды, нефлавоноидные фенолы, проантоцианины, интенсивность цвета, оттенок, оптическая плотность разбавленного вина, пролин). Признаки измерены в разных шкалах, поэтому перед кластеризацией их стандартизируют.

```
pkgs <- c("tidyverse", "cluster", "factoextra", "patchwork", "RColorBrewer",
          "mclust", "caret", "rattle")
new <- pkgs[!pkgs %in% installed.packages()[, "Package"]]
if (length(new) > 0) install.packages(new)

library(tidyverse)
library(cluster)
library(factoextra)
library(patchwork)
library(RColorBrewer)
library(mclust)
library(caret)
library(rattle)
library(dplyr)
items <- tryCatch(
  data(package = "rattle")$results[, "Item"],
  error = function(e) character()
)
if ("wine" %in% items) {
  data("wine", package = "rattle")
} else {
  cache_file <- if (file.exists("../../data/wine.csv")) {
    "../../data/wine.csv"
  } else {
    "data/wine.csv"
  }
  if (!file.exists(cache_file)) {
    stop("В пакете rattle нет набора wine и кэш data/wine.csv не найден")
  }
  wine <- read.csv(cache_file)
  wine$Type <- factor(wine$Type)
}
head(wine)
##   Type Alcohol Malic  Ash Alcalinity Magnesium Phenols Flavanoids
Nonflavanoids
## 1    1   14.23  1.71 2.43       15.6       127    2.80       3.06
0.28
## 2    1   13.20  1.78 2.14       11.2       100    2.65       2.76
0.26
## 3    1   13.16  2.36 2.67       18.6       101    2.80       3.24
0.30
## 4    1   14.37  1.95 2.50       16.8       113    3.85       3.49
0.24
## 5    1   13.24  2.59 2.87       21.0       118    2.80       2.69
0.39
## 6    1   14.20  1.76 2.45       15.2       112    3.27       3.39
```

```
0.34
##   Proanthocyanins Color  Hue Dilution Proline
## 1            2.29  5.64 1.04     3.92    1065
## 2            1.28  4.38 1.05     3.40    1050
## 3            2.81  5.68 1.03     3.17    1185
## 4            2.18  7.80 0.86     3.45    1480
## 5            1.82  4.32 1.04     2.93     735
## 6            1.97  6.75 1.05     2.85    1450
str(wine)
## 'data.frame':    178 obs. of  14 variables:
##  $ Type           : Factor w/ 3 levels "1","2","3": 1 1 1 1 1 1 1 1
1 ...
##  $ Alcohol        : num  14.2 13.2 13.2 14.4 13.2 ...
##  $ Malic          : num  1.71 1.78 2.36 1.95 2.59 1.76 1.87 2.15 1.64 1.35
...
##  $ Ash            : num  2.43 2.14 2.67 2.5 2.87 2.45 2.45 2.61 2.17
2.27 ...
##  $ Alcalinity     : num  15.6 11.2 18.6 16.8 21 15.2 14.6 17.6 14 16 ...
##  $ Magnesium      : int  127 100 101 113 118 112 96 121 97 98 ...
##  $ Phenols        : num  2.8 2.65 2.8 3.85 2.8 3.27 2.5 2.6 2.8 2.98 ...
##  $ Flavanoids     : num  3.06 2.76 3.24 3.49 2.69 3.39 2.52 2.51 2.98 3.15
...
##  $ Nonflavanoids  : num  0.28 0.26 0.3 0.24 0.39 0.34 0.3 0.31 0.29
0.22 ...
##  $ Proanthocyanins: num  2.29 1.28 2.81 2.18 1.82 1.97 1.98 1.25 1.98 1.85
...
##  $ Color          : num  5.64 4.38 5.68 7.8 4.32 6.75 5.25 5.05 5.2
7.22 ...
##  $ Hue            : num  1.04 1.05 1.03 0.86 1.04 1.05 1.02 1.06 1.08 1.01
...
##  $ Dilution       : num  3.92 3.4 3.17 3.45 2.93 2.85 3.58 3.58 2.85
3.55 ...
##  $ Proline        : int  1065 1050 1185 1480 735 1450 1290 1295 1045
1045 ...
df <- wine[, -1]
df_scaled <- scale(df)
true_class <- wine$Type
n_na <- sum(is.na(df))
n_na
## [1] 0
table(true_class)
## true_class
##  1  2  3
## 59 71 48
```

Пропусков в матрице признаков — 0. Всего 178 вин и 13 признаков. Истинных классов — 3, их частоты: 1 — 59; 2 — 71; 3 — 48.

Вывод. Данные полные и пригодны для кластеризации. Класс `Type` отделён от признаков и используется только как внешний критерий (ARI), а не как вход алгоритма. Стандартизация `scale()` выравнивает вклад пролина и магния с вкладом оттенка и фенолов.

2 Выбор числа кластеров

Число кластеров оценивается двумя способами при одном зерне датчика случайных чисел. По условию практикума само разбиение выполняется при k = 3 — по числу известных типов вина.

```
k <- 3
pal <- brewer.pal(8, "Set2")

set.seed(123)
p_sil <- fviz_nbclust(df_scaled, kmeans, method = "silhouette")
gap_stat <- clusGap(df_scaled, FUN = kmeans, nstart = 25,
                    K.max = 8, B = 50)
p_gap <- fviz_gap_stat(gap_stat)

sil_df <- as.data.frame(p_sil$data)
k_sil <- as.integer(as.character(sil_df$clusters[which.max(sil_df$y)]))
k_gap <- as.integer(maxSE(gap_stat$Tab[, "gap"], gap_stat$Tab[, "SE.sim"]))
k_sil
## [1] 3
k_gap
## [1] 3
```

Метод силуэта показан на рисунке 1, статистика разрыва — на рисунке 2.

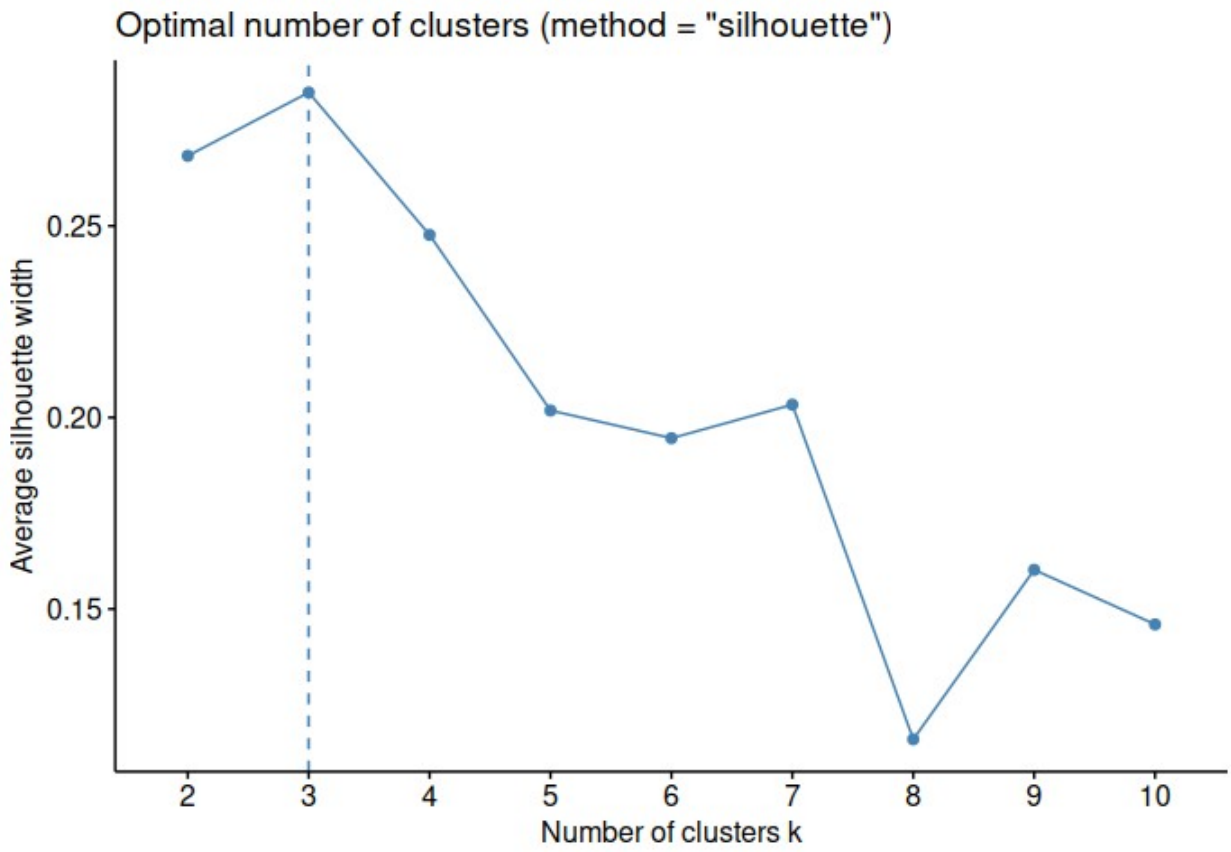


Рисунок 1 — Выбор числа кластеров методом силуэта

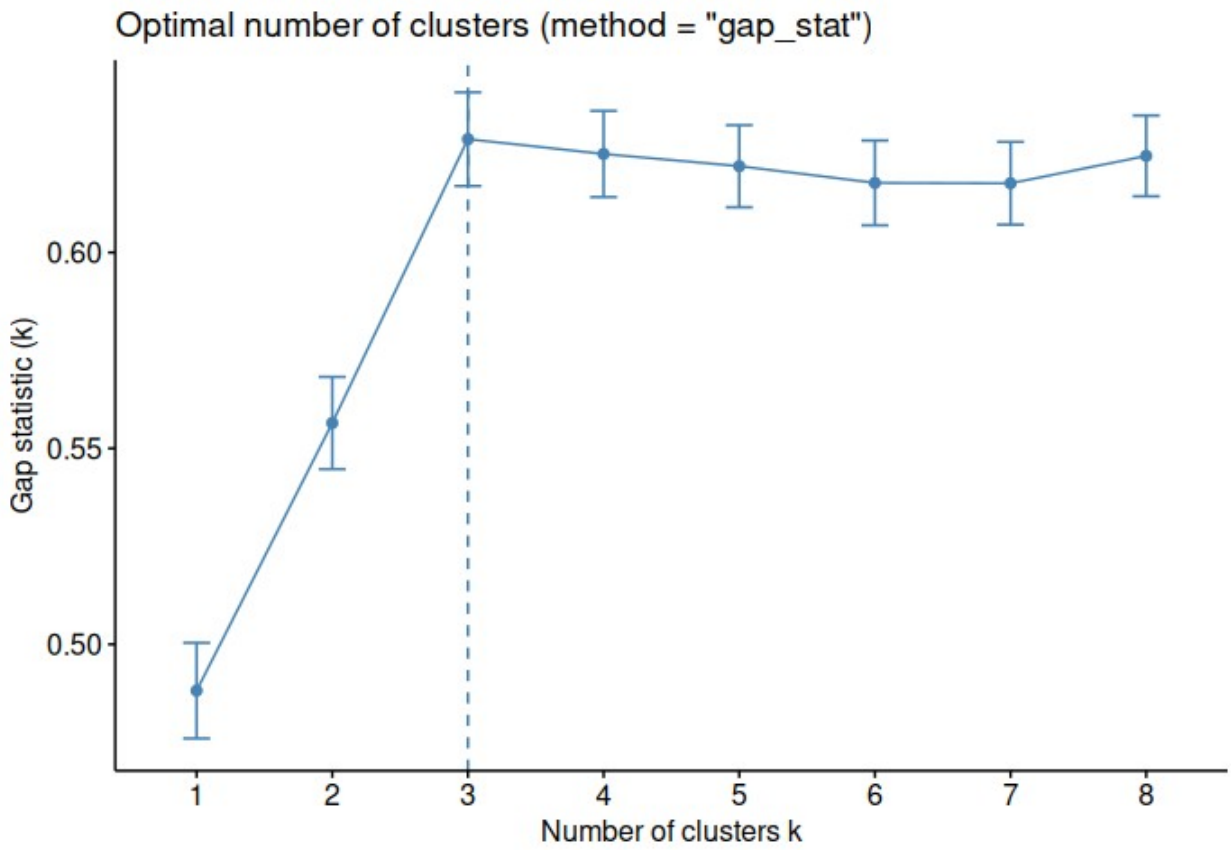


Рисунок 2 — Статистика разрыва (Gap Statistic)

Интерпретация. Максимум среднего силуэта достигается при k = 3. Статистика разрыва (правило firstSEmax, им же пользуется `fviz_gap_stat`) указывает на k = 3. Оба ориентира сопоставляются с известным числом типов вина.

Вывод. Для сравнения с истинными классами далее фиксируется k = 3, как требует задание. Если оценка по силуэту или по gap отличается от 3, это означает, что внутренняя геометрия данных не обязана совпасть с числом сортов, и качество при k = 3 нужно проверять отдельно — по силуэтам разбиения и по ARI.

3 Кластеризация и сравнение алгоритмов

3.1 K-means, PAM и CLARA

K-means ищет сферические кластеры вокруг средних. PAM (partitioning around medoids) опирается на реальные объекты-медоиды и устойчивее к выбросам. CLARA строит PAM на подвыборках и предназначена для больших наборов; здесь она применяется к тем же 178 винам, чтобы сравнить алгоритмы на равных условиях.

```
set.seed(123)
km <- kmeans(df_scaled, centers = k, nstart = 25)
pam_fit <- pam(df_scaled, k = k)
clara_fit <- clara(df_scaled, k = k)

table(Kmeans = km$cluster)
## Kmeans
##  1  2  3
## 51 62 65
table(PAM = pam_fit$clustering)
## PAM
##  1  2  3
## 74 55 49
table(CLARA = clara_fit$clustering)
## CLARA
##  1  2  3
## 69 60 49
```

Размеры кластеров K-means: 51, 62, 65. PAM: 74, 55, 49. CLARA: 69, 60, 49. Частоты истинных классов — 59, 71, 48.

3.2 Проекция на главные компоненты

```
pca <- prcomp(df_scaled)
pca_df <- as.data.frame(pca$x[, 1:2])
pca_imp <- summary(pca)$importance

plot_pca <- function(clusters, title) {
  pca_df$cluster <- factor(clusters)
  ggplot(pca_df, aes(PC1, PC2, color = cluster)) +
    geom_point(size = 2, alpha = 0.8) +
    scale_color_manual(values = pal) +
    theme_minimal() +
    labs(title = title)
}
```

Первые две компоненты объясняют 36.2 % и 19.2 % дисперсии (вместе 55.4 %). Это проекция для просмотра, а не само пространство кластеризации: алгоритмы работали по всем 13 стандартизированным признакам. Расположение кластеров показано на рисунках 3–5.

```
plot_pca(km$cluster, "PCA + K-means")
```

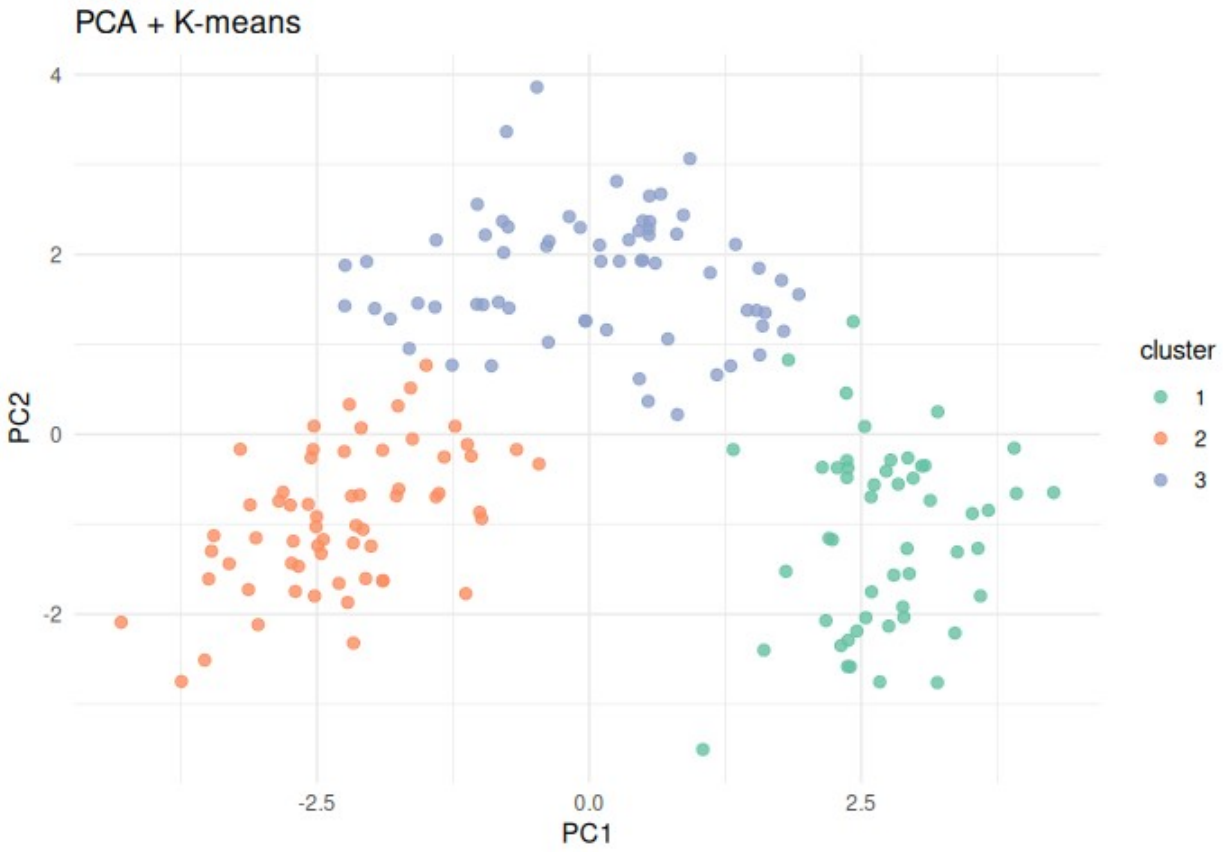


Рисунок 3 — Кластеры K-means в пространстве двух главных компонент

```
plot_pca(pam_fit$clustering, "PCA + PAM")
```

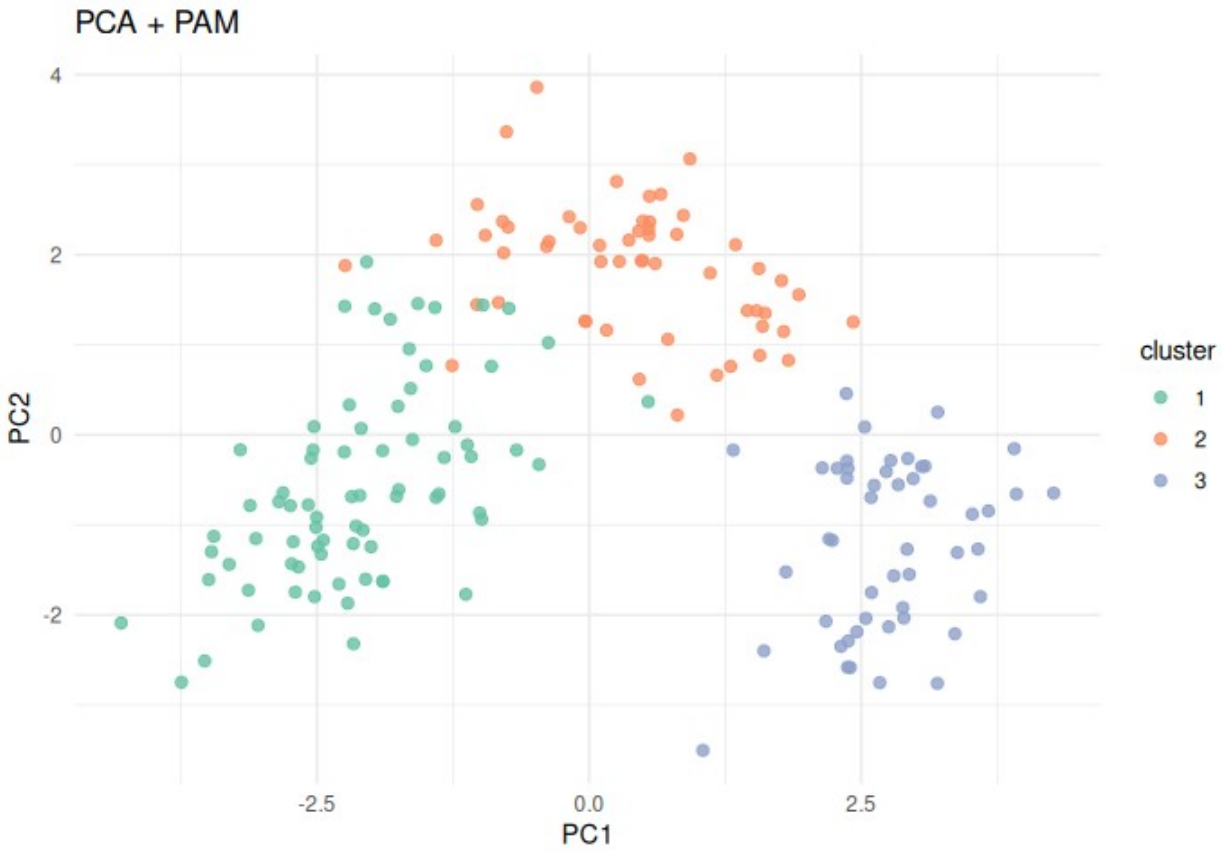


Рисунок 4 — Кластеры PAM в пространстве двух главных компонент

```r
plot_pca(clara_fit$clustering, "PCA + CLARA")
```

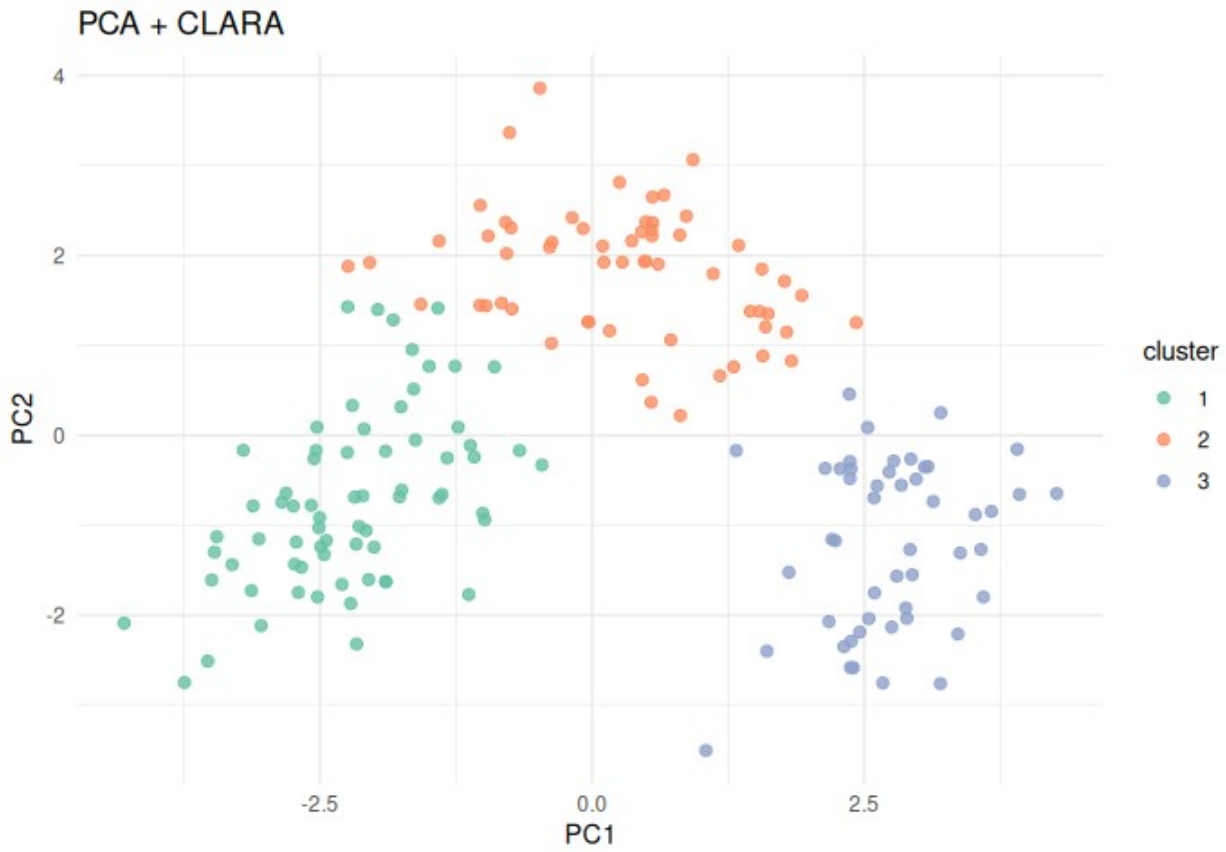


Рисунок 5 — Кластеры CLARA в пространстве двух главных компонент

Вывод. На рисунках 3–5 три группы вин разделяются вдоль PC1, но границы не пустые: часть объектов лежит между облаками. Картины K-means, PAM и CLARA близки, значит различия алгоритмов на этих данных невелики и их нужно подтверждать числами, а не только проекцией.

3.3 Графики силуэтов

Средняя ширина силуэта показывает, насколько объект ближе к своему кластеру, чем к соседнему. Графики — на рисунках 6–8.

```r
sil_width <- function(clusters) {
  mean(silhouette(clusters, dist(df_scaled))[, "sil_width"])
}
sil_km <- sil_width(km$cluster)
sil_pam <- sil_width(pam_fit$clustering)
sil_clara <- sil_width(clara_fit$clustering)
c(Kmeans = sil_km, PAM = sil_pam, CLARA = sil_clara)
##    Kmeans       PAM     CLARA
## 0.2848589 0.2676221 0.2777125
fviz_silhouette(silhouette(km$cluster, dist(df_scaled))) +
  ggtitle("Silhouette: K-means")
##   cluster size ave.sil.width
## 1       1   51          0.35
## 2       2   62          0.34
## 3       3   65          0.18
```

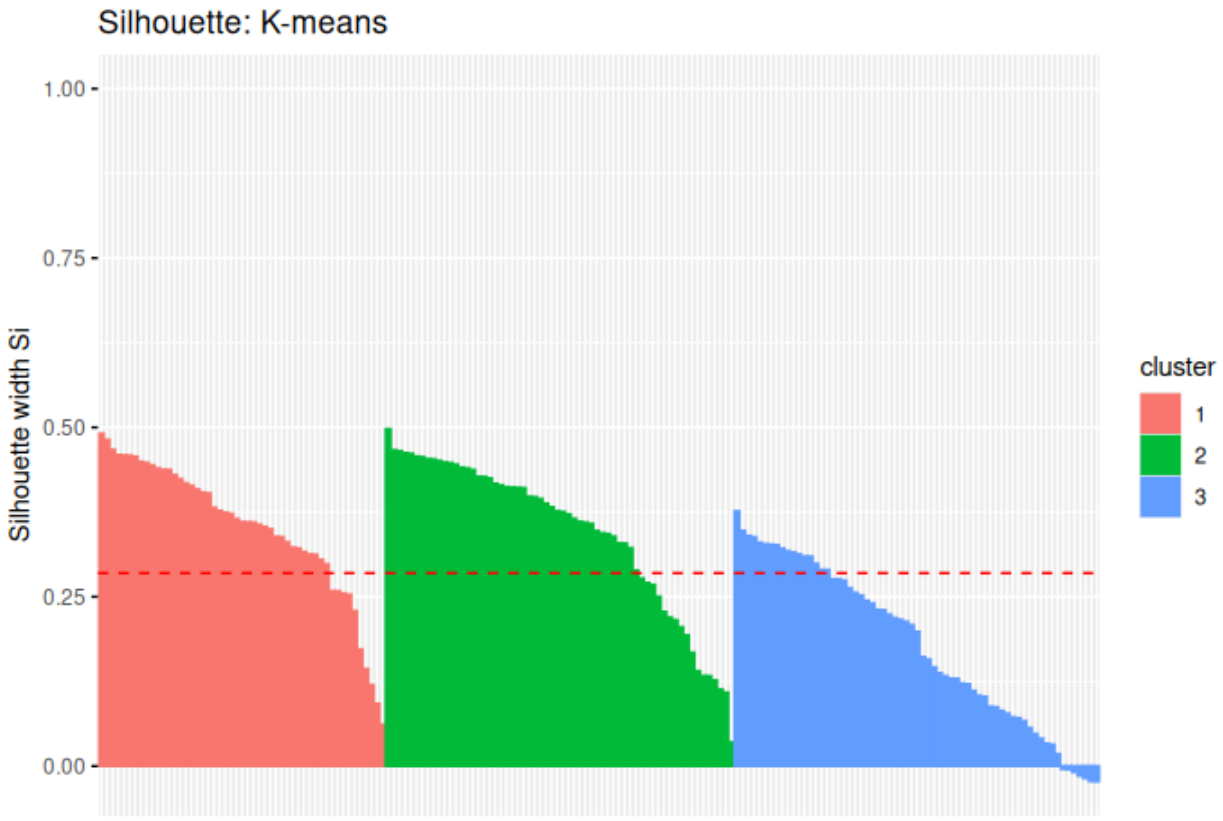


Рисунок 6 — Силуэты кластеров K-means

```
fviz_silhouette(silhouette(pam_fit$clustering, dist(df_scaled))) +
  ggtitle("Silhouette: PAM")
##   cluster size ave.sil.width
## 1       1   74          0.25
## 2       2   55          0.22
## 3       3   49          0.34
```

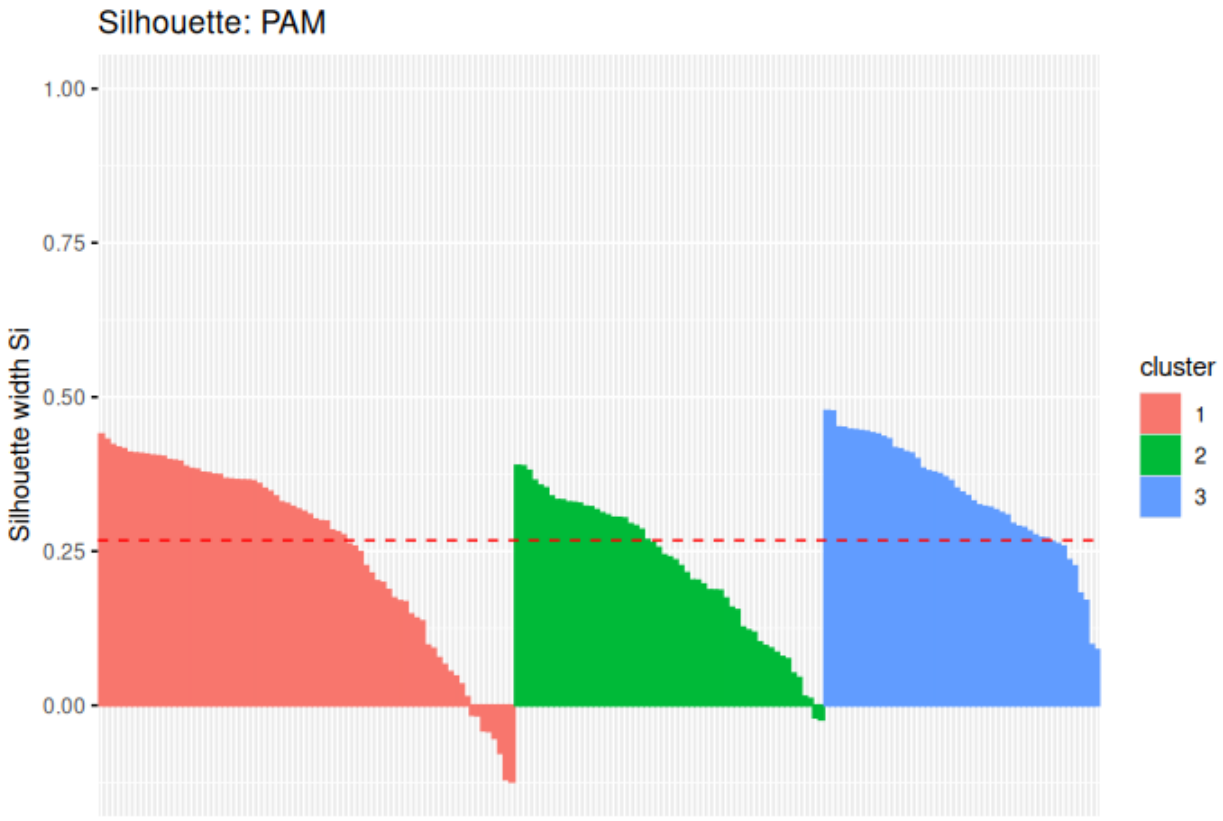


Рисунок 7 — Силуэты кластеров PAM

```
fviz_silhouette(silhouette(clara_fit$clustering, dist(df_scaled))) +
  ggtitle("Silhouette: CLARA")
##   cluster size ave.sil.width
## 1       1   69          0.29
## 2       2   60          0.21
## 3       3   49          0.35
```

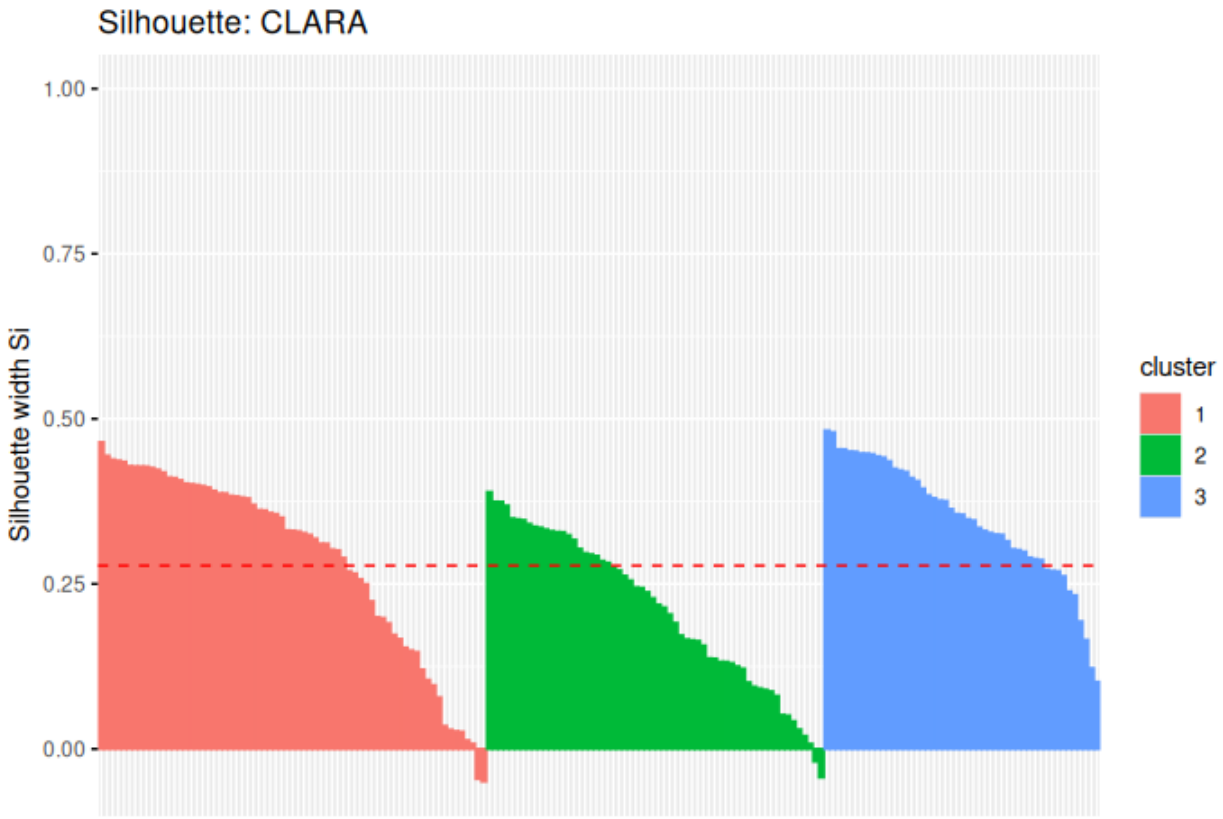


Рисунок 8 — Силуэты кластеров CLARA

Интерпретация. Средний силуэт K-means равен 0.285, PAM — 0.268, CLARA — 0.278. Положительное среднее означает, что типичный объект отнесён к более близкому кластеру; отдельные отрицательные полосы на рисунках 6–8 — объекты на границе групп.

Вывод. Внутреннее качество трёх разбиений сопоставимо. Средний силуэт равен 0.285 у K-means, 0.268 у PAM и 0.278 у CLARA; лидер — K-means. После стандартизации группы ближе к сферическим и сопоставимы по размеру (K-means: 51, 62, 65; PAM: 74, 55, 49; CLARA: 69, 60, 49), поэтому отрыв лидера по силуэту небольшой. Отрицательные полосы на рисунках 6–8 остаются у вин на границе сортов.

3.4 Сравнение с истинными классами

ARI равен 1 при полном совпадении разбиений с точностью до перестановки меток и близок к 0, если совпадение не лучше случайного.

Таблица 1 — Качество кластеризации: ARI и средний силуэт

```
ari_km <- adjustedRandIndex(km$cluster, true_class)
ari_pam <- adjustedRandIndex(pam_fit$clustering, true_class)
ari_clara <- adjustedRandIndex(clara_fit$clustering, true_class)

ari_tbl <- data.frame(
  Алгоритм = c("K-means", "PAM", "CLARA"),
  ARI = c(ari_km, ari_pam, ari_clara),
  `Средний силуэт` = c(sil_km, sil_pam, sil_clara),
  check.names = FALSE
)
knitr::kable(ari_tbl, digits = 3)
```

Алгоритм	ARI	Средний силуэт
K-means	0.897	0.285
PAM	0.741	0.268
CLARA	0.814	0.278

```
cat("K-means и истинные классы:\n")
## K-means и истинные классы:
print(table(Истинный = true_class, Кластер = km$cluster))
##          Кластер
## Истинный  1  2  3
##        1  0 59  0
##        2  3  3 65
##        3 48  0  0
cat("PAM и истинные классы:\n")
## PAM и истинные классы:
print(table(Истинный = true_class, Кластер = pam_fit$clustering))
##          Кластер
## Истинный  1  2  3
##        1 59  0  0
##        2 15 55  1
##        3  0  0 48
cat("CLARA и истинные классы:\n")
## CLARA и истинные классы:
print(table(Истинный = true_class, Кластер = clara_fit$clustering))
##          Кластер
## Истинный  1  2  3
##        1 59  0  0
##        2 10 60  1
##        3  0  0 48
ari_vec <- c(`K-means` = ari_km, PAM = ari_pam, CLARA = ari_clara)
sil_vec <- c(`K-means` = sil_km, PAM = sil_pam, CLARA = sil_clara)
best_ari_name <- names(which.max(ari_vec))
best_sil_name <- names(which.max(sil_vec))
best_ari <- max(ari_vec)
best_sil <- max(sil_vec)

hits_of <- function(clusters, truth) {
  as.integer(sum(apply(table(truth, clusters), 1, max)))
}
hits_km <- hits_of(km$cluster, true_class)
hits_pam <- hits_of(pam_fit$clustering, true_class)
hits_clara <- hits_of(clara_fit$clustering, true_class)
km_sizes_txt <- paste(as.integer(table(km$cluster)), collapse = ", ")
pam_sizes_txt <- paste(as.integer(table(pam_fit$clustering)), collapse = ",
")
```

```
clara_sizes_txt <- paste(as.integer(table(clara_fit$clustering)), collapse =
", ")
true_sizes_txt <- paste(as.integer(table(true_class)), collapse = ", ")
```

Интерпретация. По таблице 1 наибольший ARI у K-means (0.897), наибольший средний силуэт у K-means (0.285). Оба критерия выделяют один и тот же алгоритм — K-means. Таблицы сопряжённости показывают, что каждый истинный класс в основном попадает в свой кластер, а ошибки сосредоточены на границе двух соседних типов.

Вывод. Для этой задачи внешний критерий важнее: типы вин известны, и цель — восстановить их. Лучший метод — K-means (ARI = 0.897). По таблице 1 ARI равен 0.897 у K-means, 0.741 у PAM и 0.814 у CLARA; средние силуэты — 0.285, 0.268 и 0.278. По максимуму строки таблицы сопряжённости K-means совпадает с сортом у 172 из 178 вин, PAM — у 162, CLARA — у 167. После стандартизации кластеры ближе к сферическим и сопоставимы по размеру: K-means даёт группы 51, 62, 65 при истинных частотах 59, 71, 48, а PAM (74, 55, 49) и CLARA (69, 60, 49) сильнее укрупняют один кластер. В такой геометрии среднее K-means согласуется с сортами лучше медоидов. PAM устойчивее к выбросам, но здесь это не улучшило согласие с типами вина: разница ARI (K-means минус PAM) равна 0.156. CLARA повторяет PAM на подвыборках и рассчитана на большие наборы; при n = 178 подвыборка не даёт выигрыша над K-means (ARI CLARA минус PAM — 0.073, K-means минус CLARA — 0.083).

ВЫВОДЫ

На 178 образцах вина (13 стандартизированных признаков, пропусков — 0) сравнены K-means, PAM и CLARA при k = 3. Метод силуэта дал оптимальное k = 3, статистика разрыва — k = 3. В проекции PCA (рисунки 3–5) первые две компоненты удерживают 55.4 % дисперсии и показывают три пересекающихся облака.

По таблице 1 и рисункам 3–8 лучший алгоритм — K-means. ARI составляет 0.897 (K-means), 0.741 (PAM) и 0.814 (CLARA); средние силуэты — 0.285, 0.268 и 0.278. Оба критерия выделяют один и тот же метод — K-means. Совпадение с сортом по таблице сопряжённости: 172, 162 и 167 вин из 178. После `scale()` признаки соизмеримы, кластеры близки к сферическим и по размеру умеренно ровные (51, 62, 65 у K-means против 74, 55, 49 у PAM и 69, 60, 49 у CLARA; истинные частоты — 59, 71, 48), поэтому центроидный алгоритм совпадает с тремя сортами лучше. PAM устойчивее к выбросам, но на Wine это не дало большего согласия с классами (разница ARI, K-means минус PAM — 0.156). CLARA предназначена для больших выборок: при n = 178 разница ARI (CLARA минус PAM) равна 0.073, а (K-means минус CLARA) — 0.083. Ни один алгоритм не достигает ARI = 1: химические профили соседних типов перекрываются, что видно и по отрицательным силуэтам отдельных вин на рисунках 6–8.