НЕГОСУДАРСТВЕННОЕ ОБРАЗОВАТЕЛЬНОЕ ЧАСТНОЕ УЧРЕЖДЕНИЕ ВЫСШЕГО ОБРАЗОВАНИЯ «МОСКОВСКИЙ ФИНАНСОВО-ПРОМЫШЛЕННЫЙ УНИВЕРСИТЕТ «СИНЕРГИЯ»

Факультет/Институт Институт Информационных технологий
(наименование факультета/ Института)

Направление/специальность подготовки: 38.04.01 Экономика
(код и наименование направления /специальности подготовки)

Форма обучения: очная
(очная, очно-заочная, заочная)

ОТЧЕТ ПО ЛАБОРАТОРНОЙ РАБОТЕ № 3

на тему «Методы очистки и предобработки данных»
(наименование темы)

по дисциплине Продвинутые технологии работы с большими данными
(наименование дисциплины)

Обучающийся Шатов Илья Андреевич _____
(ФИО) (подпись)

Группа ДМЭ-101цэии

Преподаватель Дзизинская Диана Викторовна _____
(ФИО) (подпись)

Москва 2026 г.

СОДЕРЖАНИЕ

ВВЕДЕНИЕ **3**

1 Предварительная обработка данных о квартирах и метро **4**

1.1 Исходные данные и первичная очистка 4

1.2 Полигоны районов и привязка объектов 5

1.3 Мультиколлинеарность факторов 5

2 Диагностика пространственной зависимости **7**

2.1 Матрицы пространственных весов 7

2.2 Глобальный и локальный индексы Морана 7

3 Эконометрические модели цен на жильё **10**

3.1 OLS-регрессия и отбор факторов 10

3.2 Диагностика остатков: тест Морана и LM-тесты 10

3.3 SAR- и SEM-модели, сравнение по AIC и BIC 11

3.4 Прямые и косвенные эффекты SAR 14

ВЫВОДЫ **17**

ВВЕДЕНИЕ

Условие. На основе данных о ценах на жильё и социально-экономических характеристиках районов Москвы построить и сравнить различные пространственные эконометрические модели. Необходимо оценить классическую регрессию OLS с факторами, влияющими на цены жилья, провести диагностику пространственной зависимости в остатках модели с помощью теста Морана, выполнить LM-тесты (Lagrange Multiplier) для обоснования выбора между моделью пространственного лага (SAR) и моделью пространственной ошибки (SEM), оценить выбранную пространственную модель с использованием функций `lagsarlm()` и `errorsarlm()` из пакета `spatialreg`, сравнить качество пространственной модели с OLS-спецификацией по информационным критериям AIC и BIC, дать содержательную интерпретацию коэффициентов и сформулировать выводы о значимости различных факторов в формировании цен на жильё с учётом пространственных эффектов. Перед моделированием проводится предварительная обработка данных о квартирах и данных о метро.

Цель работы — очистить и предобработать исходные данные о 25 877 объявлениях о продаже квартир и 1 160 выходах станций метро, агрегировать показатели на уровень районов Москвы и определить, какая эконометрическая спецификация (OLS, SAR или SEM) корректнее описывает формирование цен на жильё с учётом пространственных эффектов.

Работа выполнена на языке R в среде RStudio (Docker-образ `big-data-labs-rstudio`, R 4.6.1) с использованием пакетов `sf`, `spdep`, `spatialreg`, `geosphere`.

1 Предварительная обработка данных о квартирах и метро

1.1 Исходные данные и первичная очистка

Исходные файлы содержат объявления о продаже жилья в Москве (DATA.xlsx) и справочник выходов метро (METRO.xlsx). Каждое объявление описывается подкатегорией (студии, квартиры), типом рынка, ценой, типом дома, этажностью, площадью, этажом, санузлом, ремонтом, географическими координатами и адресом.

Очистка выполнена в следующей последовательности: приведение типов, извлечение числовых значений из текстовых полей, удаление строк с пропусками в ключевых полях и удаление экстремальных выбросов по перцентилям.

```
df_realty$Цена <- as.numeric(gsub("[^0-9]", "", df_realty$Цена))
df_realty$Общая.площадь <- as.numeric(gsub(" м²", "",
df_realty$Общая.площадь))
df_realty$Этаж_номер <- as.numeric(str_extract(df_realty$Этаж, "^\\d+"))
df_realty$Этажей.в.доме <- as.numeric(str_extract(df_realty$Этажей.в.доме,
"^\\d+"))

df_realty_clean <- df_realty %>%
  mutate(
    доля_этажа = Этаж_номер / Этажей.в.доме,
    первый_этаж = as.integer(Этаж_номер == 1),
    последний_этаж = as.integer(Этаж_номер == Этажей.в.доме),
    log_price = log(Цена),
    price_per_sqm = Цена / Общая.площадь,
    log_price_sqm = log(price_per_sqm)
  ) %>%
  filter(!is.na(Цена), !is.na(Общая.площадь),
         !is.na(Широта), !is.na(Долгота),
         Общая.площадь > 0, Цена > 0)

# удаление выбросов по 1%- и 99%-перцентилям
q_price <- quantile(df_realty_clean$Цена, c(0.01, 0.99))
q_area  <- quantile(df_realty_clean$Общая.площадь, c(0.01, 0.99))
q_ppsqm <- quantile(df_realty_clean$price_per_sqm, c(0.01, 0.99))
df_realty_clean <- df_realty_clean %>%
  filter(Цена >= q_price[1], Цена <= q_price[2],
         Общая.площадь >= q_area[1], Общая.площадь <= q_area[2],
         price_per_sqm >= q_ppsqm[1], price_per_sqm <= q_ppsqm[2])
```

После базовой очистки (числовые поля, пропуски в цене, площади и координатах) осталось 25 844 объявлений; после расширенной очистки и удаления выбросов — 24 713 объявлений. Данные о метро содержат 1 160 выходов с координатами без пропусков. Медианная цена предложения после очистки составляет 20 139 240 руб., медианная площадь — 53.6 м².

1.2 Полигоны районов и привязка объектов

Границы районов взяты из GeoJSON-выгрузки OpenStreetMap (`export.geojson`). Из 262 объектов отобраны только полигоны и мультиполигоны с уровнем `admin_level = 8` (районы и муниципальные округа): получено 132 уникальных районов. Названия нормализованы (нижний регистр, удаление слов «район», «поселение», знаков препинания), по полигонам рассчитаны центроиды.

Каждая квартира привязана к району пространственным соединением `st_join(..., join = st_within)`; точки вне полигонов (граничные случаи) привязаны к ближайшему центроиду района:

```
df_sf <- df_realty_clean %>%
  st_as_sf(coords = c("Долгота", "Широта"), crs = 4326)
df_joined <- st_join(df_sf, rayons_clean, join = st_within)
```

Для каждого дома рассчитано расстояние по формуле гаверсинусов до ближайшего выхода метро (`geosphere::distHaversine`), после чего все показатели агрегированы по районам: средние логарифмы цены и цены за квадратный метр, средняя площадь и этажность застройки, среднее расстояние до метро, а также доли квартир с различными характеристиками (студии, вторичный рынок, кирпичные и панельные дома, евроремонт и дизайнерский ремонт, совмещённый санузел, первые и последние этажи, повышенная и высотная застройка). В анализ включены районы не менее чем с 10 объявлениями: 128 районов.

```
find_nearest_metro_idx <- function(lon, lat, metro_coords) {
  d <- geosphere::distHaversine(c(lon, lat), metro_coords)
  which.min(d)
}
```

Медианное расстояние до ближайшего выхода метро по всей выборке — 0.78 км, максимальное — 27.04 км: транспортная доступность варьирует между районами почти на порядок, что делает её кандидатом в предикторы цены.

1.3 Мультиколлинеарность факторов

Перед оцениванием регрессии рассчитаны факторные инфляционные дисперсии (VIF) для исходного набора из 17 предикторов (таблица 1).

Таблица 1 — Наибольшие значения VIF исходного набора предикторов

Предиктор	VIF
share_skyscraper	10.92
share_panel	7.92
mean_floors	5.53
share_brick	5.32
share_first_floor	5.30
share_studio	4.51
share_secondary	4.34
share_high_rise	3.61

Максимум — 10.92 у предиктора «share_skyscraper»: он превышает порог 10 и исключается из набора, остальные 16 предикторов входят в регрессию без риска мультиколлинеарности [2, с. 76–85].

2 Диагностика пространственной зависимости

2.1 Матрицы пространственных весов

Построены две матрицы весов, кодирующие соседство районов [4, с. 61–74]: k-ближайших соседей (k = 8) по центроидам и матрица «ферзь» (Queen) по фактическому касанию полигонов. Обе стандартизованы по строкам (style = “W”).

```
W_knn       <- knn2nb(knearneigh(coords, k = 8))
W_knn_listw <- nb2listw(W_knn, style = "W", zero.policy = TRUE)
W_queen     <- poly2nb(rayon_sf_wgs, queen = TRUE)
W_queen_listw <- nb2listw(W_queen, style = "W", zero.policy = TRUE)
```

Среднее число соседей в матрице k-NN — 8.0, в матрице Queen — 5.3; изолированных районов нет, обе матрицы пригодны для тестирования.

2.2 Глобальный и локальный индексы Морана

Глобальный индекс Морана рассчитан для логарифма средней цены по районам при обеих матрицах весов.

```
moran_knn   <- moran.test(rayon_sf_wgs$log_price, W_knn_listw,
                          zero.policy = TRUE)
moran_queen <- moran.test(rayon_sf_wgs$log_price, W_queen_listw,
                          zero.policy = TRUE)
```

Гипотезы. H_0 — пространственная автокорреляция отсутствует ($I = 0$); H_1 — автокорреляция положительная ($I > 0$).

По матрице k-NN индекс Морана $I = 0.505$ ($p < 0{,}001$), по матрице Queen — $I = 0.559$ ($p < 0{,}001$). Оба теста отвергают H_0 на уровне значимости 0,05: дорогие районы граничат с дорогими, дешёвые — с дешёвыми, то есть цены на жильё в Москве пространственно автокоррелированы. Дальнейшая диагностика опирается на матрицу Queen, поскольку она отражает фактическое соседство полигонов районов.

Локальный индекс Морана (LISA) выделяет статистически значимые кластеры ($p < 0{,}1$): значимы 32.3% районов. Распределение кластеров: High-High — 26, Low-Low — 14, High-Low — 2, Low-High — 0, незначимые — 88.

Распределение средних цен по районам показано на рисунке 1, карта LISA-кластеров — на рисунке 2.

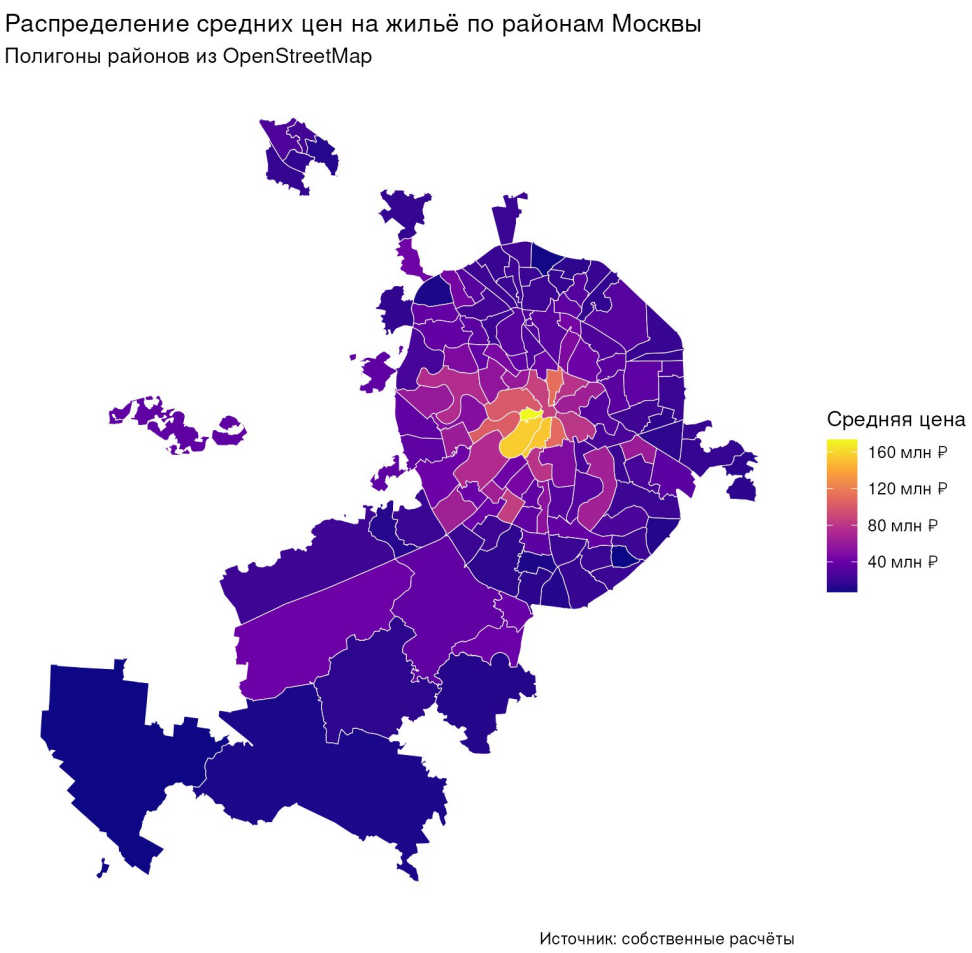


Рисунок 1 — Средняя цена предложения жилья по районам Москвы

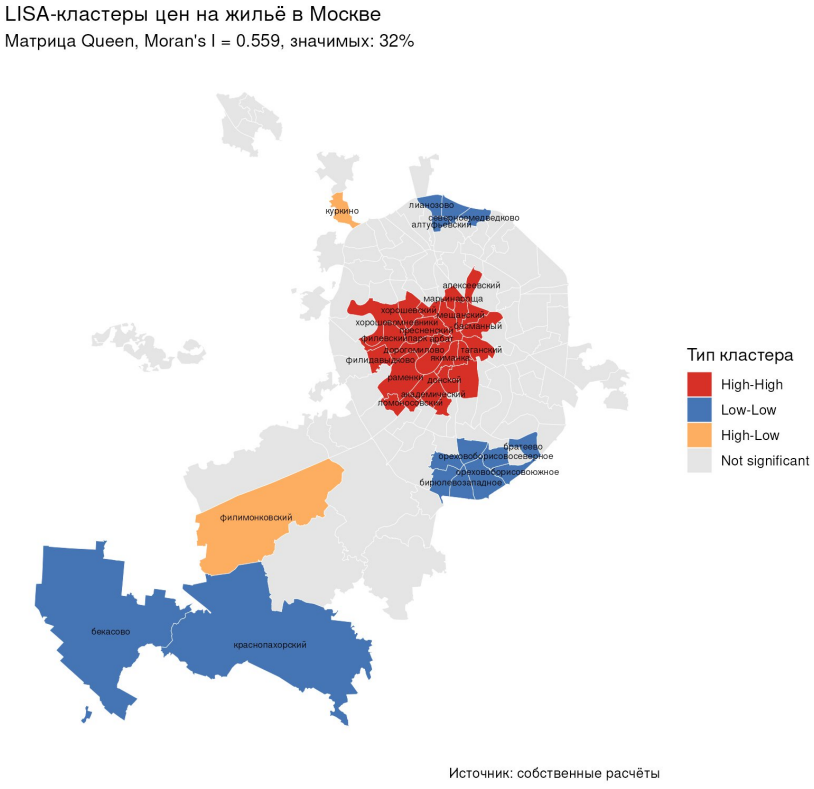


Рисунок 2 — LISA-кластеры логарифма средней цены (матрица Queen)

Кластер High-High (ядро дорогого жилья) сосредоточен в центре города, кластер Low-Low — на периферии. Полученная карта подтверждает вывод глобального теста и служит наглядным обоснованием перехода от OLS к пространственным моделям.

3 Эконометрические модели цен на жильё

3.1 OLS-регрессия и отбор факторов

Зависимая переменная — средний по району логарифм цены; объясняющие — среднее расстояние до метро, средняя площадь, средняя этажность застройки, доли квартир с разными характеристиками и объём выборки. Оценена полная OLS-модель, затем выполнен пошаговый отбор переменных методом `step(direction = "both")` по критерию AIC [2, с. 70–144].

```
ols_full <- lm(ols_formula_full, data = rayon_reg_wgs)
ols_step <- step(ols_full, direction = "both", trace = FALSE)
```

После отбора в модели осталось 4 объясняющих переменных (mean_area, share_studio, share_secondary, share_brick) и свободный член. Коэффициент детерминации $R^2 = 0.688$, скорректированный $R^2 = 0.678$: всего три-четыре агрегированные характеристики района объясняют 69% вариации логарифма средней цены (125 районов с полными данными). Наибольший вклад даёт доля вторичного жилья: рост доли на 10 процентных пунктов снижает логарифм средней цены района примерно на 0.27 (то есть среднюю цену — примерно на 23%): новостройки систематически дороже. Положительный коэффициент при доле студий отражает центральную локализацию малогабаритного жилья, а отрицательный при средней площади — сдвиг структуры предложения в дорогих районах в сторону компактных квартир.

3.2 Диагностика остатков: тест Морана и LM-тесты

Остатки OLS-модели проверены на пространственную автокорреляцию тестом Морана (`lm.morantest`) при матрице Queen.

Гипотезы. H_0 — автокорреляция в остатках отсутствует; H_1 — автокорреляция в остатках присутствует.

```
moran_ols_full <- lm.morantest(ols_step, W_queen_reg_listw,
                               zero.policy = TRUE)
lm_tests_full  <- lm.RStests(ols_step, listw = W_queen_reg_listw,
                             test = "all", zero.policy = TRUE)
```

Статистика Морана для остатков I = -0.061 (p 0.788) — H_0 не отвергается: после учёта социально-экономических характеристик районов пространственная автокорреляция в остатках не обнаружена. Наблюдаемая выше автокорреляция цен (I = 0.559) объясняется пространственной кластеризацией самих факторов — распределением вторичного жилья, студий и транспортной доступности, а не неучтённым пространственным взаимодействием. Тем не менее вывод проверяется формальными LM-тестами [4, с. 87–114] (таблица 2).

Таблица 2 — LM-тесты пространственной зависимости для OLS-модели

Тест	Статистика	p-значение
LM-лаг (LMlag)	1.108	0.292
LM-ошибка (LMerr)	0.235	0.628
RLM-лаг (устойчивый)	3.270	0.071
RLM-ошибка (устойчивый)	2.397	0.122

Интерпретация. Обычный LM-тест на пространственный лаг (LMlag) даёт статистику 1.108 (p 0.292), LM-тест на пространственную ошибку (LMerr) — 0.235 (p 0.628): оба незначимы на уровне 0,05. Устойчивые (robust) версии уточняют диагноз: RLMlag — 3.270 (p 0.071), RLMerr — 2.397 (p 0.122). По процедуре Анселина—Бера при обоих незначимых обычных тестах на уровне 0,05 остаётся классическая OLS-спецификация; лишь на уровне 0,10 устойчивый RLMlag даёт слабый сигнал в пользу SAR, который ниже проверяется формально оценкой обеих пространственных моделей.

Вывод. Формальная диагностика не требует пространственной спецификации: автокорреляция цен целиком объяснена ковариатами. По требованию задания обе пространственные модели (SAR и SEM) всё же оцениваются, а финальный выбор делается по информационным критериям AIC и BIC.

3.3 SAR- и SEM-модели, сравнение по AIC и BIC

Модель пространственного лага SAR включает в правую часть лаг зависимой переменной W·y, модель пространственной ошибки SEM —

авторегрессию в ошибке. Обе оценены методом максимального правдоподобия (`method = "eigen"`) при матрице Queen.

```
sar_full <- lagsarlm(final_formula, data = rayon_reg_wgs,
                     listw = W_queen_reg_listw,
                     method = "eigen", zero.policy = TRUE)
sem_full <- errorsarlm(final_formula, data = rayon_reg_wgs,
                       listw = W_queen_reg_listw,
                       method = "eigen", zero.policy = TRUE)
```

Параметр пространственной автокорреляции SAR ρ = 0.044 (p 0.624) статистически не отличается от нуля; параметр SEM λ = -0.173 (p 0.250) также незначим. Сравнение моделей по информационным критериям приведено в таблице 3 и на рисунке 3.

Таблица 3 — Сравнение качества моделей OLS, SAR и SEM

Модель	Логарифм правдоподобия	AIC	BIC
OLS	-84.25	180.51	197.48
SAR	-84.13	182.27	202.07
SEM	-83.59	181.19	200.99

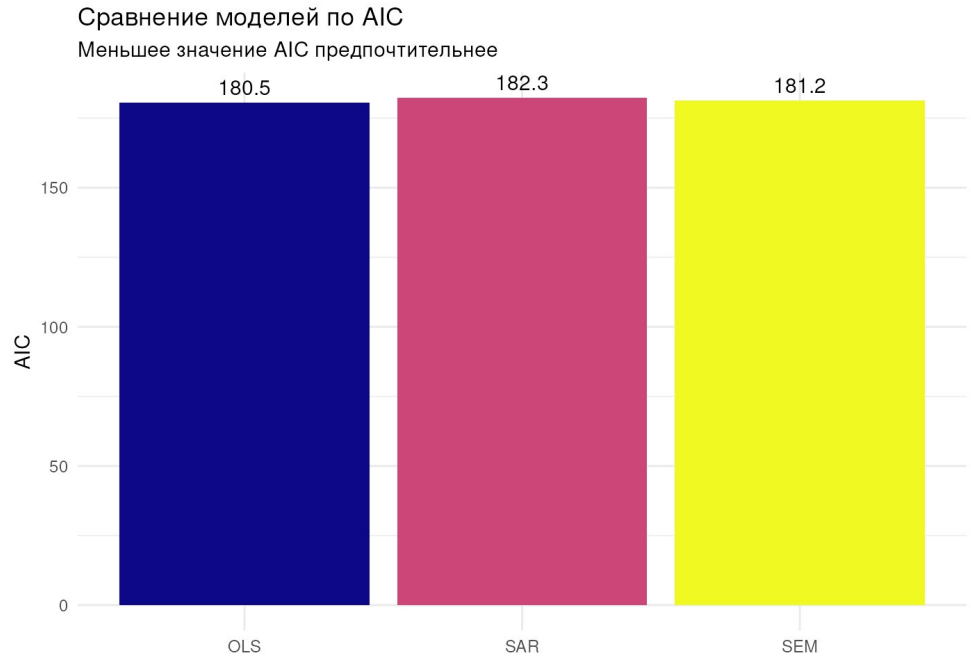


Рисунок 3 — Сравнение моделей по AIC (лучшая — OLS)

Вывод. Минимальные AIC и BIC у модели OLS (AIC = 180.510, BIC = 197.480). Пространственные спецификации проигрывают классической OLS-регрессии: прирост логарифма правдоподобия (0.120–0.660) меньше штрафа за дополнительный параметр. Добавление пространственного лага или пространственной ошибки не улучшает модель: зависимость цен объяснена

наблюдаемыми факторами районов. Карты остатков (рисунки 4–6) подтверждают вывод теста Морана: у OLS-модели нет систематической «пятнистости» ошибок, картина остатков практически не меняется при переходе к SAR и SEM.

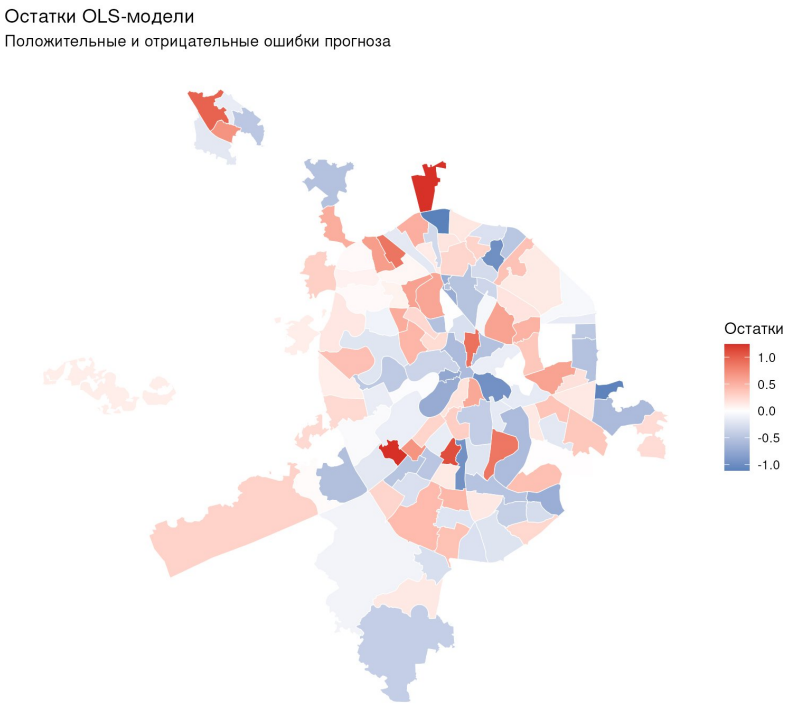


Рисунок 4 — Остатки OLS-модели по районам Москвы

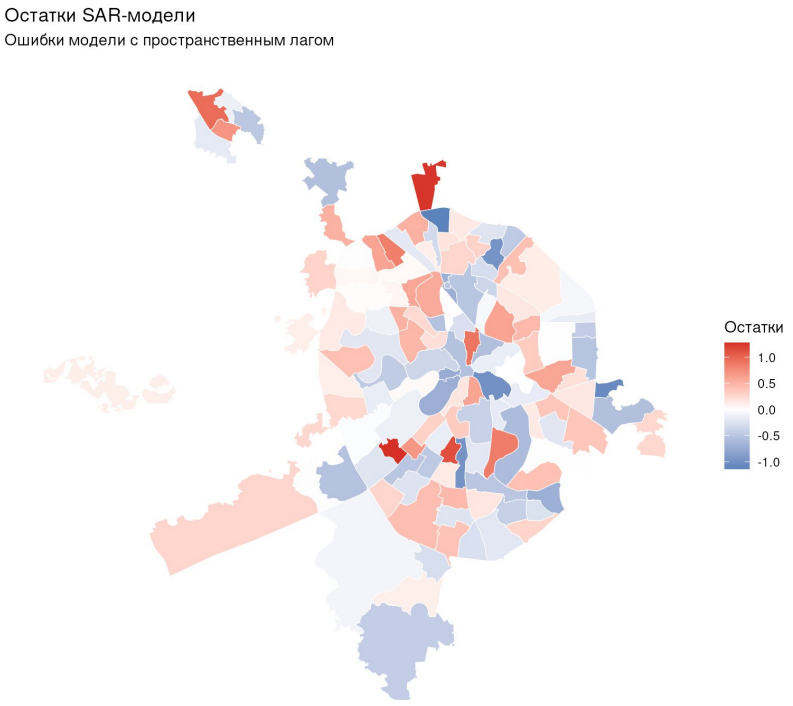


Рисунок 5 — Остатки SAR-модели по районам Москвы

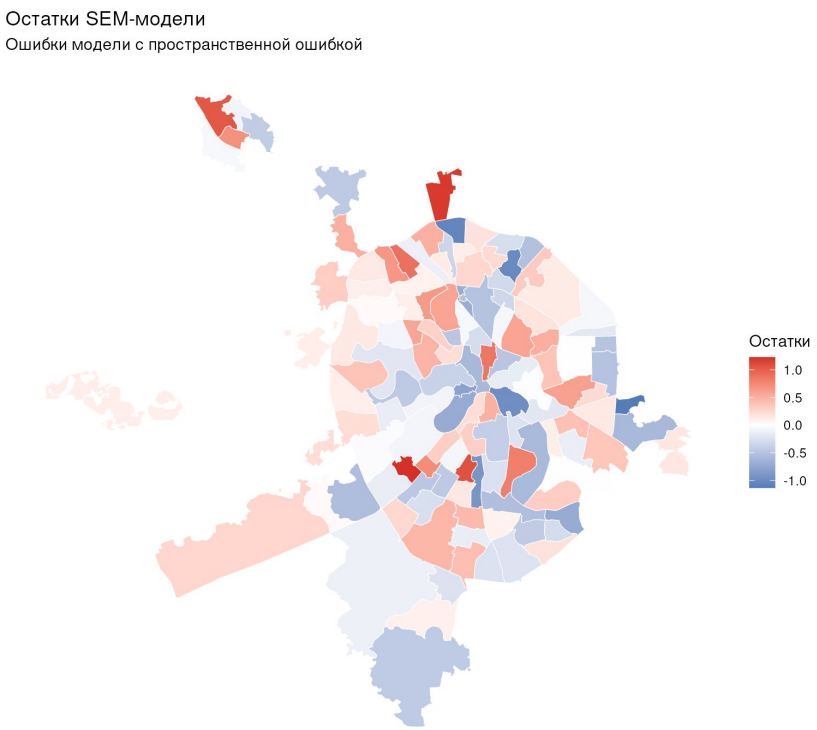


Рисунок 6 — Остатки SEM-модели по районам Москвы

3.4 Прямые и косвенные эффекты SAR

В SAR-модели коэффициенты не совпадают с предельными эффектами из-за одновременности: изменение фактора в одном районе влияет на цены в нём (прямой эффект) и через лаг W·y — на цены соседних районов (косвенный эффект). Эффекты разложены функцией `impacts()` с симуляциями Монте-Карло (R = 1000) [4, с. 87–114]; результаты для значимых факторов — в таблице 4, полное разложение — на рисунке 7.

Таблица 4 — Прямые, косвенные и общие эффекты SAR-модели

Переменная	Прямой	Косвенный	Общий
mean_area	-0.008	-0.000	-0.009
share_studio	1.481	0.080	1.561
share_secondary	-2.653	-0.142	-2.795
share_brick	0.485	0.028	0.513

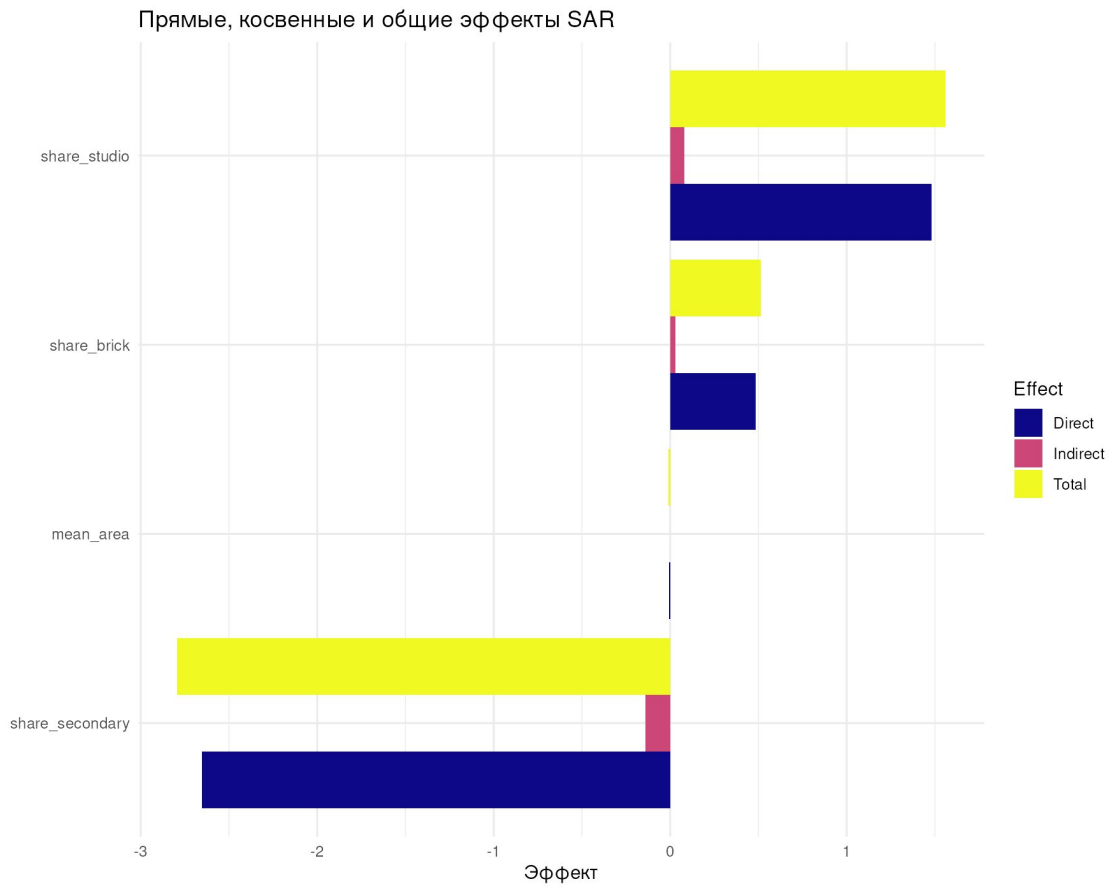


Рисунок 7 — Разложение эффектов SAR-модели по факторам

Наибольший по модулю общий эффект имеет фактор «share_secondary» (общий эффект -2.795): рост доли вторичного жилья на 10 процентных пунктов снижает логарифм средней цены района в сумме на 0.28 с учётом отклика соседних районов. Косвенные эффекты составляют лишь 5.1% общих — межрайонные переливы практически отсутствуют, что прямо согласуется с незначимостью ρ: пространственное взаимодействие между районами после учёта их характеристик не обнаруживается, и оценки OLS не искажены пропущенным пространственным лагом.

Сводные коэффициенты трёх моделей с уровнями значимости приведены в таблице 5.

Таблица 5 — Сводная таблица коэффициентов моделей OLS, SAR и SEM

Модель	Переменная	Оценка	p-значение
OLS	(Intercept)	16.894	< 0,001 ***
OLS	mean_area	-0.009	0.013 *
OLS	share_studio	1.485	< 0,001 ***
OLS	share_secondary	-2.671	< 0,001 ***

Модель	Переменная	Оценка	p-значение
OLS	share_brick	0.480	0.129
SAR	(Intercept)	16.195	< 0,001 ***
SAR	mean_area	-0.008	0.012 *
SAR	share_studio	1.492	< 0,001 ***
SAR	share_secondary	-2.647	< 0,001 ***
SAR	share_brick	0.489	0.113
SEM	(Intercept)	16.959	< 0,001 ***
SEM	mean_area	-0.009	0.004 **
SEM	share_studio	1.418	< 0,001 ***
SEM	share_secondary	-2.733	< 0,001 ***
SEM	share_brick	0.499	0.085 .

ВЫВОДЫ

1. Проведена очистка и предобработка данных: из 25 877 объявлений после контроля типов, пропусков и удаления выбросов по перцентилям сохранено 24 713 (96%); 1 160 выходов метро проверены на пропуски координат. Квартиры привязаны к 128 районам Москвы, для каждой рассчитано расстояние до ближайшей станции; показатели агрегированы на уровень районов, мультиколлинеарность проконтролирована по VIF.
2. Глобальный индекс Морана для логарифма средней цены составил 0.559 при матрице Queen ($p < 0{,}001$): цены пространственно автокоррелированы, LISA выделяет ядро дорогого жилья в центре (26 районов High-High) и пояс дешёвого на периферии (14 районов Low-Low).
3. OLS-регрессия с пошаговым отбором (AIC) оставляет 4 фактора и объясняет 69% вариации логарифма средней цены ($R^2 = 0.688$). Ключевой фактор — доля вторичного жилья ($p < 0{,}001$): рост доли на 10 п.п. снижает среднюю цену района примерно на 23%. Значимы также средняя площадь ($p = 0{,}013$) и доля студий ($p < 0{,}001$).
4. Тест Морана на остатки OLS (I = -0.061, p 0.788) и LM-тесты (LMlag p 0.292, LMerr p 0.628) не выявляют остаточной пространственной зависимости: автокорреляция цен полностью объяснена пространственной кластеризацией наблюдаемых характеристик районов (вторичное жильё, студии, доступность метро), а не неучтённым пространственным взаимодействием.
5. Оценены SAR ($\rho = 0.044$, p 0.624) и SEM ($\lambda = -0.173$, p 0.250): параметры пространственной автокорреляции незначимы. По минимуму AIC и BIC лучшей признана модель OLS (AIC = 180.510, BIC = 197.480); косвенные эффекты в SAR составляют лишь 5.1% общих. Для описания цен на жильё Москвы на уровне районов достаточна классическая OLS-спецификация; значимость факторов

(структура рынка и типаж жилья) следует интерпретировать без поправки на пространственные переливы, поскольку последние статистически не обнаружены.