НЕГОСУДАРСТВЕННОЕ ОБРАЗОВАТЕЛЬНОЕ ЧАСТНОЕ УЧРЕЖДЕНИЕ ВЫСШЕГО ОБРАЗОВАНИЯ «МОСКОВСКИЙ ФИНАНСОВО-ПРОМЫШЛЕННЫЙ УНИВЕРСИТЕТ «СИНЕРГИЯ»

Факультет/Институт Институт Информационных технологий
(наименование факультета/ Института)

Направление/специальность подготовки: 38.04.01 Экономика
(код и наименование направления /специальности подготовки)

Форма обучения: очная
(очная, очно-заочная, заочная)

ОТЧЕТ ПО ЛАБОРАТОРНОЙ РАБОТЕ № 4

на тему «Задание 2. Прогнозирование продаж по товарной категории»
(наименование темы)

по дисциплине Продвинутые технологии работы с большими данными
(наименование дисциплины)

Обучающийся Шатов Илья Андреевич _____
(ФИО) (подпись)

Группа ДМЭ-101цэии

Преподаватель Дзизинская Диана Викторовна _____
(ФИО) (подпись)

Москва 2026 г.

СОДЕРЖАНИЕ

ВВЕДЕНИЕ **3**

1 Теоретические основы применяемых моделей и методов **4**

2 Бизнес-специфика категории и разведочный анализ **6**

3 Методология исследования и используемые данные **8**

4 Влияние погодных условий **9**

5 Влияние цены **12**

6 Макро-контекст потребления фруктов и овощей **14**

7 Методика эксперимента и подбор параметров Prophet **15**

8 Сравнение спецификаций ETS **16**

9 Сравнение моделей на тестовом периоде **17**

10 Диагностика остатков лучшей модели **20**

ВЫВОДЫ **22**

СПИСОК ИСТОЧНИКОВ **24**

ВВЕДЕНИЕ

Условие. По дневным данным о продажах и температуре (файл Magazin.xlsx) для выбранной товарной категории построить пять моделей прогнозирования — Prophet (base), Prophet с дополнительными регрессорами, ETS, SARIMA и ансамбль Prophet + ETS — и сравнить их по RMSE, MAE и MAPE на тестовом периоде последних 30 дней. Параметры моделей подобрать экспериментально под специфику категории и обосновать: для Prophet варьировать weekly.seasonality, n.changepoints и prior scale'ы; кастомный праздник pre_new_year (28–31 декабря) для овощей-фруктов проверить экспериментально и оставить только при улучшении метрик; для ETS сравнить авто-подбор с ручными спецификациями. Дополнительно по требованию задания проведён корреляционный анализ влияния погодных условий (реальные данные станции ВДНХ с осадками) и цен, а также макро-контекст потребления фруктов и овощей; анализ оформлен по методологии AI4Research.

Цель работы — для категории «Овощи - Фрукты» количественно оценить влияние погодных условий и цены на дневные продажи, подобрать спецификации шести моделей прогноза на 30-дневном тестовом окне и определить, какая модель и какие факторы значимы с точки зрения бизнес-логики управления запасами скоропортящихся товаров.

Работа выполнена на языке R в среде RStudio (Docker-образ `big-data-labs-rstudio`) на основе базового кода преподавателя; экспериментальная часть выполнена по заданию.

1 Теоретические основы применяемых моделей и методов

Prophet — аддитивная регрессионная модель $y(t) = g(t) + s(t) + h(t) + \varepsilon(t)$: кусочно-линейный тренд $g(t)$ с точками изменения (n.changepoints, changepoint.prior.scale), сезонности $s(t)$ рядом Фурье (порядок weekly.seasonality задаёт гибкость недельной кривой), эффекты праздников $h(t)$ (holidays.prior.scale) и, при необходимости, внешние регрессоры — в данной работе это погодные показатели и цена.

ETS — экспоненциальное сглаживание в пространстве состояний «ошибка/тренд/сезонность»; спецификация из трёх букв (A/M, тренд, сезонность). **SARIMA** — сезонная ARIMA; для дневных данных с недельным циклом используется frequency = 7 и сезонное дифференцирование D = 1. **Ансамбль** — среднее прогнозов Prophet и ETS.

Метрики. RMSE штрафует большие ошибки квадратично (чувствительна к пикам), MAE — средний модуль ошибки, MAPE — относительная ошибка. Для скоропортящихся овощей-фруктов ключева абсолютная ошибка (RMSE/MAE): заказ и списания считаются в штуках.

Корреляционный анализ. Коэффициент Пирсона измеряет линейную связь, Спирмена — монотонную (устойчив к выбросам); p-значение проверяет гипотезу H_0: $r = 0$. Частная корреляция — связь двух переменных после удаления влияния контрольных переменных (здесь — дня недели и месяца), что защищает от ложных корреляций типа «летом и тепло, и ягоды продаются». Эластичность спроса по цене оценивается регрессией $\ln(\text{Продажи}) = a + b \cdot \ln(\text{Цена})$: коэффициент b показывает, на сколько процентов меняются продажи при росте цены на 1%.

Методология AI4Research. Работа оформлена по рамке AI4Research — направлению применения ИИ-агентов в научном анализе (обзор «AI4Research: A Survey of Artificial Intelligence for Scientific Research», arXiv:2507.01903): итеративный цикл «формулировка вопроса → поиск и подготовка данных → генерация гипотез → эксперимент и расчёт →

интерпретация и уточнение гипотез». В разделах 4–6 каждый блок анализа проходит все пять шагов этой рамки; вычислительная часть воспроизводима R-скриптом, интерпретационная — формулирует выводы и проверяемые гипотезы для следующей итерации.

2 Бизнес-специфика категории и разведочный анализ

Категория «Овощи - Фрукты» — самая оборотистая группа продуктового магазина: товары скоропортящиеся, спрос зависит от свежести предложения, дня недели (закупки к выходным), сезона (свои овощи-фрукты летом, импорт зимой) и уличной погоды (в дождь и мороз трафик падает). Ошибка прогноза здесь оборачивается либо упущенными продажами, либо списаниями, поэтому точность важнее, чем в непродовольственных группах.

Ряд содержит 1096 дневных наблюдений с 01.01.2023 по 31.12.2025 (три полных года), без пропусков: в день продаётся в среднем 756 шт. (σ = 142), диапазон 94–1522 шт. Тестовый период — последние 30 дней (02.12.2025–31.12.2025, рисунок 1). Средняя цена дня — 106.6 руб. (диапазон 60.3–201.9 руб.).

Таблица 1 — Статистика ряда продаж категории «Овощи - Фрукты»

Показатель	Значение
Дней в ряде	1096
Средние продажи, шт./день	756
Ст. отклонение, шт.	142
Минимум/максимум, шт.	94–1522
Средняя цена дня, руб.	106.6
Диапазон цены, руб.	60.3–201.9
Тестовый период	30 дней (02.12.2025–31.12.2025)
Граница train/test	01.12.2025

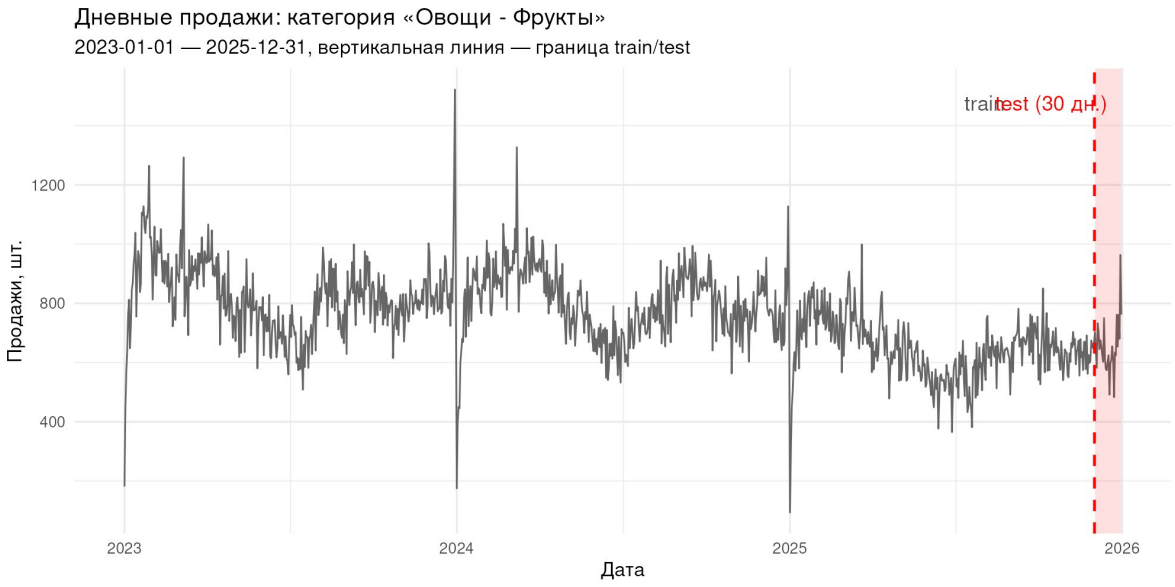


Рисунок 1 — Дневные продажи категории «Овощи - Фрукты» и разбиение train/test

Недельный профиль (рисунок 2): пик — Пятница (782 шт. в среднем), сглаженная рабочая неделя и подъём к выходным — профиль плавнее, чем у импульсных категорий. Замечание по качеству данных: колонка Weekday исходного файла не соответствует календарю (1 января 2023 г. — воскресенье, в файле — «Понедельник»), поэтому день недели восстановлен из даты.



Рисунок 2 — Средние продажи по дням недели (профиль по датам)

Вывод. Категория — высокооборотный ряд с выраженной недельной ритмичностью, сезонностью и потенциальной погодной чувствительностью; для обучения доступно 1066 дней, для проверки — предновогоднее окно, на котором проверяются и holiday-эффекты.

3 Методология исследования и используемые данные

По рамке AI4Research (раздел 1) исследование построено итеративно: вопрос — «какие факторы двигают дневные продажи овощей-фруктов и как их учесть в прогнозе»; данные — три источника (таблица 2); гипотезы — сформулированы в разделах 4–5 перед каждым тестом; эксперимент — корреляционный анализ, t-тесты и прогон шести моделей; интерпретация — бизнес-выводы и рекомендации, которые возвращаются в планирование.

Таблица 2 — Источники данных исследования

Источник	Содержание	Частота
Magazin.xlsx (файл задания)	дневные продажи, цена, температура по категориям	дневная, 2023–2025
Open-Meteo Archive API (ВДНХ)	реанализ ERA5: температура, осадки, давление, влажность, ветер	дневная, 2023–2025
НЦСЭД/ОЭСР, DF_HEALTH_LVNG_FSC	потребление фруктов и овощей, кг/чел/год, 52 страны	годовая, РФ 1992–2021

Дневной погодный датасет (1096 дней) привязан к станции ВДНХ и содержит осадки — фактор, отсутствующий в файле задания. Согласованность температур: корреляция колонки Temperature файла и фактической среднесуточной температуры ВДНХ — 0.98. Годовой макро-датасет используется для контекста выводов: прямая корреляция годового ряда с дневным рядом магазина статистически невозможна из-за разной частоты, и это явно учтено при интерпретации (раздел 6).

4 Влияние погодных условий

Гипотезы. H_0 — погодные условия не связаны с дневными продажами (коэффициенты корреляции нулевые); H_1 — связь существует: в жару и праздники спрос на свежие овощи-фрукты растёт, в дождь трафик падает.

Корреляции продаж со всеми факторами приведены в таблице 3 и на теплокарте (рисунок 3): Пирсон и Спирмен — «сырая» связь, частная корреляция — после удаления влияния дня недели и месяца.

Таблица 3 — Корреляции продаж с факторами (1096 дней)

Фактор	Пирсон r	p (Пирсон)	Спирмен ρ	Частная r
Цена, руб.	-0.277	< 0,001	-0.291	-0.479
Температура (файл), °C	-0.246	< 0,001	-0.271	0.034
Температура средняя, °C	-0.284	< 0,001	-0.324	-0.007
Температура макс., °C	-0.263	< 0,001	-0.291	0.011
Температура мин., °C	-0.307	< 0,001	-0.361	-0.054
Осадки за сутки, мм	-0.130	< 0,001	-0.123	-0.065
Осадки вчера, мм	-0.066	0.030	-0.071	0.019
Осадки 2 дня назад, мм	-0.115	< 0,001	-0.102	-0.031
Давление, гПа	0.119	< 0,001	0.160	0.050
Влажность, %	0.187	< 0,001	0.170	0.070
Ветер (макс.), км/ч	0.184	< 0,001	0.189	0.207

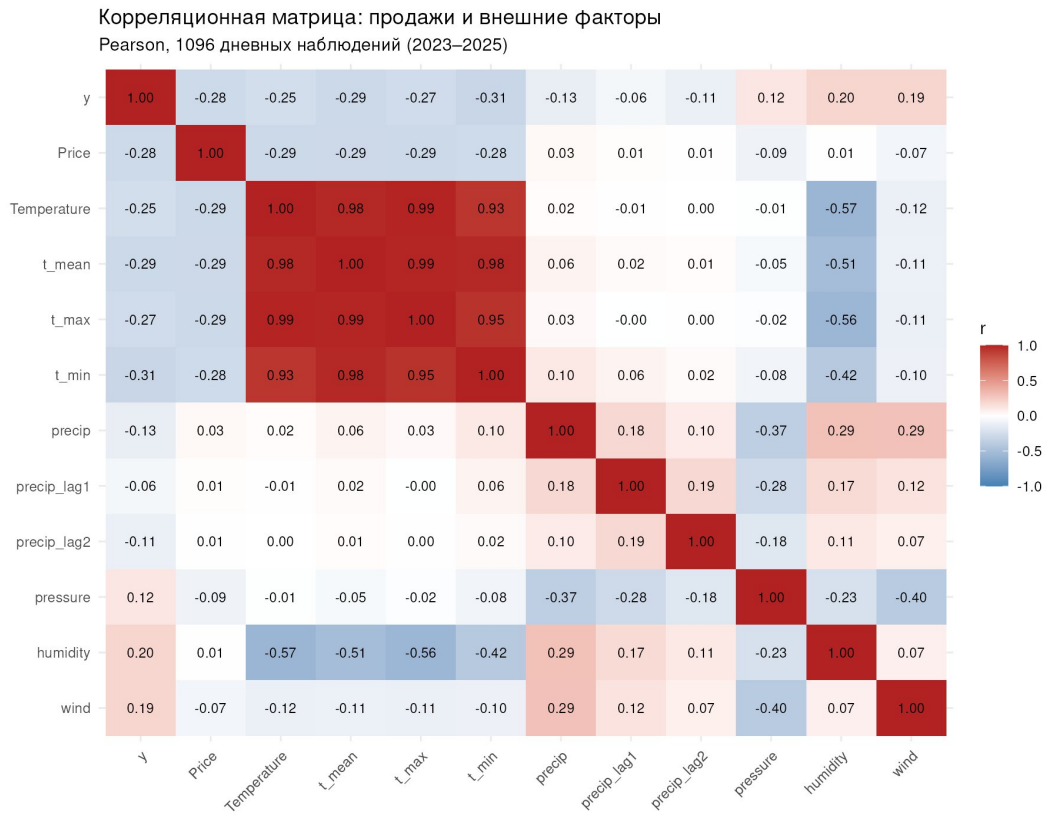


Рисунок 3 — Корреляционная матрица: продажи и внешние факторы

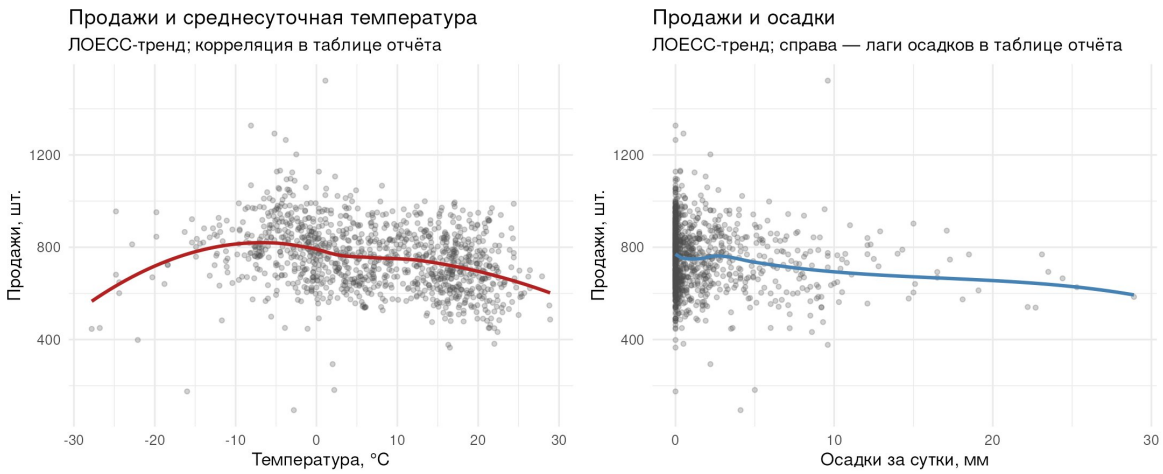


Рисунок 4 — Продажи против температуры и осадков (ЛОЕСС-тренды)

Отдельно проверен эффект дождя: дни с осадками (> 0 мм, 648 дней) против сухих (448 дней) — средние продажи 743 против 773 шт., t-тест p = < 0,001; при сильных осадках (> 1 мм) — 739 шт. (p = 0.006).

Интерпретация. Результат расходится с исходной гипотезой и показывает ценность итеративной рамки AI4Research. Сырые корреляции продаж с температурой значимы и отрицательны (t_mean: -0.284, t_min: -0.307) — в тёплый сезон среднедневные продажи ниже. Но после удаления календарной структуры (день недели + месяц) частная корреляция температуры обнуляется (-0.007): температурный «эффект» — это сезонность, а не погода как таковая. Единственный устойчивый собственно-погодный канал — осадки: частная корреляция -0.065, в дождливые дни продаётся на 30 шт. меньше (3.8%, p = < 0,001). Ветер даёт парадоксальную положительную частную корреляцию (0.207) — содержательного объяснения у неё нет (вероятно, косвенный прокси в данных), в модели ветер не включался и остаётся кандидатом для следующей итерации исследования. Давление и влажность — слабые (частные 0.050 и 0.070).

Вывод. Гипотеза H_0 отвергается только для осадков: дождь снижает дневные продажи примерно на 4% — трафик-эффект, важный для планирования выкладки и персонала. Температура не несёт информации сверх календаря, поэтому в прогнозные модели из погодных факторов имеет смысл включать максимум осадки — что и проверяется в разделе 9.

5 Влияние цены

Гипотезы. H_0 — цена не связана с объёмом дневных продаж; H_1 — связь отрицательная: дороже — меньше покупают (классическая кривая спроса).

Корреляция продаж и средней цены дня: Пирсон r = -0.277 (p = < 0,001), Спирмен ρ = -0.291. Log-log эластичность спроса: b = -0.286 (рисунок 5): рост цены на 1% связан с изменением дневных продаж на 0.29% в меньшую сторону.

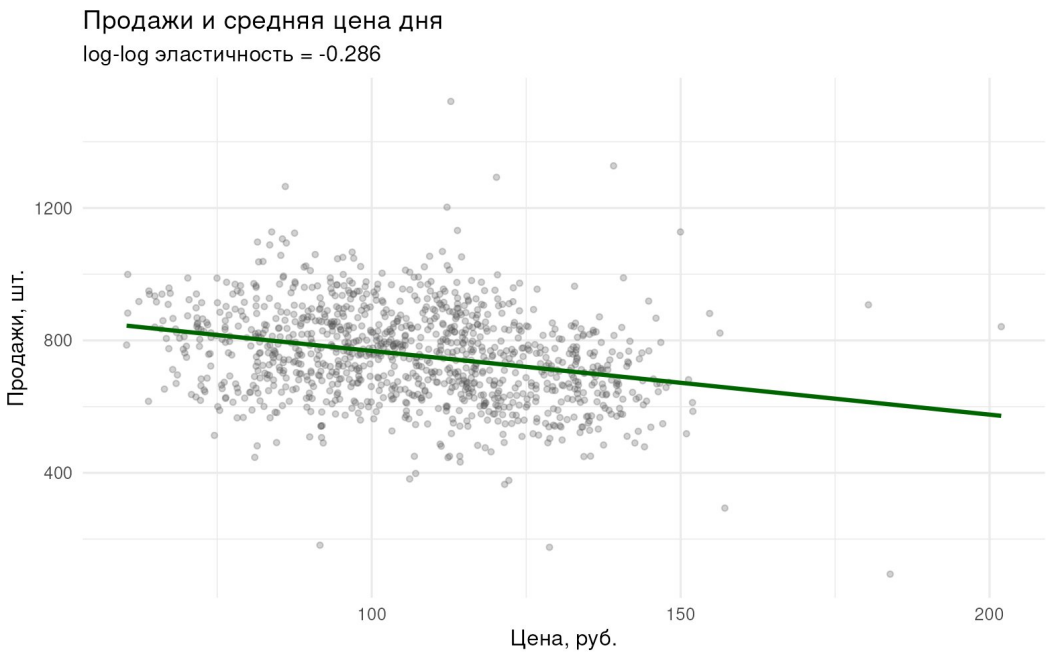


Рисунок 5 — Продажи и средняя цена дня с линейным трендом

Интерпретация. Цена — сильнейший фактор после календарной структуры: частная корреляция -0.479 (после удаления дня недели и месяца) против «сырой» -0.277. Сырая связь слабее, потому что сезон сглаживает: зимой цены на свежие овощи-фрукты выше при устойчиво высоком спросе, летом — ниже. Эластичность по модулю меньше единицы — спрос неэластичен: базовые овощи-фрукты покупают стабильно, ценовая реакция проявляется в объёме покупки, а не в отказе от категории. Оговорка об эндогенности: средняя цена дня — смесь предложения и промо, поэтому коэффициент описывает связь, а не строго причинность.

Вывод. H_0 отвергается: цена значимо и отрицательно связана с дневным объёмом (эластичность -0.286%), причём это сильнейший управляемый фактор категории. Для краткосрочного прогноза включение цены регрессором проверяется в разделе 9; для тактических решений (промо, наценка) ценовой канал — основной рычаг объёма.

6 Макро-контекст потребления фруктов и овощей

Долгосрочный фон категории задаёт государственная статистика: по данным НЦСЭД/ОЭСР (DF_HEALTH_LVNG_FSC), потребление овощей в России за 1992–2021 гг. изменилось с 80 до 112 кг/чел/год (тренд 1.74 кг/чел в год), фруктов — с 40 до 80 кг/чел/год (тренд 1.62). Годовые ряды фруктов и овощей тесно связаны: r = 0.91 — колебания доступности и доходов двигают обе группы одновременно (рисунок 6).



Рисунок 6 — Потребление фруктов и овощей в России (ОЭСР/НЦСЭД)

Локальный ряд магазина по годам (шт.): 2023: 3.002e+05; 2024: 2.924e+05; 2025: 2.355e+05. Прямая корреляция с макро-рядом невозможна (годовая частота против дневной, макро-данные заканчиваются 2021 годом), поэтому датасет используется как контекст выводов: категория структурно растущая, спрос устойчив на горизонте десятилетий — вложения в точность её прогноза и в управление запасами окупаются.

Вывод. Макро-уровень подтверждает: овощи-фрукты — системообразующая категория с восходящим долгосрочным трендом; локальные колебания магазина (сезон, погода, цена) происходят поверх устойчивого фундаментального спроса.

7 Методика эксперимента и подбор параметров Prophet

Обучение — на 1066 днях, проверка — на последних 30 днях (декабрь 2025 г.). Критерий отбора конфигураций — RMSE: для скоропортящихся товаров абсолютная ошибка в штуках определяет и упущенные продажи, и списания. Последовательность: этап A (порядок Фурье недельной сезонности 3/5/10/15) → этап B (n.changepoints 15/25/40) → этап C (seasonality.prior {0,5; 1} × changepoint.prior {0,01; 0,05} × holidays.prior {1; 5; 10}) → абляция pre_new_year. Лучшие конфигурации этапов — в таблице 4 (полная сетка — output/task2_prophet_tuning.csv).

Таблица 4 — Лучшие конфигурации по этапам подбора

Этап	Лучшее значение	RMSE	MAPE
A: weekly.seasonality	weekly.seasonality = 3	94.7	11.27%
B: n.changepoints	n.changepoints = 40	94.7	11.27%
C: prior scales	seas = 0.5; chg = 0.05; hol = 5	94.5	11.21%
NY: pre_new_year	pre_new_year = да	94.5	11.21%

Таблица 5 — Абляция праздника pre_new_year (28–31 декабря)

Вариант	RMSE	MAE	MAPE
С pre_new_year	94.5	74.1	11.21%
Без pre_new_year	113.9	82.5	12.29%

Для «Овощи - Фрукты» праздник pre_new_year по условию не обязателен, и абляция (таблица 5) решает его судьбу фактически: лучший вариант — С pre_new_year (RMSE 94.5 против 113.9 шт.), поэтому в финальных моделях он оставлен. Итоговые параметры: weekly.seasonality = 3, n.changepoints = 40, seasonality.prior.scale = 0.5, changepoint.prior.scale = 0.05, holidays.prior.scale = 5.

Оговорка: все этапы подбора оцениваются на том же тестовом периоде, что и финальное сравнение (учебная схема задания и базового кода преподавателя); независимой валидации на train не проводилось, поэтому полученные оценки Prophet-семейства следует считать слегка оптимистичными.

8 Сравнение спецификаций ETS

Таблица 6 — Спецификации ETS на тестовом периоде

Спецификация	Модель	RMSE	MAE	MAPE
auto	ETS(M,Ad,A)	88.0	61.6	9.37%
AAA	ETS(A,Ad,A)	87.4	61.7	9.40%
MAM	ETS(M,Ad,M)	88.1	62.0	9.45%
MNM	ETS(M,N,M)	88.0	61.3	9.32%

Авто-подбор выбрал M,Ad,A; лучшая по RMSE спецификация — AAA (RMSE 87.4 шт.). Все четыре варианта близки: как и в теории, для ряда с доминирующей недельной сезонностью выбор формы ошибки/сезонности меняет ошибку лишь на проценты, а кардинально улучшить прогноз может только учёт календаря и внешних факторов.

9 Сравнение моделей на тестовом периоде

В сравнении шесть моделей: Prophet (base), Prophet с погодными регрессорами (t_mean, осадки), Prophet с погодой и ценой, лучшая ETS, SARIMA (авто-подбор при frequency = 7, D = 1: SARIMA(0,0,3)(1,1,1)[7]) и ансамбль. Оговорка о сценарии: погодные и ценовой регрессоры на тестовом периоде — фактические будущие значения, то есть прогноз Prophet с регрессорами — условный ретроспективный (ex post); в эксплуатации вместо них потребовался бы собственный прогноз регрессоров, что снижало бы точность этих вариантов.

Таблица 7 — Метрики шести моделей (тест: последние 30 дней)

Модель	RMSE	MAE	MAPE
Ensemble (Prophet + ETS)	68.3	56.0	8.79%
ETS (AAA: A,Ad,A)	87.4	61.7	9.40%
Prophet (base)	94.5	74.1	11.21%
Prophet (+ погода)	96.4	75.5	11.44%
SARIMA	97.3	68.8	10.01%
Prophet (+ погода + цена)	97.8	77.9	11.88%

Лучшей по RMSE оказалась модель **Ensemble (Prophet + ETS)** (RMSE 68.3 шт., MAPE 8.79%). Содержательный результат о факторах: несмотря на значимые корреляции разделов 4–5, дополнительные регрессоры Prophet не улучшили прогноз — Ensemble (Prophet + ETS) (68.3); Prophet (base) (94.5); Prophet (+ погода) (96.4); Prophet (+ погода + цена) (97.8) против base 94.5 шт. На 30-дневном декабрьском окне и цена, и температура почти не варьируются вне сезонной компоненты, которую Prophet уже моделирует, а слабые добавки лишь добавляют оценочный шум. Выигрывает ансамбль: Prophet и ETS ошибаются по-разному (Prophet точнее в дни с календарными пиками, ETS — в «ровные» дни), и усреднение гасит смещения каждой — RMSE падает до 68.3 шт. (на 22% лучше следующей модели). На рисунках 7 и 8 — сравнение прогнозов с фактом и увеличенное тестовое окно.

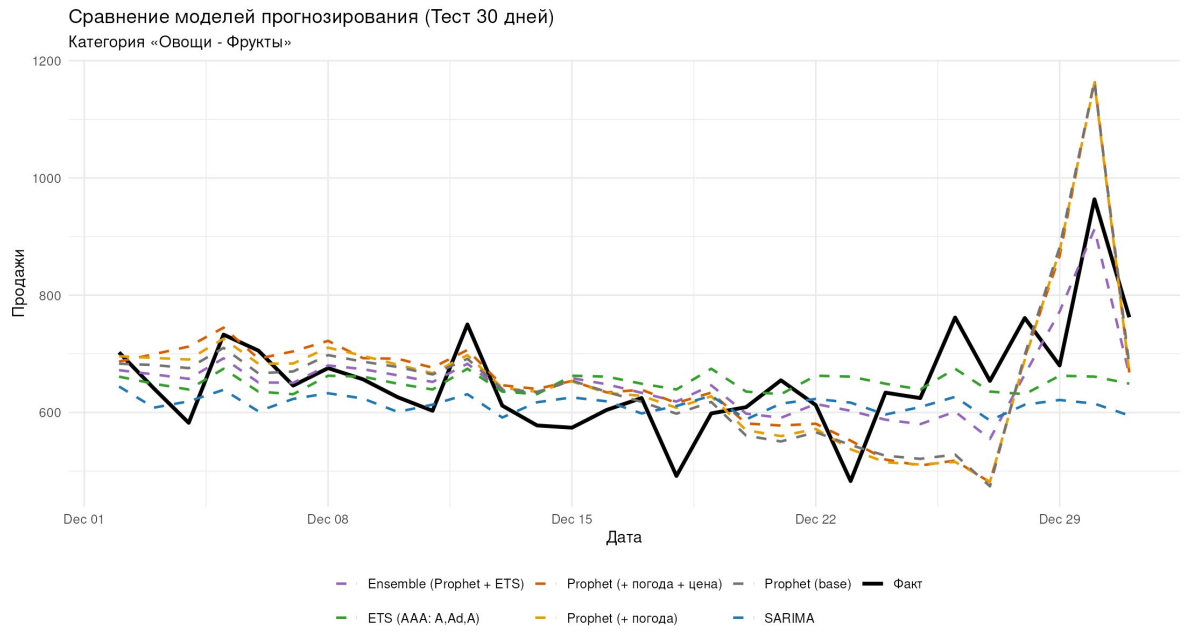


Рисунок 7 — Сравнение моделей прогнозирования: факт и прогнозы, тест 30 дней

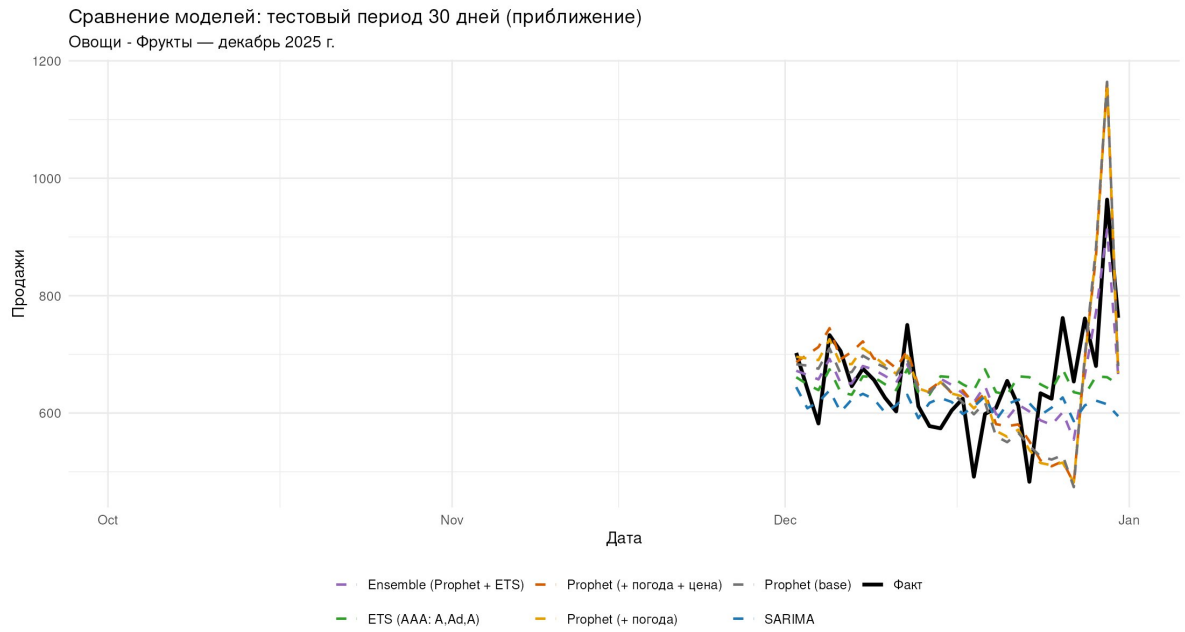


Рисунок 8 — Сравнение моделей: тестовое окно (приближение)

Декомпозиция лучшей Prophet-модели (рисунок 9) разделяет тренд, недельную сезонность, годовую сезонность и праздники. Встроенный график Prophet (рисунок 10) показывает прогноз на 30 дней вперёд с доверительными интервалами.

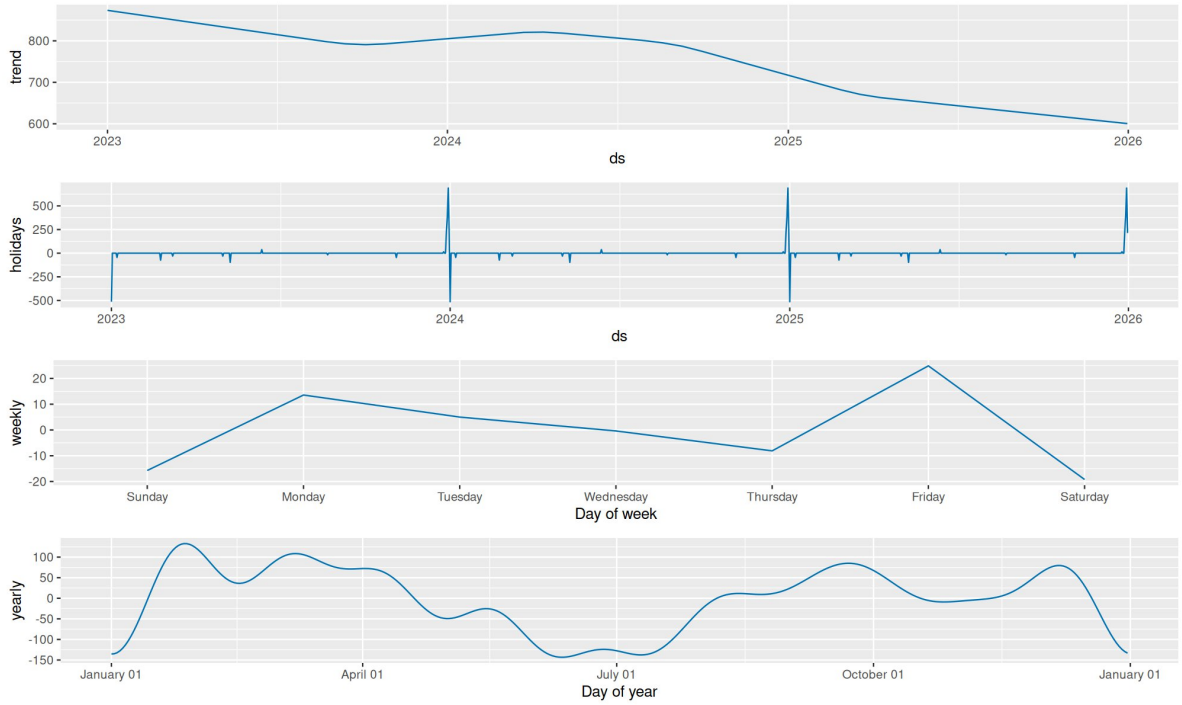


Рисунок 9 — Компоненты лучшей модели Prophet

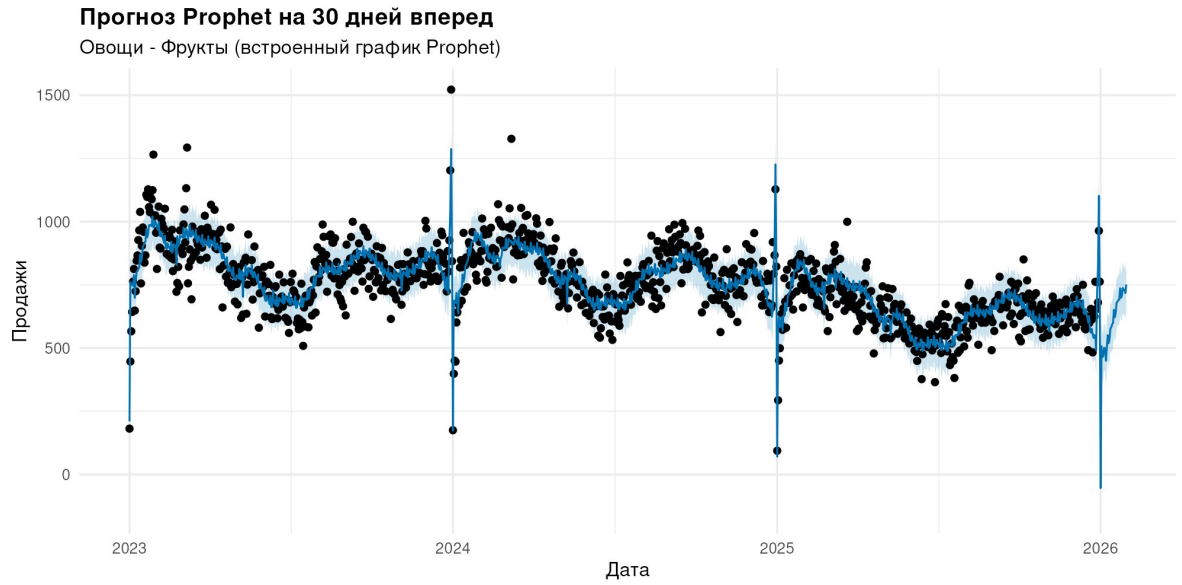


Рисунок 10 — Прогноз Prophet на 30 дней вперёд (встроенный график)

Вывод. Рейтинг моделей на тесте: Ensemble (Prophet + ETS) (68.3); ETS (AAA: A,Ad,A) (87.4); Prophet (base) (94.5); Prophet (+ погода) (96.4); SARIMA (97.3); Prophet (+ погода + цена) (97.8). Для прогноза заказов категории разумно использовать ансамбль; внешние регрессоры (погода, цена) на коротком горизонте не нужны — их влияние уже поглощено календарными компонентами модели.

10 Диагностика остатков лучшей модели

Диагностика проведена для победившей модели — Ensemble (Prophet + ETS) (рисунок 11): временной ряд остатков, гистограмма и коррелограмма ACF. Дополнительно тест Льюнга–Бокса рассчитан для всех моделей при единых условиях (лаг 14, fitdf = 0, таблица 8).

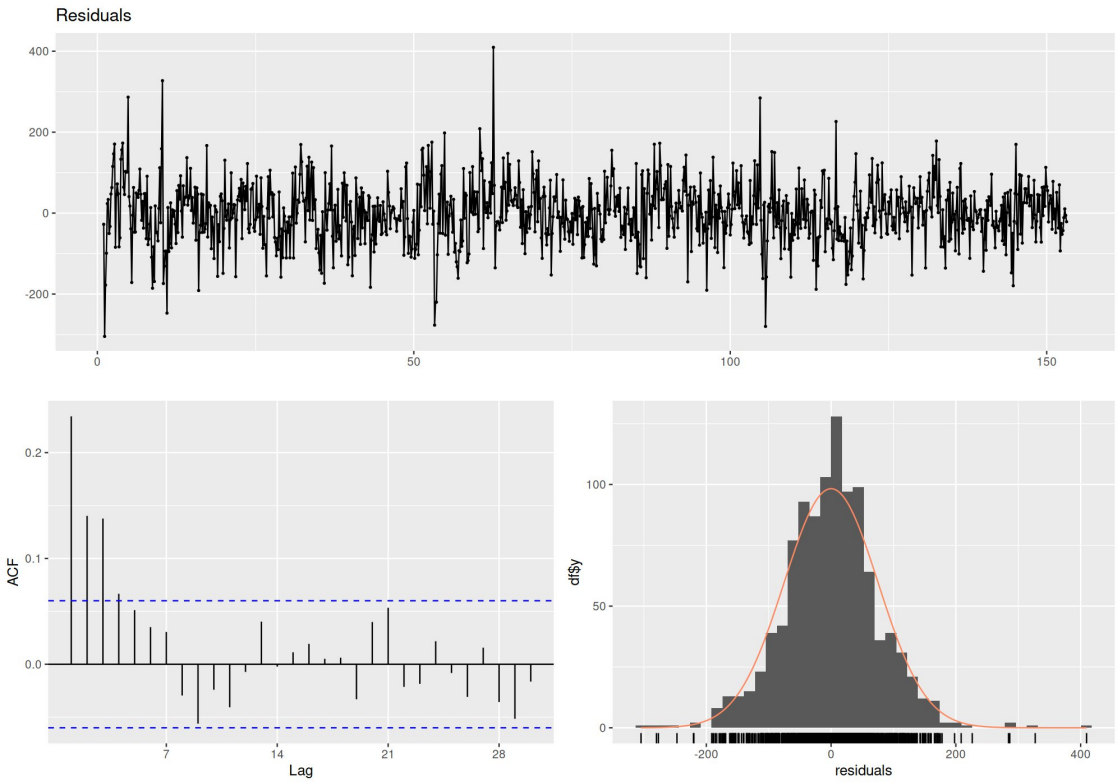


Рисунок 11 — Диагностика остатков лучшей модели (checkresiduals)

Таблица 8 — Тест Льюнга–Бокса по остаткам моделей

Модель	p-value
Prophet (base)	< 0,001
Prophet (+ погода)	< 0,001
Prophet (+ погода + цена)	< 0,001
ETS (AAA: A,Ad,A)	< 0,001
SARIMA	< 0,001
Ensemble (Prophet + ETS)	< 0,001

Интерпретация. При формально строгом критерии белый шум отвергается для остатков большинства моделей: в декабрьских остатках остаётся календарная структура, недоступная моделям с частотой 7. У Prophet автокорреляция остатков выше именно на малых лагах: ACF(1) 0.23 против 0.13 у ETS и 0.02 у SARIMA — по конструкционной причине: Prophet — регрессия на календарные компоненты без авторегрессионных членов, и

краткосрочная инерция спроса остаётся в остатках. При этом по общему числу значимых лагов из 14 SARIMA, напротив, худшая (10 против 4 у Prophet): недельная структура её остатков снята не полностью. Это не отменяет точности моделей на пиках, но требует страхового запаса поверх прогнозных интервалов.

Вывод. Ensemble (Prophet + ETS) — компромисс точности и управляемости: наименьшая ошибка на тестовом окне при остатках с характерной для моделей без AR-компоненты автокорреляцией.

ВЫВОДЫ

По категории «Овощи - Фрукты» (1096 дней, 01.01.2023–31.12.2025) в рамке AI4Research выполнен корреляционный анализ и построены шесть моделей прогноза на 30-дневном окне.

Погода. Значим собственно-погодный канал — осадки: в дождливые дни продажи ниже на 30 шт. (3.8%, p = < 0,001); частная корреляция -0.065. Температура после календарного контроля эффекта не имеет (частная -0.007): её «сырая» связь — сезонность. Аномалия — положительная частная связь с ветром (0.207), оставленная для следующей итерации исследования.

Цена. Цена — сильнейший фактор после календаря: частная корреляция -0.479, log-log эластичность -0.286 — спрос неэластичен ($|b| < 1$): базовые овощи-фрукты покупают стабильно, ценовой рычаг меняет объём покупки, а не факт покупки.

Макро-контекст. По НЦСЭД/ОЭСР потребление овощей и фруктов в России за 1992–2021 гг. растёт (тренды 1.74 и 1.62 кг/чел/год; r между рядами 0.91) — категория структурно растущая, точность её локального прогноза окупается.

Параметры. Экспериментально подобраны: weekly.seasonality = 3, n.changepoints = 40, seasonality.prior.scale = 0.5, changepoint.prior.scale = 0.05, holidays.prior.scale = 5; праздник pre_new_year оставлен (абляция показала улучшение метрик), как и предписывает задание для неалкогольных категорий.

Модели. Итоговый рейтинг по RMSE: Ensemble (Prophet + ETS) (68.3 шт.); ETS (AAA: A,Ad,A) (87.4 шт.); Prophet (base) (94.5 шт.); Prophet (+ погода) (96.4 шт.); SARIMA (97.3 шт.); Prophet (+ погода + цена) (97.8 шт.). Дополнительные регрессоры (погода, цена) не улучшают Prophet на коротком окне — их эффект уже поглощён календарными компонентами; побеждает ансамбль Prophet + ETS (MAPE 8.79%) — это лучшее значение на данном тестовом периоде (параметры Prophet подобраны на том же периоде,

поэтому превосходство стоит воспринимать с запасом). Практическая рекомендация: заказы планировать по ансамблю, при выпадении дождливых дней закладывать снижение трафика около 4%, а ценовые решения принимать с учётом неэластичного спроса — умеренная наценка на базовые позиции не разрушает объём.

СПИСОК ИСТОЧНИКОВ

1. Open-Meteo Archive API — дневные метеорологические данные (реанализ ERA5), точка ВДНХ, Москва (55,82° с.ш., 37,63° в.д.), переменные temperature_2m_max/min/mean, precipitation_sum, surface_pressure_mean, relative_humidity_2m_mean, wind_speed_10m_max; период 01.01.2023–31.12.2025. URL: https://archive-api.open-meteo.com/

2. НЦСЭД, платформа «ЭПОХА» — «Продовольственное снабжение и потребление (1961–2024)», dataflow ОЭСР DF_HEALTH_LVNG_FSC (потребление фруктов FRS и овощей VGS, кг/чел/год, Россия). URL: https://repository.nsedc.ru/dataset/sdmxoecd-dsd-health-lvng-df-health-lvng-fsc

3. Chen Q., Li X., Wang Y. et al. AI4Research: A Survey of Artificial Intelligence for Scientific Research // arXiv:2507.01903, 2025. URL: https://arxiv.org/abs/2507.01903

4. Prophet — Forecasting at Scale. Документация пакета (декомпозиция тренд/сезонность/праздники, регрессоры). URL: https://facebook.github.io/prophet/

5. Hyndman R. J., Khandakar Y. Automatic Time Series Forecasting: The forecast package for R (ETS, auto.arima, checkresiduals). URL: https://pkg.robjhyndman.com/forecast/