НЕГОСУДАРСТВЕННОЕ ОБРАЗОВАТЕЛЬНОЕ ЧАСТНОЕ УЧРЕЖДЕНИЕ ВЫСШЕГО ОБРАЗОВАНИЯ
«МОСКОВСКИЙ ФИНАНСОВО-ПРОМЫШЛЕННЫЙ УНИВЕРСИТЕТ «СИНЕРГИЯ»»

Факультет Информационных технологий

Направление подготовки:	09.03.02 Информационные системы и технологии	**Кафедра**	ИИиАД
(код, наименование)		*(аббревиатура)*	

Профиль: Разработка, сопровождение и обеспечение безопасности информационных систем

ОТЧЕТ ПО ЛАБОРАТОРНОЙ РАБОТЕ № 4

по дисциплине «Продвинутые технологии работы с большими данными»

на тему **Анализ потребительской корзины (Apriori)**

Обучающийся ***Шатов Илья Андреевич***

(Фамилия Имя Отчество) *(подпись)*

Группа ***ДМЭ-101цэии***

Преподаватель ***Дзизинская Диана Викторовна***

(Фамилия Имя Отчество) *(подпись)*

МОСКВА 2026 г.

СОДЕРЖАНИЕ

ВВЕДЕНИЕ..... 3

1 Данные и первичный анализ..... 4

2 Ассоциативные правила: построение и очистка..... 6

2.1 Метрики правил..... 6

2.2 Построение правил и удаление избыточных..... 6

2.3 Сильные правила..... 7

3 Система рекомендаций: прямой и обратный вывод..... 10

4 Бизнес-рекомендации по категориям..... 12

5 Ограничения анализа..... 14

ВЫВОДЫ..... 15

ВВЕДЕНИЕ

Условие. Запустить предоставленный R-скрипт, который строит ассоциативные правила для датасета Groceries (9835 транзакций, 169 товаров): алгоритм Apriori с параметрами support = 0,001 и confidence = 0,3, удаление избыточных правил, выделение бизнес-правил (lift > 1,2) и сильных (support ≥ 0,5%, lift > 2), визуализации, функция рекомендаций с прямым и обратным выводом, автоматическое формирование бизнес-рекомендаций по категориям (завтрак, выпечка, алкоголь, снеки, быстрый ужин, фрукты-овощи) и обратный вывод для молока. В отчёте объяснить смысл метрик support, confidence и lift на конкретных примерах, разобрать, почему для одних категорий правила найдены, а для других нет, объяснить разницу прямого и обратного вывода, предложить практические бизнес-рекомендации и описать ограничения анализа.

Цель работы — выявить устойчивые связи между товарами в покупательских корзинах сетевого магазина и превратить их в управленческие решения: выкладку, комплектацию наборов и ценовые акценты.

Работа выполнена на языке R в среде RStudio (Docker-образ `big-data-labs-rstudio`) с использованием пакетов `arules` и `arulesViz` по методическому скрипту преподавателя.

1 Данные и первичный анализ

Датасет Groceries входит в пакет `arules` и содержит реальные чеки английского продуктового магазина за месяц: 9 835 транзакций и 169 уникальных товаров. Транзакция — одна покупательская корзина, состав которой известен без количества купленных единиц.

```
data("Groceries")
summary(Groceries)
cat("Транзакций:", length(Groceries),
    "| Уникальных товаров:", length(itemLabels(Groceries)), "\n")
```

Средняя длина корзины — 4.41 товара: покупатель обычно берёт несколько позиций за один визит, и между позициями возможны устойчивые связи. Самые частые товары показаны на рисунке 1: `whole milk` присутствует в 25.6% корзин, `other vegetables` — в 19.3%, `rolls/buns` — в 18.4%.

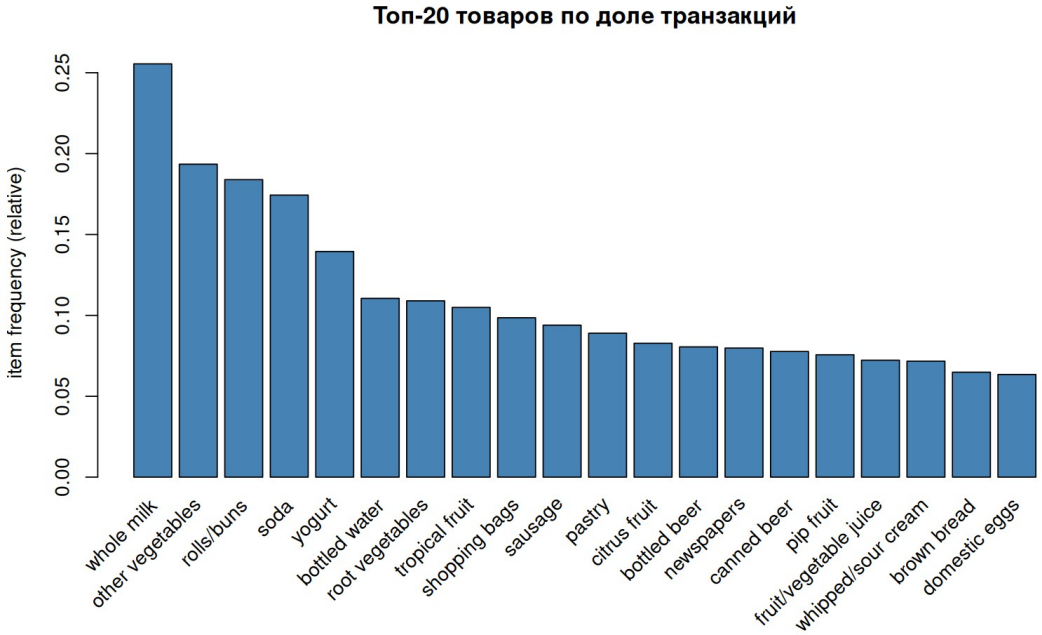


Рисунок 1 — Топ-20 товаров по доле транзакций

Распределение длины транзакций (рисунок 2) скошено вправо: корзины из 1–5 товаров дают основную массу чеков, длинные корзины редки. Именно поэтому в параметрах Apriori ограничена длина правил: `minlen = 2`, `maxlen = 4` — правила из 5+ товаров опирались бы на единичные чеки.

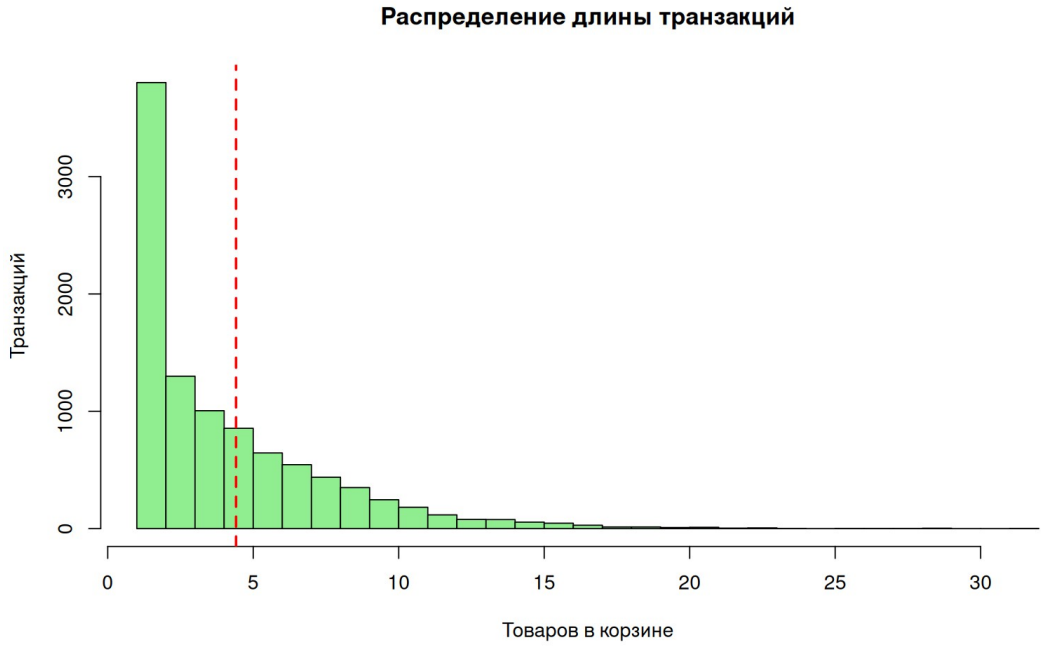


Рисунок 2 — Распределение длины транзакций (красная линия — среднее)

Вывод. Датасет — типичная «рыночная корзина»: высокая концентрация частоты у небольшого числа товаров-магнитов и длинный хвост редких позиций. Это задаёт стратегию поиска правил: считать support/confidence для пар и троек товаров вокруг товаров-магнитов.

2 Ассоциативные правила: построение и очистка

2.1 Метрики правил

Правило ассоциации записывается X → Y: «если в корзине есть набор X, то в ней же присутствует и Y». Для каждого правила считаются три метрики.

- **Support (поддержка)** — доля транзакций, содержащих и X, и Y: supp(X → Y) = P(X ∪ Y). Это частота, с которой правило вообще встречается в данных.
- **Confidence (достоверность)** — условная вероятность Y при наличии X: conf(X → Y) = P(Y | X) = supp(X → Y)/supp(X).
- **Lift (подъём)** — во сколько раз условная вероятность Y превышает безусловную: lift(X → Y) = conf(X → Y)/supp(Y). Lift > 1 — товары встречаются вместе чаще, чем при независимости; lift = 1 — независимы; lift < 1 — вместе покупают реже случайного.

На конкретном примере датасета: правило {citrus fruit, other vegetables, whole milk} → {root vegetables} имеет lift 4.1 — корнеплоды попадают в корзину с цитрусами, овощами и молоком в несколько раз чаще, чем в случайную корзину. Confidence такого правила (45%) означает: из всех корзин с цитрусами, овощами и молоком примерно в каждой 2-й лежат и корнеплоды. Но поддержка правила — лишь 0.58% корзин: событие редкое, хотя и очень выразительное.

2.2 Построение правил и удаление избыточных

Apriori запускался с широкой сеткой (support = 0,001; confidence = 0,3), чтобы не потерять редкие, но ценные связи.

```
rules <- apriori(Groceries,
                 parameter = list(support = 0.001, confidence = 0.3,
                                  minlen = 2, maxlen = 4, target = "rules"))

redundant <- is.redundant(sort(rules, by = "lift", decreasing = TRUE),
                          measure = "confidence")
rules_pruned <- sort(rules, by = "lift", decreasing = TRUE)[!redundant]
```

Таблица 1 — Воронка отбора правил

Этап	Количество
Найдено Apriori	12 181
Избыточные правила	1 362
После очистки	10 819
Бизнес-правила (lift > 1,2)	10 736
Сильные правила (support ≥ 0,5%, lift > 2)	255

Правило избыто, если существует более общее правило с тем же RHS и не меньшей достоверностью: например, если {A, B} → C и {A} → C имеют

одну confidence, то условие B ничего не добавляет. После очистки остаётся 10 819 правил (таблица 1) — каждое несёт самостоятельную информацию.

2.3 Сильные правила

Сильные правила (support ≥ 0,5% и lift > 2) — пересечение «часто» и «выразительно»: они опираются минимум на 50 чеков и поднимают вероятность покупки в два с лишним раза. Топ-10 правил по lift приведены в таблице 2.

Таблица 2 — Топ-10 сильных правил по lift

Правило	Поддержка	Достоверность	Подъём
citrus fruit,other vegetables,whole milk → root vegetables	0.006	0.445	4.09
herbs → root vegetables	0.007	0.431	3.96
citrus fruit,pip fruit → tropical fruit	0.006	0.404	3.85
tropical fruit,other vegetables,whole milk → root vegetables	0.007	0.411	3.77
root vegetables,whole milk,yogurt → tropical fruit	0.006	0.392	3.73
pip fruit,other vegetables,whole milk → root vegetables	0.005	0.406	3.72
tropical fruit,curd → yogurt	0.005	0.515	3.69
beef,other vegetables → root vegetables	0.008	0.402	3.69
onions,other vegetables → root vegetables	0.006	0.400	3.67
other vegetables,whole milk,fruit/vegetable juice → yogurt	0.005	0.485	3.48

На диаграмме рассеяния (рисунок 3) каждое правило — точка: по оси X — support, по оси Y — confidence, цвет — lift. Виден классический «закон рынка»: с ростом support confidence падает — самые частые правила связывают товары-магниты и потому имеют lift, близкий к 1, а высокие lift достигаются на редких сочетаниях.

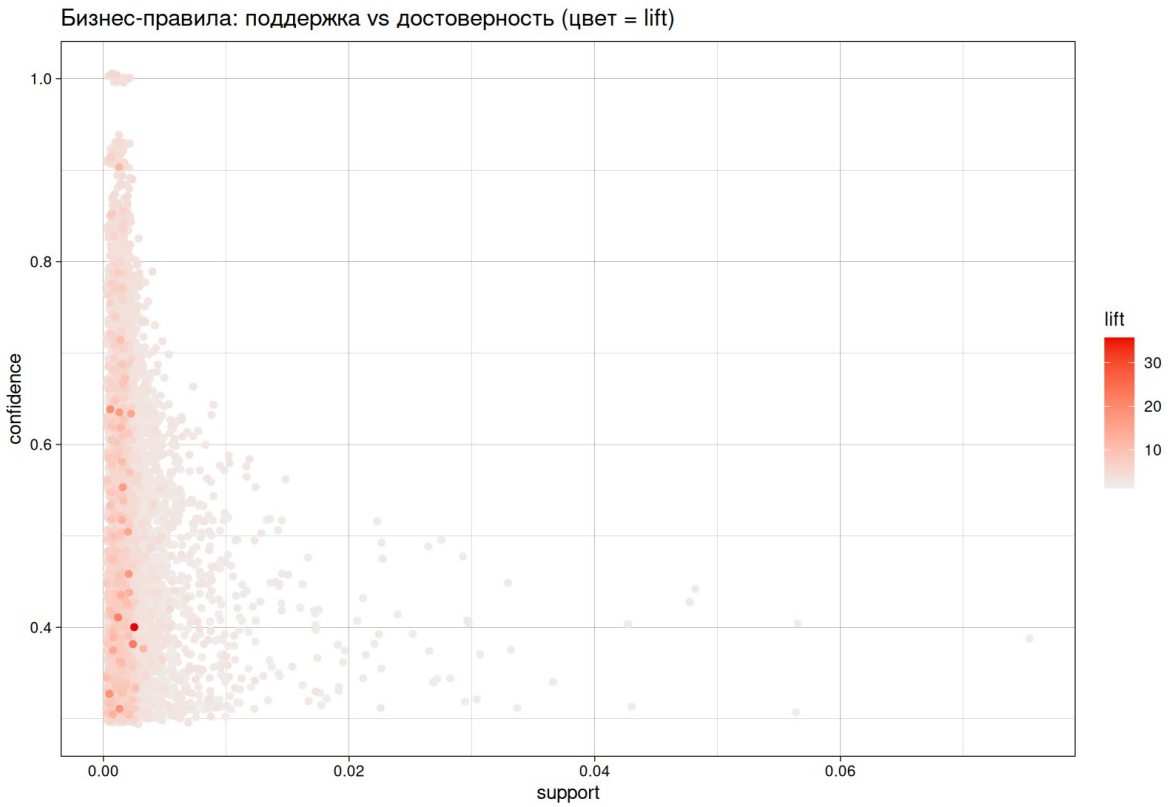


Рисунок 3 — Бизнес-правила: поддержка против достоверности (цвет — lift)

Граф сильных правил (рисунок 4) показывает ядро связей: молоко, овощи, йогурт и булочки — центральные вершины, к которым стягиваются условия большинства правил.

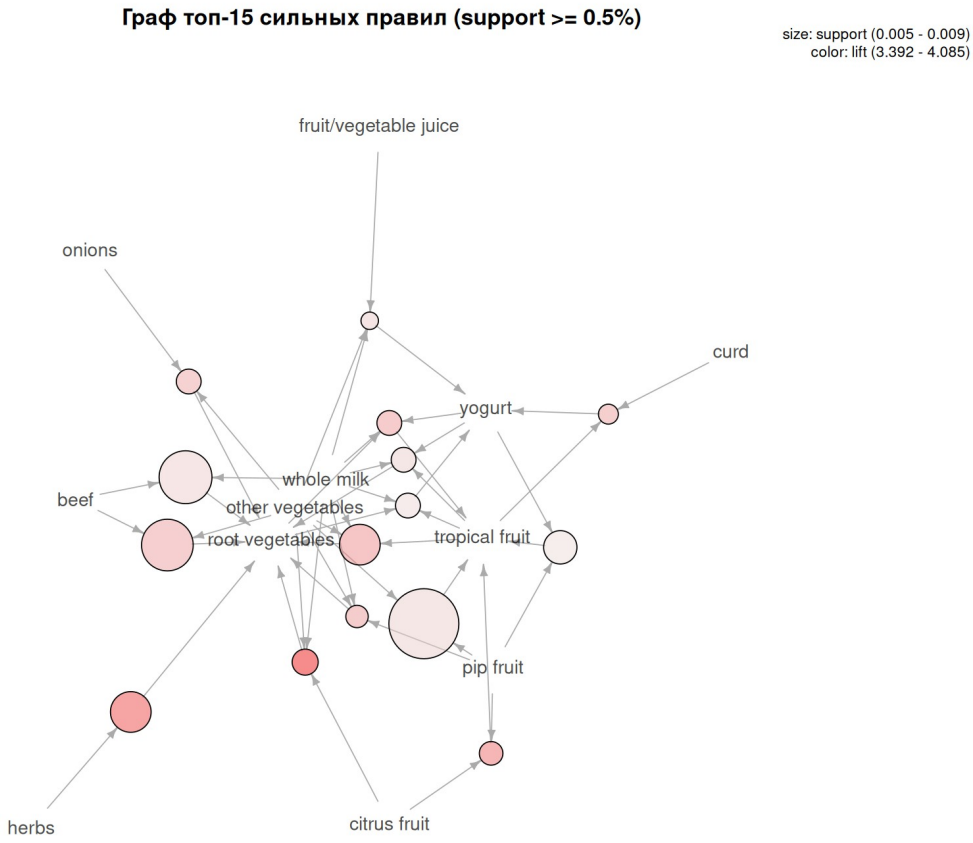


Рисунок 4 — Граф топ-15 сильных правил (support ≥ 0,5%)

Вывод. Из 12 181 найденных правил практическую ценность имеют 255 сильных: они одновременно статистически надёжны (высокая поддержка) и бизнес-значимы (lift > 2). Связка {butter, whipped/sour cream} → {whole milk} (lift 2.6) и {citrus fruit, other vegetables, whole milk} → {root vegetables} (lift 4.1) — характерные представители.

3 Система рекомендаций: прямой и обратный вывод

Функция `recommend_for_basket()` ищет правила двух типов для товаров переданной корзины.

Прямой вывод — правила вида «корзина ⊆ LHS»: если товары корзины содержатся в левой части правила, рекомендуются товары из RHS. Логика: «кто берёт X, тот берёт и Y».

Обратный вывод — правила вида «корзина ⊆ RHS»: товар корзины оказался в правой части, рекомендуются товары из LHS. Логика обратная: «кто берёт Y, обычно перед этим взял X». Это не то же самое, что прямой вывод: ассоциативные правила несимметричны.

Характерный пример — корзина {whole milk, other vegetables}. Для неё функция в том числе рекомендует мясные товары (frankfurter, sausage, ham, meat): прямого правила {молоко, овощи} → {мясо} в данных нет, но есть «зеркальные» правила, где молоко стоит справа: {meat} → {whole milk} (support 1.0%, confidence 39%, lift 1.51), а среди сильных правил — {sausage, whipped/sour cream} → {whole milk} (confidence 56%, lift 2.20) и {frankfurter, yogurt} → {whole milk} (confidence 55%, lift 2.17). Покупатели мяса и сосисок почти всегда берут молоко — значит, и покупатель молока и овощей является кандидатом на покупку мясного: в «зеркальных» корзинах мясное уже лежало рядом. Именно это и возвращает обратный вывод — товары из LHS.

Таблица 3 — Примеры рекомендаций для корзин

Корзина	Рекомендации
whole milk, other vegetables	frankfurter, sausage, liver loaf, ham, meat
white bread, butter	— (правил с support ≥ 0,5% нет)
bottled beer, red/blush wine	— (правил с support ≥ 0,5% нет)

Для корзин {white bread, butter} и {bottled beer, red/blush wine} сильных правил нет: совместные покупки этих пар реже порога 0,5% — сами по себе это ценные сигналы о границах метода (см. раздел 5).

Обратный вывод для молока по всем правилам с support ≥ 0,5% (таблица 3): чаще всего молоко оказывается в корзинах, где уже лежат {tropical fruit, root vegetables, yogurt} (confidence 70%), {pip fruit, root vegetables, other vegetables} и {butter, whipped/sour cream}. Молоко — типичный товар-«зеркало»: его кладут в корзину, которая уже «собралась» вокруг овощей, фруктов и масла.

Вывод. Прямой вывод отвечает на вопрос «что ещё положит покупатель с этими товарами», обратный — «что уже лежало в корзинах, где покупают этот товар». Для молока как товара-магнита решающим оказывается именно обратный вывод.

4 Бизнес-рекомендации по категориям

Автоматический подбор готовых наборов проверял для каждой категории сильные правила, где в LHS и RHS суммарно встречается не менее двух товаров категории (таблица 4).

Таблица 4 — Сильные правила по категориям

Категория	Правил найдено	Комментарий
Завтрак	19	хлеб + масло + молоко + яйца
Выпечка	0	нет: мука/сахар/маргарин редко в одном чеке
Алкоголь	0	нет: пиво/вино покупают отдельно
Снеки	0	нет: снеки — импульсная одиночная покупка
Быстрый ужин	3	сосиски + булочки: «хот-дог-эффект»
Фрукты-овощи	86	овощи, корнеплоды, цитрусы, фрукты

Категории разделились на «рабочие» (Фрукты-овощи — 86 правил, Завтрак — 19, Быстрый ужин — 3) и «пустые» (Выпечка, Алкоголь, Снеки — 0 правил). Причина — порог support ≥ 0,5%: пары «мука + сахар», «пиво + вино», «чипсы + газировка» встречаются реже, чем в 50 чеках из 9 835 (то есть реже полпроцента корзин). Это не отсутствие связи, а её недостаточная частота: такие покупки ситуативны, а не рутинны.

На основе найденных правил сформулированы управленческие рекомендации.

1. **Кросс-выкладка.** {citrus fruit, other vegetables, whole milk} → {root vegetables} (lift 4.1) — сезонные овощи и корнеплоды размещать в одном маршруте с цитрусами; {butter, whipped/sour cream} → {whole milk} — молочную группу собирать вокруг масла и сливок.
2. **Bundle-акции.** {rolls/buns} → {sausage} — готовые наборы «булочки + сосиски» (lift 3.3, классический «хот-дог-эффект»): скидка на набор выше, чем на части.
3. **Цена на товары-магниты.** whole milk (25.6% корзин), other vegetables, rolls/buns держат конкурентными: они формируют трафик, а маржа набирается сопутствующими товарами из правил. Магниты ставить в глубине зала — маршрут до них проходит мимо полок с сопутствующими.
4. **Промо-наборы «Завтрак»** (хлеб + масло + молоко/яйца — 19 правил) — готовые корзины выходного дня и «пятничный ужин» (овощи + сосиски + булочки).

Вывод. Правила конвертируются в четыре типа решений: маршрутизация потока (выкладка), комплектация наборов (bundle), ценевые

якоря (товары-магниты) и тематические промо. Наибольший запас — у категорий с высокой частотой: «Фрукты-овощи» и «Завтрак».

5 Ограничения анализа

Почему алкоголь и снеки не дали сильных правил. Пиво, вино и ликёр в Groceries — штучные позиции с поддержкой каждого правила ниже 0,5%: алкоголь покупается целенаправленно (одна позиция на чек), а не в связке. То же со снеками: чипсы или газировка — импульсная одиночная покупка. Порог support ≥ 0,5% отсекает эти связи как статистически ненадёжные: при частоте правила ниже ~50 чеков confidence меняется на десятки процентных пунктов от смены пары дней данных.

Зачем удалять избыточные правила. Избыточное правило — частный случай более общего ({A, B} → C при том же confidence, что и {A} → C). Без очистки 1 362 правил из 12 181 — шум: аналитик видит десятки вариантов одного и того же эффекта, а приоритезация по lift искажается дублированием. Очистка оставляет минимальную причинную структуру правил.

Почему support — ключевая метрика для практики. Confidence и lift можно «настроить» на любом сколь угодно редком правиле: пара, встретившаяся в 3 чеках из 9835, может показать confidence 100% и огромный lift, но у такого правила нет ни устойчивости, ни охвата аудитории. Support — единственная метрика, связывающая правило с реальным потоком чеков: она показывает, какая доля покупок затрагивается решением (выкладкой, набором), и задаёт доверительный интервал для оценки confidence. Поэтому бизнес-фильтрация начинается с порога support, и лишь затем ранжируются confidence и lift.

Дополнительные ограничения: данные одного месяца и одного магазина (нет сезонности и географии), отсутствие количества и цены в чеке (правила о факте совместной покупки, а не о корзинной стоимости), пороги 0,5%/2 выбраны как консервативный компромисс охвата и надёжности.

ВЫВОДЫ

В датасете Groceries (9 835 чеков) алгоритм Apriori нашёл 12 181 правил, из которых после удаления избыточных осталось 10 819, бизнес-значимых (lift > 1,2) — 10 736, сильных (support ≥ 0,5%, lift > 2) — 255.

Главные результаты: (1) выявлено ядро товаров-магнитов — молоко (25.6% корзин), овощи, булочки, газировка, йогурт; (2) найдены устойчивые межкатегорийные связи с lift до 4.1 — цитрусы+овощи+молоко → корнеплоды, масло+сливки → молоко, булочки → сосиски; (3) подтверждено, что рабочие наборы существуют в категориях «Фрукты-овощи» (86 правил), «Завтрак» (19), «Быстрый ужин» (3), а «Выпечка», «Алкоголь» и «Снеки» правил с support ≥ 0,5% не дают — их совместные покупки слишком редки; (4) построена рекомендательная функция с прямым и обратным выводом: для корзины {молоко, овощи} она предлагает мясо по правилу {мясо} → {молоко} — асимметрия ассоциативных правил.

Практическая ценность — готовые решения по выкладке, bundle-наборам, ценовым якорям и промо-категориям; ограничение — порог support ≥ 0,5% отсекает редкие, но потенциально прибыльные связи (алкоголь, снеки), для которых нужен либо больший объём данных, либо пониженный порог.